



Conservatoire National des Arts et Métiers

Projet STA201 : Analyse multivariée approfondie

Étude de cas : annulations de réservations hôtelières

Auteurs : ASSAL HAMZA
TRAORE SAH

Emails : assal.hamza@yahoo.fr
yacoubat16@yahoo.fr

Téléphones : +33 7 54 46 67 64
+33 7 58 57 86 34

Date : 17-05-2026

Table des matières

1	Présentation des bases théoriques des deux approches	3
1.1	Première approche : régression logistique	3
1.1.1	Sélection de variables	3
1.1.2	Régression logistique pénalisée	4
1.1.3	Stratégie d'évaluation des modèles	5
1.2	Deuxième approche : analyse discriminante sur variables qualitatives	5
1.2.1	Analyse discriminante linéaire	6
1.2.2	Analyse discriminante quadratique	6
1.2.3	Méthode des k plus proches voisins	7
1.2.4	Hypothèses et validation	7
2	Présentation de la base, préparation des données et démarche d'analyse	8
2.1	Présentation de la base	8
2.2	Préparation et analyse des données	8
2.2.1	Présentation des variables importantes à l'étude	8
2.2.2	Prétraitements et statistiques descriptives	8
2.2.3	Nettoyage, cohérence des données et ingénierie des variables	8
2.2.4	Analyse statistique élémentaire	9
2.3	Objectif de l'étude et démarche choisie	10
3	Résultats et interprétations de la première approche : régression logistique	11
3.1	Stratégie de modélisation	11
3.2	Résultats et interprétations	11
3.2.1	Interpretation et Importance des variables	12
3.3	Choix du seuil et discrimination	13
3.4	Conclusion	14
4	Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives	14
4.1	Stratégie de modélisation	14
4.2	Construction de l'ACM et interprétation des axes	14
4.2.1	Rôle de l'ACM dans la méthode DISQUAL	14
4.2.2	Inertie des axes factoriels	15

4.2.3	Représentation et interprétation des axes	15
4.3	Tests statistiques sur les axes de l'ACM	17
4.4	Choix du meilleur modèle et du nombre d'axes optimal	17
4.5	Choix du seuil de classification	18
5	Comparaison des résultats et conclusion	19
6	Sources des données et références	20
6.1	Reproductibilité	20
6.2	Données	20
6.3	Supports de cours	20
6.4	Références méthodologiques	20
7	Annexes	21
7.1	Annexe A - Base, préparation des données et statistiques descriptives	21
7.2	Annexe B - Objectif de l'étude et démarche choisie	25
7.3	Annexe C - Modèle logistique	25
7.3.1	Comparaison des modèles logistiques sur validation	25
7.3.2	AIC et complexité	26
7.3.3	Variables importantes du modèle complet	26
7.4	Annexe D - Analyse discriminante sur variables qualitatives	28
7.4.1	Inertie des axes factoriels	28
7.4.2	Représentation et interprétation des axes	29
7.4.3	Tests statistiques sur les axes de l'ACM	32
7.4.4	Choix du nombre d'axes et du classifieur	33

1 Présentation des bases théoriques des deux approches

1.1 Première approche : régression logistique

La régression logistique est une méthode de classification supervisée utilisée lorsque la variable à expliquer est qualitative, le plus souvent binaire. Elle permet d'estimer la probabilité qu'un individu appartienne à une modalité d'intérêt à partir d'un ensemble de variables explicatives quantitatives ou qualitatives. Lorsque les variables explicatives sont qualitatives, elles sont généralement transformées en variables indicatrices afin d'être intégrées au modèle.

L'objectif du modèle est d'estimer la probabilité conditionnelle de réalisation de l'événement : $P(Y = 1 | X) = p(X)$ où X représente l'ensemble des variables explicatives.

Contrairement à une régression linéaire classique, la probabilité estimée doit nécessairement rester comprise entre 0 et 1. Pour cette raison, la régression logistique utilise la fonction logit, qui transforme la probabilité en logarithme des chances, ou log-odds :

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

avec :

$p(X)$: la probabilité de réalisation de l'événement ;

β_0 : la constante du modèle ;

β_j : le coefficient associé à la variable explicative X_j ;

p : le nombre de variables explicatives intégrées au modèle.

Les coefficients sont généralement estimés par maximisation de la vraisemblance. L'interprétation des paramètres se fait souvent à partir des odds ratios, obtenus en exponentiant les coefficients : $OR_j = e^{\beta_j}$

Un odds ratio supérieur à 1 indique que la variable est associée à une augmentation des chances de réalisation de l'événement. À l'inverse, un odds ratio inférieur à 1 indique une diminution des chances de réalisation de l'événement. Lorsque l'odds ratio est proche de 1, l'effet de la variable est faible ou limité.

1.1.1 Sélection de variables

Dans un modèle comportant un nombre important de variables explicatives, une étape de sélection de variables peut être nécessaire. Elle vise à construire un modèle plus parcimonieux, c'est-à-dire un modèle qui conserve un nombre réduit de variables tout en maintenant un bon niveau de performance prédictive.

Les méthodes classiques de sélection reposent notamment sur des procédures dites stepwise. Trois approches sont généralement utilisées :

la sélection ascendante, ou forward, qui part d'un modèle vide puis ajoute progressivement les variables les plus pertinentes ;

la sélection descendante, ou backward, qui part du modèle complet puis retire progressivement les variables les moins pertinentes ;

la sélection mixte, qui combine les deux logiques précédentes.

Ces procédures peuvent s'appuyer sur des critères statistiques tels que l'AIC, le BIC ou la significativité des coefficients. Néanmoins, elles peuvent devenir instables en présence de variables fortement corrélées ou lorsque le nombre de variables est important. Dans notre contexte, les modèles pénalisés sont étudiés constituent une alternative pertinente.

1.1.2 Régression logistique pénalisée

Les méthodes de régression pénalisée consistent à modifier la fonction d'optimisation du modèle en ajoutant une contrainte sur les coefficients. L'objectif est de réduire la complexité du modèle, de limiter le surapprentissage et d'améliorer la capacité de généralisation sur des données nouvelles.

Dans le cadre d'une régression logistique classique, les coefficients sont estimés en maximisant la vraisemblance. Dans une régression pénalisée, on ajoute un terme de pénalisation à cette même fonction. De manière générale, le problème peut s'écrire sous la forme suivante :

$$\min_{\beta} [-\log L(\beta) + \text{Pénalité}(\beta)]$$

où $L(\beta)$ représente la vraisemblance du modèle et $\text{Pénalité}(\beta)$ le terme de régularisation appliqué aux coefficients.

1.1.2.1 Ridge

La régression ridge applique une pénalisation de norme L_2 sur les coefficients :

$$\min_{\beta} \left[-\log L(\beta) + \lambda \sum_{j=1}^p \beta_j^2 \right]$$

Le paramètre λ contrôle l'intensité de la pénalisation. Plus λ est élevé, plus les coefficients sont contraints vers zéro. La méthode ridge réduit la magnitude des coefficients sans les annuler complètement. Elle est particulièrement utile en présence de multicollinéarité, car elle stabilise les estimations lorsque plusieurs variables explicatives portent une information similaire.

1.1.2.2 Lasso

La méthode lasso repose sur une pénalisation de norme L_1 :

$$\min_{\beta} \left[-\log L(\beta) + \lambda \sum_{j=1}^p |\beta_j| \right]$$

Contrairement au ridge, le lasso peut ramener certains coefficients exactement à zéro. Il réalise donc simultanément une régularisation du modèle et une sélection automatique de variables. Cette propriété est particulièrement intéressante lorsque le nombre de variables explicatives est élevé ou lorsque certaines variables apportent peu d'information au modèle.

1.1.2.3 Elastic net

L'elastic net combine les deux types de pénalisation, ridge et lasso :

$$\min_{\beta} \left[-\log L(\beta) + \lambda \left((1 - \alpha) \sum_{j=1}^p \beta_j^2 + \alpha \sum_{j=1}^p |\beta_j| \right) \right]$$

Le paramètre α contrôle l'équilibre entre les deux pénalisations : $\alpha = 0$ correspond à une pénalisation ridge ; $\alpha = 1$ correspond à une pénalisation lasso ; $0 < \alpha < 1$ correspond à un compromis elastic net.

Cette approche est adaptée lorsque plusieurs variables sont corrélées entre elles. Elle combine la stabilité du ridge et la capacité de sélection du lasso.

1.1.3 Stratégie d'évaluation des modèles

L'évaluation du modèle repose sur plusieurs indicateurs issus de la matrice de confusion. L'accuracy mesure la proportion globale de bonnes classifications, mais elle peut être insuffisante lorsque les classes sont déséquilibrées ou lorsque l'on s'intéresse davantage à une classe particulière. La sensibilité, ou recall, mesure la proportion d'individus de la classe d'intérêt correctement détectés. La spécificité mesure la proportion d'individus de l'autre classe correctement reconnus. La précision indique, parmi les individus prédits dans la classe d'intérêt, la proportion qui appartient réellement à cette classe. Le F1-score combine précision et sensibilité, tandis que l'AUC mesure la capacité globale du modèle à séparer les classes indépendamment d'un seuil particulier.

Pour l'évaluation de la calibration du modèle, le score de Brier est privilégié au test de Hosmer-Lemeshow, compte tenu de la sensibilité extrême de ce dernier en présence d'un échantillon de grande taille. Le score de Brier donne ainsi une mesure plus stable et plus lisible dans ce contexte. Il est défini par : $\text{Brier} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2$ où $\hat{p}_i$ désigne la probabilité prédite d'annulation pour l'observation i , et y_i vaut 1 si la réservation est annulée et 0 sinon. Plus ce score est faible, meilleure est la qualité probabiliste du modèle.

1.2 Deuxième approche : analyse discriminante sur variables qualitatives

La méthode DISQUAL, développée dans la tradition de l'analyse des données de Saporta, est une méthode de discrimination adaptée aux variables qualitatives. Elle repose sur deux étapes principales : d'abord une Analyse des Correspondances Multiples (ACM), puis une méthode de classification supervisée appliquée aux coordonnées factorielles obtenues.

Soit un échantillon de n individus décrits par p variables qualitatives. Les données sont d'abord transformées en tableau disjonctif complet Z , dans lequel chaque modalité est codée par une indicatrice binaire. L'ACM permet ensuite de projeter les individus dans un espace factoriel continu. Chaque individu i est alors représenté par un vecteur de coordonnées $F_i = (f_{i1}, f_{i2}, \dots, f_{iK})$, où f_{ik} désigne la coordonnée de l'individu i sur l'axe factoriel k . Ces coordonnées deviennent les variables explicatives utilisées par les modèles de classification. En pratique, seuls les axes les plus informatifs sont conservés afin de limiter le bruit et le risque de sur-ajustement.

Dans une démarche prédictive rigoureuse, l'ACM doit être estimée uniquement sur la base d'entraînement. Les bases de validation et de test sont ensuite projetées comme individus supplémentaires. Cette précaution évite une fuite d'information, car les axes utilisés pour entraîner le modèle ne doivent pas être construits à partir d'observations servant ensuite à évaluer sa performance.

1.2.1 Analyse discriminante linéaire

La LDA, ou analyse discriminante linéaire, trouve son origine dans les travaux de Fisher. Il s'agit d'un classifieur probabiliste fondé sur le théorème de Bayes. On suppose que, conditionnellement à la classe $Y = k$, le vecteur explicatif X suit une loi normale multivariée : $X | Y = k \sim \mathcal{N}(\mu_k, \Sigma)$.

L'hypothèse centrale de la LDA est que les classes partagent une même matrice de covariance Σ , mais possèdent des moyennes différentes μ_k . Pour un individu décrit par un vecteur x , la règle de décision consiste à choisir la classe maximisant la probabilité a posteriori $P(Y = k | X = x)$. En appliquant la formule de Bayes, cette probabilité est proportionnelle au produit de la densité conditionnelle et de la probabilité a priori :

$$P(Y = k | X = x) \propto \pi_k f_k(x),$$

où π_k désigne la probabilité a priori de la classe k . Sous l'hypothèse d'une covariance commune, le logarithme de cette quantité conduit à la fonction discriminante linéaire :

$$\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log(\pi_k).$$

L'individu est affecté à la classe dont le score $\delta_k(x)$ est le plus élevé. Dans le cas de deux classes, la frontière de décision est une droite, ou plus généralement un hyperplan. Appliquée à DISQUAL, la LDA ne travaille donc pas directement sur les variables qualitatives initiales, mais sur les axes factoriels issus de l'ACM.

1.2.2 Analyse discriminante quadratique

La QDA, ou analyse discriminante quadratique, repose sur la même logique bayésienne que la LDA, mais relâche l'hypothèse d'égalité des matrices de covariance. On suppose alors : $X | Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$.

Chaque classe possède donc sa propre matrice de covariance Σ_k . La fonction discriminante devient :

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) + \log(\pi_k).$$

La frontière de décision entre deux classes n'est plus linéaire mais quadratique. La QDA est donc plus flexible que la LDA : elle peut représenter des séparations plus complexes lorsque les classes ont des dispersions différentes dans l'espace factoriel. Cette flexibilité a cependant un coût, car il faut estimer une matrice de covariance par classe. La QDA peut ainsi devenir instable lorsque le nombre d'axes conservés est élevé ou lorsque certaines classes sont peu représentées.

1.2.3 Méthode des k plus proches voisins

Le KNN, ou méthode des k plus proches voisins, adopte une logique différente de la LDA et de la QDA. Il ne suppose pas de distribution normale, ni de forme paramétrique de la frontière de décision. C'est une méthode non paramétrique fondée sur la proximité entre individus.

Pour prédire la classe d'un nouvel individu x , on calcule sa distance aux individus de la base d'entraînement dans l'espace des axes ACM. On retient ensuite les k individus les plus proches. La probabilité prédite d'annulation peut être estimée par la proportion de voisins appartenant à la classe d'annulation : $\widehat{P}(Y = 1 \mid X = x) = \frac{1}{k} \sum_{i \in N_k(x)} \mathbf{1}(Y_i = 1)$,

où $N_k(x)$ désigne l'ensemble des k plus proches voisins de x . L'individu est ensuite classé comme annulé si cette probabilité dépasse un seuil donné, par exemple 0,50, ou un seuil optimisé sur validation.

Le choix de k est crucial. Une faible valeur de k produit un modèle très local, sensible au bruit et aux observations atypiques. Une grande valeur de k lisse davantage la décision, ce qui peut améliorer la stabilité mais réduire la capacité à détecter des profils spécifiques. Dans le cadre DISQUAL, le KNN est particulièrement pertinent car les distances sont calculées dans un espace factoriel continu résumant les profils qualitatifs.

1.2.4 Hypothèses et validation

La LDA et la QDA reposent sur une hypothèse de normalité multivariée des coordonnées ACM conditionnellement aux classes. La LDA suppose en plus l'égalité des matrices de covariance. Ces hypothèses peuvent être étudiées à l'aide de tests de normalité et du test de Box. Toutefois, elles sont rarement parfaitement vérifiées en pratique, surtout lorsque les variables initiales sont qualitatives.

Ainsi, la LDA et la QDA peuvent être utilisées à la fois comme modèles probabilistes et comme classifieurs empiriques. Le choix final entre LDA, QDA et KNN doit donc reposer principalement sur la performance observée sur validation et sur test. Les paramètres importants, notamment le nombre d'axes ACM, le nombre de voisins k et le seuil de classification, doivent être sélectionnés sans utiliser la base de test afin de garantir une évaluation non biaisée.

2 Présentation de la base, préparation des données et démarche d'analyse

2.1 Présentation de la base

Notre étude s'appuie sur la base de données [Hotel Booking Demand Datasets](#), construite afin d'analyser le comportement d'annulation des réservations dans le secteur hôtelier. Cette base a notamment été diffusée sur Kaggle et documentée dans un article scientifique publié dans la revue *Data in Brief*. Les informations détaillées sur l'origine des données sont précisées dans la section Section 6.

La base contient 119 390 réservations provenant de deux types d'hôtels *Resort Hotel* et *City Hotel*. Chaque observation correspond à une réservation hôtelière, qu'elle ait donné lieu à un séjour effectif ou à une annulation.

La variable d'intérêt de notre étude est donc la variable indicatrice d'annulation, notée `is_canceled`, qui prend la valeur 1 lorsque la réservation a été annulée et 0 sinon.

La base de données ne contient pas de valeurs manquantes. Toutefois, certaines variables catégorielles, peuvent prendre la valeur « NULL ». Cette valeur ne correspond pas à une donnée absente, mais indique simplement que l'information n'est pas applicable. Par exemple, une valeur « NULL » pour la variable `children` signifie que la réservation ne comporte pas d'enfant.

2.2 Préparation et analyse des données

2.2.1 Présentation des variables importantes à l'étude

Les principales variables utilisées dans l'étude sont décrites en Annexe, dans le Tableau Table 9. Elles couvrent la nature de l'hôtel, la variable cible `is_canceled`, les caractéristiques temporelles de la réservation, la composition du séjour, le canal de réservation, le prix moyen journalier et les demandes particulières du client.

2.2.2 Prétraitements et statistiques descriptives

La structure générale de la base est résumée en Annexe dans le Tableau Table 10.

2.2.3 Nettoyage, cohérence des données et ingénierie des variables

Avant l'analyse statistique et la modélisation, plusieurs contrôles ont été réalisés afin de sécuriser l'utilisation de la base. L'objectif étant de conserver l'information disponible tout en traitant les situations susceptibles de produire des incohérences dans les variables construites ou dans les modèles.

La synthèse chiffrée de ces contrôles et décisions est présentée en Annexe dans le Tableau Table 11.

À l'issue de ces traitements, la base d'analyse contient 118563 observations. Ensuite, plusieurs travaux d'ingénierie des variables ont été opérés sur la base de compréhension métier de la problématique et des analyses statistiques.

Certaines variables initiales ont été transformées en indicateurs plus directement exploitables pour l'analyse. Plusieurs variables synthétiques ont été construites afin de rendre les résultats plus lisibles, de limiter le nombre de modalités et de disposer de profils interprétables.

Ces variables portent notamment sur le délai de réservation, la durée du séjour, le niveau de prix, la présence d'enfants, l'engagement du client, l'historique d'annulation, la saison touristique et l'origine géographique du client. La variable cible `is_canceled` a également été recodée sous forme factorielle avec les modalités `Non` et `Oui`, ce qui permet une lecture homogène des sorties descriptives et prédictives.

Ainsi, la variable `lead_time` devient `lead_time_cat` = (“derniere_minute”, “court”, “moyen”, “long”, “tres_long”), qui mesure d’une façon plus différenciée la durée entre la réservation et la date d’arrivée.

De même, les variables `total_of_special_requests`, `booking_changes` et `parking` deviennent `engagement_cat` qui mesure l’investissement du client dans la réservation.

L'exhaustivité des variables construites et leurs détails sont présentés dans le Tableau Table 12.

2.2.4 Analyse statistique élémentaire

Notre variable d'intérêt `is_canceled` présente **37 %** des réservations annulées, ce qui reste un niveau élevé. Cela justifie l'importance de ce type d'étude et fournit une base relativement équilibrée entre les deux modalités.




FIGURE 1 – Répartition de l’annulation et poids des modalités pour deux variables clés

Nous faisons un focus sur deux variables créées : le délai de réservation et l’engagement client. D’après l’analyse bivariable présentée dans la Figure 1, on constate que plus le délai de réservation est long, plus la probabilité d’annulation augmente. De même, un fort engagement du client se traduit par une faible probabilité d’annulation.

Vous trouverez un panorama des statistiques bivariées avec notre variable d'intérêt en annexe Figure 6

Une étude des associations entre variables a également été réalisée à partir du V de Cramer. Nous en déduisons une association faible entre la majorité des variables (V de Cramer $< 0,2$). Toutefois, quelques variables présentent une association forte, par exemple entre *market_segment* et *distribution_channel* (V de Cramér = 0,604). Ce constat nous a conduits à arbitrer entre ces deux variables. L'ensemble de la matrice des associations est détaillé dans la Figure 7 en annexe.

2.3 Objectif de l'étude et démarche choisie

L'objectif opérationnel du projet est de mieux identifier les réservations susceptibles d'être annulées. La démarche retenue consiste, après avoir construit des variables qualitatives interprétables, à mobiliser deux méthodes : la régression logistique, pour estimer une probabilité d'annulation et interpréter l'effet des facteurs explicatifs, et l'analyse discriminante sur variables qualitatives, pour étudier la discrimination entre les profils de réservations annulées et non annulées.

Pour les deux méthodes, nous avons retenu 12 variables qualitatives qui nous semblent les plus pertinentes pour l'étude. Elles sont présentées dans le Tableau ci dessous :

TABLE 1 – Variables retenues pour les modélisations

Variable	Modalité	Rôle dans l'analyse
is_canceled	Non ; Oui	Variable cible à prédire
hotel	City Hotel ; Resort Hotel	Distinguer City Hotel et Resort Hotel
market_segment	Direct ; Online_TA ; Offline_TA ; Corporate ; Other	Caractériser le canal commercial de réservation
customer_type	Contract ; Group ; Transient ; Transient-Party	Distinguer les profils de clients selon le type de réservation
lead_time_cat	derniere_minute ; court ; moyen ; long ; tres_long	Mesurer l'anticipation de la réservation
total_nights_cat	court_sejour ; moyen_sejour ; long_sejour	Regrouper les durées de séjour
adr_cat	q1_low ; q2_midlow ; q3_midhigh ; q4_high	Comparer les niveaux de prix
has_children	Non ; Oui	Identifier les réservations familiales
engagement_cat	faible ; moyen ; fort	Comparer les niveaux d'engagement
previous_cancellations_cat	Non ; Une_ou_plus	Capturer l'historique d'annulation
saison_tourisme	basse_saison ; moyenne_saison ; haute_saison ; pick_saison	Tenir compte de la saison touristique
identity_location	Europe_hors_PRT ; Local_Portugal ; Other_International	Résumer l'origine géographique du client pour la modélisation

En ce qui concerne la démarche de modélisation, la base de données a été divisée en trois sous-échantillons : une base d'entraînement (base train) contenant 50 % des observations, une base de validation contenant 25 % des observations et une base test contenant les 25 % restants. Ce découpage a été réalisé à l'aide d'un échantillonnage stratifié selon la variable cible.

Pour chaque méthode, les modèles ont d'abord été construits à partir de la base d'entraînement. Le choix du meilleur modèle a ensuite été effectué sur la base des performances observées sur la base de validation.

Une fois le modèle optimal sélectionné, celui-ci a été réestimé sur l'ensemble des données d'entraînement et de validation (soit 75 % des données). Enfin, l'évaluation finale des performances a été réalisée exclusivement sur la base test, laquelle n'a été utilisée ni pour la construction ni pour la sélection des modèles.

La Figure 8 en annexe présente la démarche suivie pour la modélisation.

3 Résultats et interprétations de la première approche : régression logistique

3.1 Stratégie de modélisation

Cette partie présente la construction des modèles de Régression logistique. L'objectif est double : comparer différentes stratégies de sélection de variables et évaluer l'apport des méthodes de régularisation telles que le ridge, le lasso et l'élastic net.

Les modèles sont estimés sur l'échantillon d'apprentissage (train). Dans une première étape le choix du modèle est réalisé sur l'échantillon de validation : l'AUC, le score de Brier et l'AIC (pour glm) ou AIC approximatif (pour pénalisé).

Une fois le modèle retenu, le seuil de classification est optimisé sur l'échantillon de validation à l'aide d'un grid search. Cette procédure consiste à faire varier le seuil de décision de 0,1 à 0,9 afin d'identifier celui qui offre le meilleur compromis entre détection des annulations et précision des prédictions. Cette seconde étape permet ensuite de transformer les probabilités prédites en classes Oui / Non de façon optimal.

La séparation entre le choix du modèle et la détermination du seuil évite de choisir un modèle uniquement parce qu'un seuil particulier lui donne ponctuellement un bon F1-score.

3.2 Résultats et interprétations

Nous présentons les critères de choix des modèles dans la table Table 2.

TABLE 2 – Critères de choix des modèles logistiques sur validation

Modèle	Type	AUC	Recall	F1-score	Brier score	AIC / AIC approx.	Coeff. non nuls	Choix
glm_full	GLM sélection	0.8783	0.7418	0.7474	0.1323	49293.56	27	Retenu
glm_backward	GLM sélection	0.8783	0.7418	0.7474	0.1323	49293.56	27	
glm_stepwise	GLM sélection	0.8783	0.7418	0.7474	0.1323	49293.56	27	
glm_forward	GLM sélection	0.8783	0.7418	0.7474	0.1323	49293.56	27	
elastic_net_075	Pénalisé	0.8767	0.7375	0.7456	0.1334	49715.51	25	
elastic_net_050	Pénalisé	0.8765	0.7431	0.7463	0.1335	49736.33	25	
elastic_net_025	Pénalisé	0.8765	0.7438	0.7464	0.1334	49705.75	26	
lasso	Pénalisé	0.8765	0.7427	0.7451	0.1336	49770.90	24	
ridge	Pénalisé	0.8712	0.7479	0.7393	0.1383	51567.37	27	

Le modèle retenu est le modèle complet glm_full. Ce choix est effectué avant l'optimisation du seuil, à partir des performances observées sur l'échantillon de validation. Les modèles GLM classiques présentent les meilleurs résultats globaux et le meilleur AIC. Les méthodes backward, forward et stepwise donnent des performances quasi identiques au modèle complet, ce qui montre que la sélection automatique ne simplifie pas réellement le modèle.

Les modèles pénalisés, tels que le ridge, le lasso et l'elastic net, n'apportent pas d'amélioration prédictive notable. Leur intérêt est surtout méthodologique, car ils permettent de régulariser les coefficients et de réduire l'importance de certaines modalités. Dans notre cas, cet apport reste limité.

3.2.1 Interpretation et Importance des variables

La Figure 2 présente l'importance de toutes les variables du modèle retenu `glm_full`. Les barres correspondent à l'importance totale, calculée comme la somme des valeurs absolues des coefficients exprimés en log-odds. La courbe indique l'importance moyenne par modalité, afin de nuancer l'effet du nombre de modalités. Les variables les plus marquantes sont `lead_time_cat`, `engagement_cat`, `market_segment`.




FIGURE 2 – Importance des variables du modèle logistique retenu

L'analyse des odds ratios permet de préciser le sens des effets associés aux principales variables du modèle. Le détail complet des coefficients est présenté en annexe Table 15. L'interprétation des odds ratios se fait par rapport à une modalité de référence.

Toutes choses égales par ailleurs, une réservation avec un délai **tres_long** présente des chances d'annulation environ 30,26 fois plus élevées, soit une hausse d'environ 2 926 % des chances d'annulation par rapport aux réservations de **derniere_minute**. Cela confirme le rôle central du délai de réservation `lead_time_cat`.

Pour `previous_cancellations_cat`, les réservations associées à la modalité **Une_ou_plus** ont des chances d'annulation environ 16,11 fois plus élevées par rapport à ceux qui n'ont pas d'antécédent d'annulation connu (**non**). L'historique d'annulation apparaît donc comme un signal fort du risque futur.

Pour `engagement_cat`, par rapport aux individus à **faible** engagement, ceux ayant un **fort** engagement voient leur chances d'annulation réduites d'environ 91 %. Un engagement élevé du client est donc associé à une plus grande stabilité de la réservation. Pour rappel `engagement_cat` est issu du data-engineering Table 12 en annexe.

Pour `market_segment`, les réservations en ligne provenant des agences de voyages (**Online_TA**) ont des chances d'annulation environ 4,50 fois plus élevées que le **Direct**, soit une hausse d'environ 350 %. Ce résultat suggère que les réservations effectuées via les agences en ligne sont plus exposées au risque d'annulation.

Enfin, pour `identity_location`, par rapport au reste de l'europe `Europe_hors_PRT`, les locaux `Local_Portugal` présente un odds ratio de 9,05, soit des chances d'annulation environ 805 % plus élevées.

3.3 Choix du seuil et discrimination

La Figure 3 complète cette lecture en présentant, côte à côte, l'évolution des métriques selon le seuil de classification et la courbe ROC du modèle complet. La courbe ROC synthétise la capacité de discrimination du modèle indépendamment du seuil choisi.

Le modèle complet est donc retenu comme référence principale, car il combine performance prédictive et interprétabilité. Il permet une lecture directe des coefficients et des odds ratios. Après sélection du modèle, le seuil de classification est fixé à 0.43. Sur l'échantillon de validation, l'AUC atteint 87.8%, le recall 74.2% et le F1-score 74.7%, ce qui traduit une bonne capacité à détecter les annulations tout en conservant une précision satisfaisante.




FIGURE 3 – Seuil de classification et courbe ROC du modèle logistique complet

Pour l'évaluation de la calibration du modèle, nous avons privilégié le score de Brier au test de Hosmer-Lemeshow, compte tenu de la sensibilité extrême de ce dernier en présence d'un échantillon de grande taille. Le score de Brier nous donne ainsi une mesure plus stable et plus lisible dans notre contexte.

Le score de Brier du modèle retenu est de 0.1323. Il mesure directement l'écart moyen entre les probabilités prédites et les annulations observées : plus il est faible, meilleure est la qualité probabiliste du modèle.

3.4 Conclusion

En synthèse, la régression logistique complète est retenue comme modèle de référence. Elle offre un bon compromis entre performance prédictive et interprétabilité, tout en permettant d'identifier les facteurs les plus associés à l'annulation. Les variables liées au délai de réservation, à l'engagement du client et au canal de réservation apparaissent comme les plus dominantes.

Le lasso reste utile comme analyse complémentaire, mais il ne simplifie que modérément le modèle. Il conserve 23 modalités explicatives, soit 24 coefficients non nuls avec l'intercept. Cela confirme que le choix du modèle complet reste cohérent avec l'objectif d'interprétation du rapport.

4 Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives

Cette partie présente l'application de la méthode DISQUAL à notre problème de prédiction des annulations. L'idée générale consiste à transformer les variables qualitatives en axes factoriels continus à l'aide d'une ACM, puis à utiliser ces axes comme variables explicatives dans des modèles de classification. Nous comparons donc trois modèles construits sur les axes ACM : la LDA, la QDA et le KNN.

4.1 Stratégie de modélisation

L'analyse discriminante est construite dans une logique strictement prédictive. Comme pour le modèle logistique, les mêmes bases train, validation et test ont été utilisées. La base train sert à apprendre la représentation factorielle et les modèles ; la base validation sert à choisir le meilleur modèle, le nombre d'axes optimal pour la prédiction et le seuil de classification ; la base test reste réservée à l'évaluation finale.

La sélection du modèle se fait en deux temps. Premièrement, on compare plusieurs nombres d'axes ACM et plusieurs modèles à partir de l'AUC sur validation. L'AUC est utilisée à cette étape car elle évalue la capacité de séparation du modèle indépendamment d'un seuil de classification particulier.

Deuxièmement, une fois le meilleur couple modèle / nombre d'axes retenu, le seuil de classification est optimisé sur validation, principalement à partir du F1-score afin de mieux équilibrer précision et rappel sur la classe des réservations annulées.

Après cette sélection, le modèle final est recalibré en utilisant train + validation pour l'ACM finale. La base test est alors projetée en individu supplémentaire, puis utilisée une seule fois pour mesurer la performance finale. Cette stratégie permet d'utiliser davantage de données pour le modèle final tout en conservant une évaluation précise et stricte sur la base test.

4.2 Construction de l'ACM et interprétation des axes

4.2.1 Rôle de l'ACM dans la méthode DISQUAL

L'analyse des correspondances multiples (ACM) est l'étape qui transforme les variables qualitatives en axes factoriels continus. Dans notre cas, les variables explicatives sont des profils de réservation :

type d'hôtel, segment de marché, type de client, délai de réservation, durée du séjour, niveau de prix, présence d'enfants, engagement, historique d'annulation, saison touristique et origine du client.

L'ACM permet donc de passer d'une lecture variable par variable à une lecture en **profils**. Chaque axe oppose des combinaisons de modalités.

La variable cible `is_canceled` est ajoutée comme variable qualitative supplémentaire. Elle ne participe donc pas à la construction des axes, mais elle est projetée sur ces axes pour vérifier si les profils factoriels sont liés au risque d'annulation.

4.2.2 Inertie des axes factoriels

L'inertie indique la part de structure du tableau disjonctif expliquée par chaque axe. L'inertie expliquée par les 5 premiers axes (33 %) est représentée dans le tableau ci-dessous.

TABLE 3 – Inertie des premiers axes de l'ACM

Axe	Valeur propre	Inertie (%)	Inertie cumulée (%)
dim 1	0.2229137	9.43	9.43
dim 2	0.1715162	7.26	16.69
dim 3	0.1470762	6.22	22.91
dim 4	0.1296038	5.48	28.39
dim 5	0.1106199	4.68	33.07

On note que nous avons 26 axes au total. En annexe, la représentation de l'inertie de l'ensemble des axes est disponible dans la Figure 9.

4.2.3 Représentation et interprétation des axes

La représentation graphique suivante affiche les modalités les plus contributives sur les deux premiers axes factoriels. Les libellés utilisent la forme **variable = modalité**. La cible est ajoutée en bleu comme variable supplémentaire. Ainsi, le graphique montre à la fois la structure des profils et la position descriptive de l'annulation.




FIGURE 4 – Plan factoriel 1-2 avec modalités labellisées

Nous pouvons ainsi interpréter précisément les axes obtenus :

4.2.3.1 Axe 1 : engagement apparent contre risque historique et canal de réservation

L'axe 1 oppose, du côté négatif, des réservations à engagement apparent fort, caractérisées notamment par la présence d'enfants, un prix élevé et un niveau d'engagement important, à des profils situés du côté positif, davantage marqués par un historique d'annulation, certains segments de marché et des canaux de réservation spécifiques. La projection de `is_canceled = Oui` du côté positif suggère que les annulations sont descriptivement plus associées aux profils présentant un risque historique ou commercial qu'aux réservations traduisant un engagement plus fort dans le séjour.

4.2.3.2 Axe 2 : Délai de réservation et mode de commercialisation

L'axe 2 traduit principalement une opposition liée au délai de réservation et au mode de commercialisation. Il distingue les réservations très anticipées ou intermédiées par des canaux offline, associées notamment aux clients contractuels, des réservations de dernière minute, corporate ou de groupe. D'un point de vue métier, cet axe montre que le risque d'annulation dépend fortement du délai et du canal de réservation ainsi que du type de client.

Une représentation des autres axes 3, 4 et 5 est disponible en annexe Figure 10 et Figure 11 ainsi que des modalités structurantes sur chaque axe sur Figure 12

4.3 Tests statistiques sur les axes de l'ACM

Avant la grid search, nous évaluons les hypothèses statistiques associées aux axes factoriels issus de l'ACM, construits uniquement sur la base d'entraînement. Cette étape permet de vérifier dans quelle mesure les axes utilisés comme variables explicatives sont compatibles avec les hypothèses de l'analyse discriminante.

La normalité est étudiée à deux niveaux : axe par axe avec le test de Shapiro-Wilk, puis globalement avec les tests multivariés de Mardia et de Henze-Zirkler. L'homogénéité des matrices de covariance entre les deux classes de `is_canceled` est vérifiée avec le test de Box's M. Les résultats détaillés de ces diagnostics sont présentés dans les tableaux Table 17, Table 18 et Table 19.

Ces tests ne déterminent pas directement le modèle final, mais ils éclairent la validité théorique de la LDA et de la QDA. Si la normalité ou l'homogénéité des covariances sont rejetées, les modèles restent utilisables comme classifieurs prédictifs, mais leur interprétation probabiliste doit être nuancée. Le choix final repose donc principalement sur la performance observée en validation, via la sélection du nombre d'axes, du modèle et du seuil de classification.

4.4 Choix du meilleur modèle et du nombre d'axes optimal

Le nombre d'axes ACM ne doit pas être choisi uniquement à partir de l'inertie factorielle. Dans notre cadre, l'objectif est prédictif : nous cherchons le nombre d'axes qui améliore réellement la capacité à distinguer les réservations annulées des réservations non annulées. Pour cette raison, une grille de recherche est appliquée sur la base validation.

La grille compare plusieurs nombres d'axes pour la LDA, la QDA et le KNN. Pour le KNN, plusieurs valeurs de `k` sont aussi testées. Ce paramètre correspond au nombre de voisins utilisés pour classer une réservation.

En voici un tableau récapitulatif :

TABLE 4 – Meilleure performance de validation par famille de modèle

Modèle	Axes	k	AUC	Accuracy	Recall	Spécificité	Précision	F1-score	Balanced accuracy
ACM + KNN	26	15	0.8924	0.8199	0.6777	0.9044	0.8081	0.7372	0.791
ACM + KNN	26	26	0.8915	0.8158	0.6583	0.9094	0.8118	0.727	0.7838
ACM + LDA	26	-	0.8753	0.8128	0.6923	0.8844	0.7805	0.7338	0.7884
ACM + KNN	26	5	0.8751	0.8144	0.7018	0.8813	0.7783	0.7381	0.7916
ACM + QDA	26	-	0.8582	0.7388	0.8653	0.6638	0.6045	0.7117	0.7645

TABLE 5 – Synthèse de la recherche du paramètre `k` pour le KNN

k	Meilleure AUC	Meilleur F1-score	Nombre d'axes associé à la meilleure AUC
15	0.8924	0.7372	26
26	0.8915	0.7297	26
5	0.8751	0.7396	26

Une première lecture des résultats de validation conduirait à retenir directement le modèle présentant la meilleure AUC dans la Table 20 en annexe. Dans notre cas, il s'agit du modèle KNN avec `k`

= 15 et 26 axes ACM. Toutefois, notre objectif n'est pas uniquement de maximiser la performance apparente sur validation : nous cherchons aussi à conserver un modèle parcimonieux, plus stable et moins exposé au risque de sur-ajustement. Nous examinons donc plus finement les gains marginaux d'AUC associés à l'ajout progressif d'axes factoriels. Cette analyse montre que le passage de 15 à 26 axes améliore très peu l'AUC, alors qu'il augmente sensiblement la complexité du modèle. Nous retenons donc le modèle KNN avec $k = 15$ et 15 axes ACM comme compromis entre précision prédictive, stabilité et parcimonie.

TABLE 6 – Gains marginaux d'AUC selon le nombre d'axes pour le KNN retenu

Nombre d'axes	k KNN	AUC	Gain vs étape précédente	Gain vs 15 axes	Écart au meilleur	Lecture
1	15	0.8468	-	-0.0393	0.0456	Gain encore utile
2	15	0.8590	0.0121	-0.0272	0.0334	Gain encore utile
3	15	0.8550	-0.004	-0.0312	0.0374	Gain encore utile
4	15	0.8676	0.0126	-0.0185	0.0248	Gain encore utile
5	15	0.8731	0.0055	-0.0131	0.0193	Gain encore utile
7	15	0.8815	0.0084	-0.0047	0.0109	Gain encore utile
10	15	0.8838	0.0023	-0.0024	0.0086	Gain encore utile
15	15	0.8862	0.0024	0.0000	0.0062	Choix retenu
20	15	0.8865	3e-04	0.0003	0.0059	Gain marginal faible
26	15	0.8924	0.0059	0.0062	0.0000	Gain marginal faible

Une représentation graphique de l'évolution de l'AUC (Figure 13) et du F1-score (Figure 14) par modèle est disponible en annexe.

4.5 Choix du seuil de classification

Après le choix du modèle discriminant parcimonieux, défini par le KNN avec $k = 15$ et 15 axes ACM, nous procédons à l'optimisation du seuil de classification. En effet, le modèle produit un score associé à la modalité `is_canceled = Oui`, mais le seuil usuel de 0,50 n'est pas nécessairement optimal, en particulier lorsque l'objectif est d'améliorer la détection des annulations.

Nous réalisons donc une grid search du seuil sur la base validation, en testant une grille de valeurs comprises entre 0,10 et 0,90. Pour chaque seuil candidat, les observations sont classées en `Oui` ou `Non`, puis les indicateurs de performance sont recalculés. Le critère principal retenu est le F1-score, car il permet d'arbitrer entre le rappel, c'est-à-dire la capacité à détecter les annulations, et la précision, c'est-à-dire la limitation des fausses alertes. Le seuil finalement retenu est 0.34.

TABLE 7 – Seuil de classification retenu sur validation pour le modèle discriminant parcimonieux

Modèle	Axes ACM	k KNN	Seuil	Accuracy	Recall	Spécificité	Précision	F1-score	Balanced accuracy
ACM + KNN	15	15	0.34	0.8111	0.7706	0.8351	0.7352	0.7525	0.8029

5 Comparaison des résultats et conclusion

Cette dernière partie confronte les deux approches sur la base test, qui n'a pas été utilisée pour choisir les variables, le nombre d'axes, les hyperparamètres ou les seuils. Elle donne donc la mesure la plus honnête de la capacité de généralisation des modèles.

TABLE 8 – Performance finale des modèles sur la base test

Modèle	Seuil	Accuracy	AUC	Recall	Spécificité	Précision	F1-score	Balanced accuracy
ACM + KNN (15 axes, k=15)	0.34	0.8174	0.8967	0.7825	0.8381	0.7417	0.7615	0.8103
Regression logistique - glm_full	0.43	0.8148	0.8808	0.7374	0.8608	0.7588	0.7479	0.7991




FIGURE 5 – Comparaison finale des principaux indicateurs sur test

La régression logistique conserve l'avantage d'être plus directement interprétable : elle fournit des odds ratios et permet de quantifier l'effet des modalités sur la probabilité d'annulation. Elle constitue donc un modèle de référence solide pour expliquer les facteurs de risque.

L'approche DISQUAL, fondée sur l'ACM puis la classification, capte davantage la structure globale des profils qualitatifs. Dans notre évaluation finale, le meilleur modèle global est ACM + KNN (15 axes, k=15), avec une AUC de 0.897 et un F1-score de 0.762. Ce résultat indique que la représentation factorielle suivie du classifieur retenu apporte un gain prédictif sur la détection des annulations.

Sur le plan opérationnel, le modèle peut servir à prioriser les réservations à risque : les observations prédites comme annulées peuvent faire l'objet d'une relance, d'une politique de garantie adaptée ou d'une surveillance plus fine. Cette utilisation doit toutefois rester prudente : l'objectif n'est pas de sanctionner un client, mais d'anticiper le risque de no-show ou d'annulation afin d'aider la gestion hôtelière.

6 Sources des données et références

6.1 Reproductibilité

L'ensemble du code source, des scripts d'analyse et des documents associés au projet est disponible sur le dépôt GitHub suivant :

- Dépôt GitHub du projet : https://github.com/hamzaassal/STA201_Projet.git

6.2 Données

- La base utilisée provient du jeu de données *Hotel Booking Demand Datasets*, diffusé sur Kaggle et documenté dans l'article scientifique publié dans *Data in Brief* : [Hotel Booking Demand Datasets](#).

6.3 Supports de cours

- Cours de STA201 - Régression logistique. Document de cours : *logistic regr FR.pdf*.
- Cours de STA201 - Analyse discriminante, classification supervisée et scoring.

6.4 Références méthodologiques

- Hosmer, D. W., Lemeshow, S. et Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.
<https://www.wiley-vch.de/en/areas-interest/mathematics-statistics/statistics-16st/regression-analysis-16st4/applied-logistic-regression-978-0-470-58247-3>
- Fawcett, T. (2006). *An Introduction to ROC Analysis*. Pattern Recognition Letters, 27(8), 861-874.
<https://doi.org/10.1016/j.patrec.2005.10.010>
- Brier, G. W. (1950). *Verification of Forecasts Expressed in Terms of Probability*. Monthly Weather Review, 78(1), 1-3.
https://journals.ametsoc.org/view/journals/mwre/78/1/1520-0493_1950_078_0001_vofeit_2_0_co_2.xml
- Ghojogh, B. et Crowley, M. (2019). *Linear and Quadratic Discriminant Analysis : Tutorial*. arXiv :1906.02590. <https://arxiv.org/abs/1906.02590>
- Stanford University. *Discriminant Analysis*, STATS305C. https://web.stanford.edu/class/stats305c/lectures/Discriminant_analysis.html
- James, G., Witten, D., Hastie, T. et Tibshirani, R. *An Introduction to Statistical Learning*. Voir le chapitre sur la classification. <https://www.statlearning.com/>
- Documentation R `DiscriMiner::disqual`. *Discriminant Analysis on Qualitative Variables*. <https://www.rdocumentation.org/packages/DiscriMiner/versions/0.1-29/topics/disqual>
- Cnam. *Cours - Méthodes factorielles*. <https://cedric.cnam.fr/vertigo/Cours/RCP208/coursMethodesFactorielles.html>
- Saporta, G. (2006). *Probabilités, analyse des données et statistique*. Technip.

7 Annexes

Les annexes suivent le même ordre que le corps du rapport : présentation et préparation des données, démarche générale, modèle logistique, puis analyse discriminante sur variables qualitatives. Cette organisation permet de conserver une numérotation des tableaux et figures cohérente avec le déroulé de l'analyse.

7.1 Annexe A - Base, préparation des données et statistiques descriptives

TABLE 9 – Description des principales variables de la base de données

Variable	Description	Type	Choix
adr	Prix moyen journalier de la réservation.	Quantitative	Retenue
adults	Nombre d'adultes associés à la réservation.	Quantitative	Retenue
arrival_date_month	Mois d'arrivée prévue du client.	Qualitative	Retenue
babies	Nombre de bébés associés à la réservation.	Quantitative	Retenue
booking_changes	Nombre de modifications effectuées sur la réservation.	Quantitative	Retenue
children	Nombre d'enfants associés à la réservation.	Quantitative	Retenue
country	Pays d'origine du client, code selon la nomenclature pays disponible dans la base.	Qualitative	Retenue
customer_type	Type de client : Transient, Contract, Group ou Transient-Party.	Qualitative	Retenue
deposit_type	Type de dépôt ou garantie associé à la réservation.	Qualitative	Retenue
hotel	Type d'hôtel concerné par la réservation : Resort Hotel ou City Hotel.	Qualitative	Retenue
is_canceled	Variable cible indiquant si la réservation a été annulée : 1 = annulée, 0 = non annulée.	Qualitative	Retenue
is_repeated_guest	Indique si le client est déjà venu auparavant : 1 = oui, 0 = non.	Qualitative	Retenue
lead_time	Nombre de jours entre la date de réservation et la date d'arrivée prévue.	Quantitative	Retenue
market_segment	Segment de marché ou canal commercial à l'origine de la réservation.	Qualitative	Retenue
previous_cancellations	Nombre d'annulations précédentes effectuées par le client.	Quantitative	Retenue
required_car_parking_spaces	Nombre de places de parking demandées par le client.	Quantitative	Retenue
stays_in_week_nights	Nombre de nuits en semaine réservées.	Quantitative	Retenue
stays_in_weekend_nights	Nombre de nuits de week-end réservées.	Quantitative	Retenue
total_of_special_requests	Nombre de demandes spéciales formulées par le client.	Quantitative	Retenue
agent	Identifiant de l'agence de voyage ayant effectué la réservation, si applicable.	Qualitative	Non retenue
arrival_date_day_of_month	Jour du mois correspondant à l'arrivée prévue.	Quantitative	Non retenue
arrival_date_week_number	Numéro de semaine de l'année correspondant à l'arrivée prévue.	Quantitative	Non retenue
arrival_date_year	Année d'arrivée prévue du client.	Quantitative	Non retenue
assigned_room_type	Type de chambre finalement attribué.	Qualitative	Non retenue
company	Identifiant de l'entreprise associée à la réservation, si applicable.	Qualitative	Non retenue
days_in_waiting_list	Nombre de jours passés sur liste d'attente avant confirmation.	Quantitative	Non retenue
distribution_channel	Canal de distribution utilisé pour effectuer la réservation.	Qualitative	Non retenue
meal	Type de repas réservé.	Qualitative	Non retenue
previous_bookings_not_canceled	Nombre de réservations précédentes non annulées par le client.	Quantitative	Non retenue
reservation_status	Statut final de la réservation : annulée, non annulée ou no-show.	Qualitative	Non retenue
reservation_status_date	Date du dernier statut de la réservation.	Date	Non retenue
reserved_room_type	Type de chambre initialement réservée.	Qualitative	Non retenue

TABLE 10 – Structure générale de la base de données

Indicateur	Valeur
Unité statistique	Une réservation hôtelière
Nombre d'observations initiales	119 390
Nombre de variables initiales	32
Nombre d'observations exclues au nettoyage	827
Part de la base conservée	99.3%
Nombre de variables après ingénierie	47
Nombre de réservations City Hotel	79 330
Nombre de réservations Resort Hotel	40 060
Variable cible	is_canceled
Réservations non annulées - base initiale	75 166
Réservations annulées - base initiale	44 224
Taux d'annulation - base initiale	37 %
Réservations non annulées - base nettoyée	74 388
Réservations annulées - base nettoyée	44 175
Taux d'annulation - base nettoyée	37.3%

TABLE 11 – Synthèse des contrôles et traitements de cohérence

Critère	Effectif	Pourcentage	Décision
ADR extrême supérieur à 1000	1	0.00%	Exclu
ADR négatif	1	0.00%	Exclu
Aucun client renseigné	180	0.15%	Exclu
Séjour de 0 nuit	645	0.54%	Exclu
Conserve	118563	99.31%	Conserve

TABLE 12 – Variables construites pour l'analyse

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
is_canceled	is_canceled	Recodage de 0/1 en Non/Oui	Variable cible à prédire
lead_time_cat	lead_time	0 = dernière_minute ; <= 7 = court ; <= 30 = moyen ; <= 90 = long ; > 90 = tres_long	Mesurer l'anticipation de la réservation
total_nights	stays_in_week_nights + stays_in_weekend_nights	Somme des nuits en semaine et de week-end	Mesurer la durée totale du séjour
total_nights_cat	total_nights	<= 2 = court_sejour ; <= 5 = moyen_sejour ; > 5 = long_sejour	Regrouper les durées de séjour
adr_cat	adr	Découpage de l'ADR en quartiles q1_low, q2_midlow, q3_midhigh, q4_high	Comparer les niveaux de prix
has_children	children + babies	Oui si au moins un enfant ou bébé, Non sinon	Identifier les réservations familiales
parking_reserved	required_car_parking_spaces	Oui si au moins une place de parking demandée, Non sinon	Mesurer un signe d'engagement du client
engagement	total_of_special_requests + booking_changes + 1 x parking_binary	Somme des demandes spéciales et des changements de réservation et de réservation de place de parking	Score enrichi d'engagement
engagement_cat	engagement	0 = faible ; <= 2 = moyen ; >= 3 = fort	Comparer les niveaux d'engagement
previous_cancellations_cat	previous_cancellations	0 = Non ; >= 1 = Une_ou_plus	Capturer l'historique d'annulation

(continued)

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
saison_tourisme	arrival_date_month	Juillet-août = pick_saison ; juin-septembre = haute_saison ; avril-mai-octobre = moyenne_saison ; autres mois = basse_saison	Tenir compte de la saison touristique
repeated_guest_cat	is_repeated_guest	1 = Oui ; 0 = Non	Identifier les clients déjà venus
continent	country	Conversion du code pays ISO en continent avec countrycode et regroupement des codes non reconnus	Intermédiaire de construction de l'origine géographique
identity_location	country + continent	Portugal = Local_Portugal ; Europe hors Portugal = Europe_hors_PRT ; autres origines = Other_International	Résumer l'origine géographique du client pour la modélisation




FIGURE 6 – Analyses bivariées : répartition de l'annulation et poids des modalités




FIGURE 7 – Matrice d'associations des variables explicatives

7.2 Annexe B - Objectif de l'étude et démarche choisie




FIGURE 8 – Démarche de modélisation

7.3 Annexe C - Modèle logistique

7.3.1 Comparaison des modèles logistiques sur validation

TABLE 13 – Performances prédictives des modèles logistiques sur validation

Modèle	Type	Accuracy	AUC	Recall	Spécificité	Précision	F1-score	Balanced accuracy
glm_full	glm_selection	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
glm_backward	glm_selection	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
glm_forward	glm_selection	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
glm_stepwise	glm_selection	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
elastic_net_075	penalized	0.8125	0.8767	0.7375	0.8570	0.7538	0.7456	0.7972
elastic_net_050	penalized	0.8117	0.8765	0.7431	0.8525	0.7495	0.7463	0.7978
elastic_net_025	penalized	0.8116	0.8765	0.7438	0.8519	0.7489	0.7464	0.7979
lasso	penalized	0.8106	0.8765	0.7427	0.8510	0.7475	0.7451	0.7968
ridge	penalized	0.8035	0.8712	0.7479	0.8365	0.7310	0.7393	0.7922

7.3.2 AIC et complexité

TABLE 14 – AIC et AIC approximatif des modèles logistiques

Modèle	Type	Alpha	Lambda lse	Log-vraisemblance train	Coefficients non nuls	AIC / AIC approx.
glm_full	glm_selection	-	-	-	27	49293.5624
glm_backward	glm_selection	-	-	-	27	49293.5624
glm_forward	glm_selection	-	-	-	27	49293.5624
glm_stepwise	glm_selection	-	-	-	27	49293.5624
elastic_net_025	penalized	0.25	0.0043	-24826.873	26	49705.746
elastic_net_075	penalized	0.75	0.0037	-24832.7574	25	49715.5147
elastic_net_050	penalized	0.5	0.0042	-24843.1655	25	49736.3311
lasso	penalized	1	0.0036	-24861.4512	24	49770.9023
ridge	penalized	0	0.0263	-25756.6859	27	51567.3718

7.3.3 Variables importantes du modèle complet

TABLE 15 – Variables ou modalités les plus importantes du modèle logistique complet

Modèle	Variable	Modalité	Odds ratio	p-value	Importance
glm_full	lead_time_cat	lead_time_cattres_long	30.2557	0.0000	3.4097
glm_full	lead_time_cat	lead_time_catlong	18.2092	0.0000	2.9019
glm_full	previous_cancellations_cat	previous_cancellations_catUne_ou_plus	16.1085	0.0000	2.7793
glm_full	lead_time_cat	lead_time_catmoyen	11.3063	0.0000	2.4254
glm_full	engagement_cat	engagement_catfort	0.0913	0.0000	2.3940
glm_full	identity_location	identity_locationLocal_Portugal	9.0518	0.0000	2.2030
glm_full	engagement_cat	engagement_catmoyen	0.1890	0.0000	1.6658
glm_full	market_segment	market_segmentOnline_TA	4.4971	0.0000	1.5034
glm_full	market_segment	market_segmentOther	3.2095	0.0000	1.1661
glm_full	customer_type	customer_typeTransient	3.1351	0.0000	1.1427
glm_full	lead_time_cat	lead_time_catcourt	2.2116	0.0000	0.7937
glm_full	identity_location	identity_locationOther_International	2.0196	0.0000	0.7029
glm_full	adr_cat	adr_catq4_high	1.9854	0.0000	0.6858
glm_full	adr_cat	adr_catq3_midhigh	1.6958	0.0000	0.5282
glm_full	customer_type	customer_typeTransient-Party	0.7086	0.0001	0.3445
glm_full	saison_tourisme	saison_tourismepick_saison	0.7108	0.0000	0.3413
glm_full	hotel	hotelResort Hotel	0.7115	0.0000	0.3403
glm_full	total_nights_cat	total_nights_catlong_sejour	1.3258	0.0000	0.2820
glm_full	adr_cat	adr_catq2_midlow	1.3118	0.0000	0.2714
glm_full	saison_tourisme	saison_tourismehaute_saison	0.8211	0.0000	0.1971
glm_full	market_segment	market_segmentCorporate	0.8216	0.0131	0.1965
glm_full	market_segment	market_segmentOffline_TA	1.1374	0.0153	0.1287
glm_full	total_nights_cat	total_nights_catmoyen_sejour	1.0998	0.0003	0.0951
glm_full	customer_type	customer_typeGroup	1.0879	0.7275	0.0842
glm_full	has_children	has_childrenOui	1.0825	0.0565	0.0793
glm_full	saison_tourisme	saison_tourismemoyenne_saison	0.9398	0.0488	0.0621

TABLE 16 – Importance agrégée des variables dans les modèles pénalisés

Modèle	Variable	Modalités retenues	Importance somme	Importance max	Importance relative
elastic_net_025	lead_time_cat	4	5.2943	2.1516	0.2639
elastic_net_025	engagement_cat	2	3.6702	2.1479	0.1830
elastic_net_025	identity_location	2	2.5889	1.9859	0.1291
elastic_net_025	market_segment	4	2.5516	1.2699	0.1272
elastic_net_025	previous_cancellations_cat	1	2.4492	2.4492	0.1221
elastic_net_050	lead_time_cat	4	5.3495	2.1940	0.2733
elastic_net_050	engagement_cat	2	3.6447	2.1283	0.1862
elastic_net_050	identity_location	2	2.5565	1.9726	0.1306
elastic_net_050	market_segment	3	2.4814	1.2648	0.1268
elastic_net_050	previous_cancellations_cat	1	2.3986	2.3986	0.1225
elastic_net_075	lead_time_cat	4	5.5668	2.3088	0.2853
elastic_net_075	engagement_cat	2	3.6537	2.1312	0.1873
elastic_net_075	identity_location	2	2.5547	1.9782	0.1309
elastic_net_075	market_segment	3	2.4516	1.2753	0.1257
elastic_net_075	previous_cancellations_cat	1	2.3801	2.3801	0.1220
lasso	lead_time_cat	4	5.6268	2.3534	0.2950
lasso	engagement_cat	2	3.6239	2.1090	0.1900
lasso	identity_location	2	2.5207	1.9631	0.1321
lasso	market_segment	3	2.3931	1.2696	0.1255
lasso	previous_cancellations_cat	1	2.3310	2.3310	0.1222
ridge	lead_time_cat	4	2.9667	1.1132	0.1956
ridge	engagement_cat	2	2.8481	1.6374	0.1878
ridge	market_segment	4	2.1157	0.8348	0.1395
ridge	identity_location	2	1.9695	1.5472	0.1299
ridge	previous_cancellations_cat	1	1.9386	1.9386	0.1278

7.4 Annexe D - Analyse discriminante sur variables qualitatives

7.4.1 Inertie des axes factoriels




FIGURE 9 – Décroissance de l'inertie de l'ensemble des axes ACM

7.4.2 Représentation et interprétation des axes




FIGURE 10 – Plan factoriel 3-4 avec modalités labellisées

7.4.2.1 Axe 3 : nature du séjour et saisonnalité

L'axe 3 oppose des profils `market_segment = Corporate`, `identity_location = Other_International` et `saison_tourisme = basse_saison` à des profils `customer_type = Contract`, `total_nights_cat = long_sejour` et `hotel = Resort Hotel`.

Interprétation métier : cet axe distingue une logique plus professionnelle/internationale ou basse saison d'une logique plus touristique, resort et long séjour. Il structure donc les motivations probables du séjour. Cette distinction est importante car une réservation business, un séjour resort et un long séjour ne portent pas les mêmes contraintes d'annulation.

7.4.2.2 Axe 4 : volatilité opérationnelle autour du séjour

L'axe 4 oppose `customer_type = Group`, `total_nights_cat = long_sejour` et `customer_type = Contract` à `previous_cancellations_cat = Une_ou_plus`, `has_children = Oui` et `lead_time_cat = derniere_minute`. Les contributions de `adr_cat = q4_high`, `saison_tourisme = basse_saison`, `saison_tourisme = pick_saison`, `total_nights_cat = court_sejour` et `hotel = Resort Hotel` montrent que cet axe combine prix, saison et structure du séjour.

Interprétation métier : cet axe capte une forme de volatilité opérationnelle. Les réservations courtes, chères, saisonnières ou associées à un historique d'annulation peuvent être plus difficiles à stabiliser.

La position de `is_canceled_Oui` sur cet axe confirme que cette dimension contient une information pertinente pour la prédiction.

Plan factoriel 1-5

Modalités actives labellisées par variable d'origine et cible projetée




FIGURE 11 – Plan factoriel 1-5 avec modalités labellisées

7.4.2.3 Axe 5 : canal, prix et saison

L'axe 5 oppose market_segment = Other, engagement_cat = fort et has_children = Oui à customer_type = Group, customer_type = Contract et lead_time_cat = dernière_minute. Les contributions de market_segment = Other, market_segment = Offline_TA, adr_cat = q3_midhigh, saison_tourisme = haute_saison et lead_time_cat = dernière_minute indiquent que cet axe combine canal, niveau de prix et saison.

Interprétation métier : cet axe affine la lecture du risque en distinguant des profils commerciaux et saisonniers. Il ne représente pas un seul facteur simple, mais une combinaison de contexte de réservation, de prix et de période touristique.

Modalités structurantes des axes ACM




FIGURE 12 – Modalités les plus contributives aux premiers axes

Les contributions indiquent quelles modalités construisent vraiment chaque axe. Une modalité peut être éloignée du centre sans être la plus structurante ; inversement, une modalité fortement contributive doit être intégrée à l'interprétation de l'axe.

7.4.3 Tests statistiques sur les axes de l'ACM

TABLE 17 – Tests de Shapiro-Wilk sur les axes ACM candidats

Axe	Statistique	p-value	Conclusion
Dim 1	0.9791	0.0000	Normalité rejetée
Dim 2	0.9435	0.0000	Normalité rejetée
Dim 3	0.9627	0.0000	Normalité rejetée
Dim 4	0.9970	0.0007	Normalité rejetée
Dim 5	0.9965	0.0001	Normalité rejetée
Dim 6	0.9624	0.0000	Normalité rejetée
Dim 7	0.9980	0.0163	Normalité rejetée
Dim 8	0.9926	0.0000	Normalité rejetée
Dim 9	0.9065	0.0000	Normalité rejetée
Dim 10	0.9962	0.0001	Normalité rejetée
Dim 11	0.7692	0.0000	Normalité rejetée
Dim 12	0.9616	0.0000	Normalité rejetée
Dim 13	0.9788	0.0000	Normalité rejetée
Dim 14	0.9955	0.0000	Normalité rejetée
Dim 15	0.9876	0.0000	Normalité rejetée
Dim 16	0.9970	0.0007	Normalité rejetée
Dim 17	0.9930	0.0000	Normalité rejetée
Dim 18	0.9874	0.0000	Normalité rejetée
Dim 19	0.9427	0.0000	Normalité rejetée
Dim 20	0.9928	0.0000	Normalité rejetée
Dim 21	0.9989	0.2509	Normalité non rejetée
Dim 22	0.9964	0.0001	Normalité rejetée
Dim 23	0.9975	0.0026	Normalité rejetée
Dim 24	0.9960	0.0000	Normalité rejetée
Dim 25	0.9987	0.1302	Normalité non rejetée
Dim 26	0.9964	0.0001	Normalité rejetée

TABLE 18 – Tests de normalité multivariée sur les axes ACM candidats

Test	Statistic	p.value	Method	MVN	conclusion
Mardia Skewness	151806.120	<0.001	asymptotic	Non normale	Normalité multivariée rejetée
Mardia Kurtosis	187.651	<0.001	asymptotic	Non normale	Normalité multivariée rejetée
Henze-Zirkler	2.485	<0.001	asymptotic	Non normale	Normalité multivariée rejetée

TABLE 19 – Test de Box M pour l'homogénéité des matrices de covariance

Test	Statistique	Degrés de liberté	p-value	Conclusion
Box M	149357	351	0	Homogénéité des covariances rejetée

7.4.4 Choix du nombre d'axes et du classifieur

TABLE 20 – AUC de validation selon le nombre d'axes ACM et le modèle

Nombre d'axes	LDA	QDA	KNN k = 5	KNN k = 15	KNN k = 26
1	0.6089	0.6089	0.8496	0.8468	0.8267
2	0.6777	0.7011	0.8558	0.859	0.844
3	0.6787	0.6988	0.8558	0.855	0.8404
4	0.7184	0.7562	0.8577	0.8676	0.8596
5	0.7353	0.7606	0.8646	0.8731	0.8649
7	0.7714	0.7998	0.8656	0.8815	0.8783
10	0.7993	0.8196	0.8699	0.8838	0.8818
15	0.8394	0.8368	0.8707	0.8862	0.8842
20	0.8621	0.8461	0.8716	0.8865	0.8843
26	0.8753	0.8582	0.8751	0.8924	0.8915




FIGURE 13 – AUC de validation selon le nombre d'axes ACM et le modèle




FIGURE 14 – F1-score de validation selon le nombre d'axes ACM et le modèle