

Projet STA201 - Analyse multivariée approfondie

ASSAL

TRAORE

2026-01-01

Table of contents

1	Présentation de la problématique et de la base de données	1
1.1	Présentation des variables importantes à l'étude	2
1.2	Description des données et statistiques descriptives	2
2	Préparation des données	2
3	Analyse statistiques univariés	3
3.1	Analyse statistique bivariés	4

1 Présentation de la problématique et de la base de données

Notre étude s'appuie sur la base de données *Hotel Booking Demand Datasets*, construite afin d'analyser le comportement d'annulation des réservations dans le secteur hôtelier. Cette base a notamment été diffusée sur Kaggle et documentée dans un article scientifique publié dans la revue *Data in Brief* : [Hotel Booking Demand Datasets](#).

La base regroupe les informations de réservation de deux établissements hôteliers situés au Portugal : un hôtel de type *Resort Hotel* et un hôtel de type *City Hotel*. Les deux sous-bases présentent une structure identique composée de 31 variables. Elles contiennent respectivement 40 060 réservations pour le *Resort Hotel* et 79 330 réservations pour le *City Hotel*.

Chaque observation correspond à une réservation hôtelière, qu'elle ait donné lieu à un séjour effectif ou à une annulation. La variable d'intérêt de notre étude est donc la variable indicatrice d'annulation, notée `is_canceled`, qui prend la valeur 1 lorsque la réservation a été annulée et 0 sinon.

L'objectif de cette étude est d'identifier les profils de clients présentant un risque élevé d'annulation. Une meilleure compréhension de ces profils permettrait au management hôtelier de mettre en place des actions ciblées, telles que des re-

lances, une adaptation des conditions de réservation ou une stratégie de surbooking maîtrisée.

La base de données ne contient pas de valeurs manquantes. Toutefois, certaines variables catégorielles, peuvent prendre la valeur « NULL ». Cette valeur ne correspond pas à une donnée absente, mais indique simplement que l'information n'est pas applicable. Par exemple, une valeur « NULL » pour la variable Agent signifie que la réservation n'a pas été effectuée via une agence de voyage et que l'observation n'est pas concernée.

1.1 Présentation des variables importantes à l'étude

Nom.de.la.variable	Description	Typ
hotel	Type d'hôtel : Resort Hotel ou City Hotel	Qua
is_canceled	Indicateur d'annulation de la réservation : 1 = annulée, 0 = non annulée	Qua
lead_time	Nombre de jours entre la réservation et la date d'arrivée	Qua
arrival_date_year	Année d'arrivée prévue	Qua
arrival_date_month	Mois d'arrivée prévue	Qua
stays_in_weekend_nights	Nombre de nuits de week-end réservées	Qua
stays_in_week_nights	Nombre de nuits en semaine réservées	Qua
adults	Nombre d'adultes	Qua
children	Nombre d'enfants	Qua
babies	Nombre de bébés	Qua
meal	Type de repas réservé	Qua
country	Pays d'origine du client	Qua
market_segment	Canal ou segment de marché de la réservation	Qua
deposit_type	Type de dépôt associé à la réservation	Qua
customer_type	Type de client	Qua
adr	Prix moyen journalier de la réservation	Qua
total_of_special_requests	Nombre de demandes spéciales formulées par le client	Qua

Le Tableau ?@tbl-dico présente les principales variables retenues pour l'analyse.

1.2 Description des données et statistiques descriptives

2 Préparation des données

Avant d'entamer la phase d'analyse des premières statistiques descriptives une revue rigoureuse de cohérence des données s'impose. Nous avons ainsi revérifier l'absence de données manquantes et la cohérence métier d'absence de variable. Dans une deuxième étape nous avons aussi vérifier l'existence de valeurs

abérantes pouvant affecter les résultats de notre modélisation *mettre ici des exemples et des détails de gestions de données abérantes même si sur notre base il y en avait pas beaucoup on parle de notre data engenering à cette etape?*

3 Analyse statistiques univariés

Notre variable d'intérêt étant "is_canceled" sa distribution se présente ainsi:




Figure 1: Répartition des annulations de réservations

L'histogramme Figure 1 présente la répartition des réservations annulées et non annulées.

ajouter les stats univariés d'autres variables

ou alors c'est juste ici après avoir présenté les variable global, évoqué le sujet du trop de modalités et expliquer notre demarche de data engenering et directement par la suite dans les stats bivariés parler des nouvelles variables créer comme ça on evite de les perdre dans trop de details et des analyses qui ne seront pas utilisés par la suite

37% des reservations sont annulées, ce qui reste un niveau élevé d'ou l'importance de ce type d'étude et qui nous donne une base relativement équilibré entre les deux modalités.

3.1 Analyse statistique bivariés

Dans la revue de littérature sur des comportements similaires (annulation dans le secteur aéronautique ou autre), quelques variables expliquant ce comportement ont retenu notre attention, notamment parce qu'elles sont présentes dans notre base de données. Il s'agit du lead time, des demandes spéciales, des clients ayant déjà annulé, ainsi que des longs séjours.

Voici un panorama de leurs statistiques bivariées avec notre variable d'intérêt.




Figure 2: Fonction de densité du délai entre la date reservation et l'arrivée

La comparaison des fonctions de densités [Figure 2](#)