



Conservatoire National des Arts et Métiers

Projet STA201 : Analyse multivariée approfondie

Etude de cas : Annulations de reservations hotelières

Auteurs : ASSAL HAMZA
TRAORE SAH
Date : 17-05-2026

Table des matières

1	Présentation des bases théoriques des deux méthodes	2
1.1	Régression logistique	2
1.2	Analyse discriminante sur variables qualitatives	3
2	Introduction, problématique et base de données	5
2.1	Présentation des variables importantes à l'étude	5
3	Description des données, prétraitements et statistiques descriptives	6
3.1	Nettoyage et cohérence des données	6
3.2	Préparation des données	7
3.3	Analyse statistique univariée	7
3.4	Analyse statistique bivariée	7
4	Objectif de l'étude et démarche choisie	9
5	Résultats de la première méthode : régression logistique	10
6	Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives	11
7	Comparaison des résultats et conclusion	12
8	Sources des données et références	13
9	Annexes	14
9.1	Tableaux complémentaires	14

1 Présentation des bases théoriques des deux méthodes

1.1 Régression logistique

La régression logistique est une méthode de classification supervisée utilisée lorsque la variable à expliquer est qualitative, le plus souvent binaire. Elle permet d'estimer la probabilité qu'un individu appartienne à une modalité d'intérêt à partir d'un ensemble de variables explicatives quantitatives ou qualitatives. Lorsque les variables explicatives sont qualitatives, elles sont généralement transformées en variables indicatrices afin d'être intégrées au modèle.

Contrairement à une régression linéaire classique, la régression logistique ne modélise pas directement la variable binaire. Elle modélise le logarithme du rapport des chances, appelé logit. Si l'on note p_i la probabilité que l'individu i appartienne à la classe étudiée, le modèle s'écrit :

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$$

où $x_{i1}, \dots, x_{ip}$ représentent les variables explicatives, et $\beta_0, \dots, \beta_p$ les paramètres du modèle. La transformation logit permet de relier une probabilité comprise entre 0 et 1 à une combinaison linéaire de variables explicatives.

Une fois le modèle estimé, la probabilité prédite s'obtient par la fonction logistique :

$$p_i = \frac{1}{1 + \exp[-(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})]}$$

La décision de classer un individu dans la classe étudiée dépend ensuite d'un seuil de classification. Le seuil de 0,5 est souvent utilisé par défaut, mais il peut être modifié selon l'objectif de l'étude. Lorsque l'on cherche prioritairement à détecter une classe particulière, il est fréquent d'ajuster ce seuil afin d'améliorer la sensibilité, c'est-à-dire la capacité du modèle à repérer correctement les individus appartenant réellement à cette classe.

L'interprétation des coefficients se fait généralement à l'aide des odds ratios. Pour une variable explicative donnée, l'odds ratio correspond à l'exponentielle du coefficient estimé :

$$OR_j = \exp(\beta_j)$$

Un odds ratio supérieur à 1 indique que la variable augmente les chances d'appartenir à la classe étudiée, toutes choses égales par ailleurs. À l'inverse, un odds ratio inférieur à 1 indique une diminution de ces chances. Cette propriété rend la régression logistique intéressante à la fois pour la prédiction et pour l'interprétation des facteurs associés à une modalité donnée.

L'évaluation du modèle repose sur plusieurs indicateurs issus de la matrice de confusion. L'accuracy mesure la proportion globale de bonnes classifications, mais elle peut être insuffisante lorsque les classes sont déséquilibrées ou lorsque l'on s'intéresse davantage à une classe particulière. La sensibilité, ou recall, mesure la proportion d'individus de la classe d'intérêt correctement détectés. La spécificité mesure la proportion d'individus de l'autre classe correctement reconnus. La précision indique, parmi les individus prédits dans la classe d'intérêt, la proportion qui appartient réellement

à cette classe. Le F1-score combine précision et sensibilité, tandis que l'AUC mesure la capacité globale du modèle à séparer les classes indépendamment d'un seuil particulier.

La régression logistique présente plusieurs avantages : elle est relativement simple à mettre en œuvre, interprétable, adaptée à une variable cible binaire et compatible avec des variables explicatives de nature variée. Ses limites tiennent notamment à l'hypothèse d'une relation linéaire entre les variables explicatives et le logit de la probabilité, à la sensibilité aux valeurs extrêmes, à la multicolinéarité et aux situations de séparation quasi parfaite.

1.2 Analyse discriminante sur variables qualitatives

L'analyse discriminante sur variables qualitatives est une approche de classification supervisée adaptée aux situations où les variables explicatives sont principalement qualitatives. Dans une perspective prédictive, elle vise à apprendre une règle permettant d'affecter un nouvel individu à l'un des groupes connus à partir de son profil de modalités. Dans la littérature, cette démarche est souvent désignée par le terme DISQUAL, notamment dans les travaux de Gilbert Saporta.

L'idée générale est de transformer l'information qualitative en une représentation numérique exploitable par une analyse discriminante. Pour cela, les variables qualitatives sont généralement codées sous forme d'un tableau disjonctif complet. Chaque modalité devient une indicatrice prenant la valeur 1 si l'individu possède la modalité, et 0 sinon. Cette transformation permet de représenter chaque individu par le profil des modalités qu'il possède.

À partir de cette représentation, une difficulté apparaît : le tableau disjonctif peut contenir beaucoup de colonnes, parfois corrélées entre elles, surtout lorsque les variables qualitatives ont de nombreuses modalités. Pour rendre la modélisation plus stable, on peut d'abord appliquer une analyse des correspondances multiples (ACM). L'ACM résume l'information qualitative dans un nombre réduit d'axes factoriels continus. Ces axes deviennent alors de nouvelles variables synthétiques qui conservent une partie importante de l'information initiale tout en réduisant la dimension du problème.

La partie discriminante peut ensuite être réalisée à partir de ces axes d'ACM. Deux méthodes classiques peuvent être utilisées : l'analyse discriminante linéaire (LDA) et l'analyse discriminante quadratique (QDA). La LDA suppose que les groupes ont des matrices de variance-covariance identiques ; elle construit donc des frontières de décision linéaires. La QDA relâche cette hypothèse et autorise une matrice de variance-covariance différente pour chaque groupe ; elle peut ainsi construire des frontières de décision plus souples, mais elle demande davantage de données pour être estimée de manière stable.

Dans cette logique, l'analyse discriminante sur variables qualitatives peut être vue comme une chaîne prédictive en deux temps. L'ACM transforme et résume les variables qualitatives, puis la LDA ou la QDA apprend une règle de classification à partir des axes factoriels retenus. La qualité du modèle dépend alors du nombre d'axes conservés, de la séparation réelle entre les groupes et de la stabilité des matrices de covariance estimées.

L'évaluation de la méthode se fait comme pour toute méthode de prédiction supervisée. On applique le modèle à un échantillon de test ou de validation, puis on compare les groupes prédits aux groupes observés. La matrice de confusion permet de calculer l'accuracy, la sensibilité, la spécificité, la précision et le F1-score. Ces indicateurs mesurent la capacité de la méthode à classer correctement les individus et à repérer les groupes d'intérêt.

Cette approche est particulièrement utile lorsque l'analyse porte sur des profils construits à partir de modalités qualitatives. L'étape d'ACM permet aussi de garder une lecture descriptive des modalités qui structurent les axes factoriels, même si l'objectif final est prédictif. Ses limites tiennent notamment à la qualité du codage, au choix du nombre d'axes retenus, à la présence de modalités rares et au risque d'instabilité lorsque certains groupes sont peu représentés. Un regroupement raisonné des modalités peut donc être nécessaire avant l'analyse.

2 Introduction, problématique et base de données

Notre étude s'appuie sur la base de données *Hotel Booking Demand Datasets*, construite afin d'analyser le comportement d'annulation des réservations dans le secteur hôtelier. Cette base a notamment été diffusée sur Kaggle et documentée dans un article scientifique publié dans la revue *Data in Brief*. Les informations détaillées sur l'origine des données sont précisées dans la section Section 8.

La base regroupe les informations de réservation de deux établissements hôteliers situés au Portugal : un hôtel de type *Resort Hotel* et un hôtel de type *City Hotel*. Les deux sous-bases présentent une structure identique composée de 31 variables. Elles contiennent respectivement 40 060 réservations pour le *Resort Hotel* et 79 330 réservations pour le *City Hotel*.

Chaque observation correspond à une réservation hôtelière, qu'elle ait donné lieu à un séjour effectif ou à une annulation. La variable d'intérêt de notre étude est donc la variable indicatrice d'annulation, notée `is_canceled`, qui prend la valeur 1 lorsque la réservation a été annulée et 0 sinon.

L'objectif de cette étude est d'identifier les profils de clients présentant un risque élevé d'annulation. Une meilleure compréhension de ces profils permettrait au management hôtelier de mettre en place des actions ciblées, telles que des relances, une adaptation des conditions de réservation ou une stratégie de surbooking maîtrisée.

La base de données ne contient pas de valeurs manquantes. Toutefois, certaines variables catégorielles, peuvent prendre la valeur « NULL ». Cette valeur ne correspond pas à une donnée absente, mais indique simplement que l'information n'est pas applicable. Par exemple, une valeur « NULL » pour la variable `Agent` signifie que la réservation n'a pas été effectuée via une agence de voyage et que l'observation n'est pas concernée.

2.1 Présentation des variables importantes à l'étude

Les principales variables utilisées dans l'étude sont décrites en Annexe, dans le Tableau Table 1. Elles couvrent la nature de l'hôtel, la variable cible `is_canceled`, les caractéristiques temporelles de la réservation, la composition du séjour, le canal de réservation, le prix moyen journalier et les demandes particulières du client.

3 Description des données, prétraitements et statistiques descriptives

La structure générale de la base est résumée en Annexe dans le Tableau Table 2. Les variables construites pour l'analyse sont détaillées dans le Tableau Table 3. Les variables retenues pour la modélisation logistique sont présentées dans le Tableau Table 4. Ces tableaux sont placés en annexe afin de conserver un corps de rapport plus lisible, conformément à la consigne de ne pas intégrer de listing brut dans le texte principal.

3.1 Nettoyage et cohérence des données

Avant l'analyse statistique et la modélisation, plusieurs contrôles ont été réalisés afin de sécuriser l'utilisation de la base. L'objectif était de conserver l'information disponible tout en traitant les situations susceptibles de produire des incohérences dans les variables construites ou dans les modèles.

La base contient très peu de valeurs manquantes au sens strict de R. Les seules valeurs manquantes identifiées concernent la variable `children`, avec 4 observations. Pour construire la variable `has_children`, ces valeurs ont été assimilées à 0 enfant. Ce choix permet d'éviter la création de valeurs manquantes dans une variable synthétique utilisée ensuite dans les analyses.

Certaines variables de la base utilisent également la modalité "NULL". Dans ce projet, cette modalité n'est pas systématiquement considérée comme une valeur manquante : elle peut traduire une information non applicable. Par exemple, une valeur "NULL" pour une agence ou une entreprise peut simplement indiquer que la réservation n'a pas été effectuée par ce canal.

Un contrôle de cohérence a aussi été effectué sur la variable `country`, utilisée pour construire les variables géographiques. Les codes pays non reconnus automatiquement par le package `countrycode` ont été traités explicitement. Les codes `CN`, `ATF` et `UMI` ont été associés à leur continent, tandis que la modalité "NULL" a été classée dans la catégorie `Unknown`.

Les observations présentant des incohérences fortes ont ensuite été exclues de la base d'analyse. Il s'agit des réservations sans aucun client renseigné, des séjours de 0 nuit, des valeurs négatives de prix moyen journalier (`adr`) et d'une valeur extrêmement élevée de `adr`. Les doublons exacts ont été repérés mais n'ont pas été supprimés automatiquement, car la base ne contient pas d'identifiant unique de réservation permettant de distinguer avec certitude un doublon technique d'une réservation distincte mais identique sur les variables disponibles.

Enfin, les variables qualitatives utiles à l'analyse ont été converties en facteurs afin de faciliter les statistiques descriptives, l'analyse discriminante sur variables qualitatives et la modélisation logistique.

La synthèse chiffrée de ces contrôles et décisions est présentée en Annexe dans le Tableau Table 5.

À l'issue de ces traitements, la base d'analyse contient 118563 observations. Les variables construites dans la suite du rapport sont donc calculées à partir de cette base d'analyse.


3.2 Préparation des données

La préparation des données consiste ensuite à transformer certaines variables initiales en indicateurs plus directement exploitables pour l'analyse. Plusieurs variables synthétiques ont été construites afin de rendre les résultats plus lisibles, de limiter le nombre de modalités et de disposer de profils interprétables.

Ces variables portent notamment sur le délai de réservation, la durée du séjour, le niveau de prix, la présence d'enfants, l'engagement du client, l'historique d'annulation, la saison touristique et l'origine géographique du client. La variable cible `is_canceled` a également été recodée sous forme factorielle avec les modalités `Non` et `Oui`, ce qui permet une lecture homogène des sorties descriptives et prédictives.

3.3 Analyse statistique univariée

Notre variable d'intérêt étant "`is_canceled`" sa distribution se présente ainsi :



L'histogramme Figure 1 présente la répartition des réservations annulées et non annulées.

37% des reservations sont annulées, ce qui reste un niveau élevé d'ou l'importance de ce type d'étude et qui nous donne une base relativement équilibré entre les deux modalités.

3.4 Analyse statistique bivariée

Dans la revue de littérature sur des comportements similaires (annulation dans le secteur aéronautique ou autre), quelques variables expliquant ce comportement ont retenu notre attention, notamment parce qu'elles sont présentes dans notre base de données. Il s'agit du lead time, des demandes spéciales, des clients ayant déjà annulé, ainsi que des longs séjours.

Voici un panorama de leurs statistiques bivariées avec notre variable d'intérêt.

La comparaison des fonctions de densités Figure 2




FIGURE 1 – Répartition des annulations de réservations




FIGURE 2 – Fonction de densité du délai entre la date reservation et l'arrivée

4 Objectif de l'étude et démarche choisie

L'objectif opérationnel du projet est de mieux identifier les réservations susceptibles d'être annulées. La démarche retenue consiste d'abord à construire des variables qualitatives interprétables, puis à mobiliser deux méthodes : la régression logistique, pour estimer une probabilité d'annulation et interpréter l'effet des facteurs explicatifs, et l'analyse discriminante sur variables qualitatives, pour étudier la discrimination entre les profils de réservations annulées et non annulées.

5 Résultats de la première méthode : régression logistique

Cette partie présentera la construction du modèle logistique, la sélection éventuelle des variables, l'interprétation des coefficients ou odds ratios, puis l'évaluation prédictive du modèle. Comme l'objectif principal est de mieux détecter les annulations, les indicateurs privilégiés seront notamment le recall, la précision, le F1-score et l'AUC, en complément de l'accuracy.

6 Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives

Cette partie présentera l'application de l'analyse discriminante sur variables qualitatives aux variables retenues. L'analyse devra mettre en évidence les modalités qui contribuent le plus à la séparation entre les réservations annulées et non annulées, ainsi que la qualité de discrimination obtenue.

7 Comparaison des résultats et conclusion

La comparaison finale confrontera les résultats obtenus avec la régression logistique et avec l'analyse discriminante sur variables qualitatives. Elle devra préciser si les deux méthodes identifient des profils similaires de réservations à risque, discuter leurs avantages respectifs et formuler une conclusion opérationnelle pour le management hôtelier.

8 Sources des données et références

La base utilisée provient du jeu de données *Hotel Booking Demand Datasets*, diffusé sur Kaggle et documenté dans l'article scientifique publié dans *Data in Brief* : [Hotel Booking Demand Datasets](#). Les références méthodologiques relatives à la régression logistique et à l'analyse discriminante sur variables qualitatives seront complétées dans cette section.

9 Annexes

9.1 Tableaux complémentaires

TABLE 1 – Description des principales variables de la base de données

Variable	Description	Type	Choix
adr	Prix moyen journalier de la reservation.	Quantitative	Retenue
adults	Nombre d'adultes associes a la reservation.	Quantitative	Retenue
arrival_date_month	Mois d'arrivee prevue du client.	Qualitative	Retenue
babies	Nombre de bebes associes a la reservation.	Quantitative	Retenue
booking_changes	Nombre de modifications effectuees sur la reservation.	Quantitative	Retenue
children	Nombre d'enfants associes a la reservation.	Quantitative	Retenue
country	Pays d'origine du client, code selon la nomenclature pays disponible dans la base.	Qualitative	Retenue
customer_type	Type de client : Transient, Contract, Group ou Transient-Party.	Qualitative	Retenue
hotel	Type d'hotel concerne par la reservation : Resort Hotel ou City Hotel.	Qualitative	Retenue
is_canceled	Variable cible indiquant si la reservation a ete annulee : 1 = annulee, 0 = non annulee.	Qualitative	Retenue
lead_time	Nombre de jours entre la date de reservation et la date d'arrivee prevue.	Quantitative	Retenue
market_segment	Segment de marche ou canal commercial a l'origine de la reservation.	Qualitative	Retenue
previous_cancellations	Nombre d'annulations precedentes effectuees par le client.	Quantitative	Retenue
required_car_parking_spaces	Nombre de places de parking demandees par le client.	Quantitative	Retenue
stays_in_week_nights	Nombre de nuits en semaine reservees.	Quantitative	Retenue
stays_in_weekend_nights	Nombre de nuits de week-end reservees.	Quantitative	Retenue
total_of_special_requests	Nombre de demandes speciales formulees par le client.	Quantitative	Retenue
agent	Identifiant de l'agence de voyage ayant effectue la reservation, si applicable.	Qualitative	Non retenue
arrival_date_day_of_month	Jour du mois correspondant a l'arrivee prevue.	Quantitative	Non retenue
arrival_date_week_number	Numero de semaine de l'annee correspondant a l'arrivee prevue.	Quantitative	Non retenue
arrival_date_year	Annee d'arrivee prevue du client.	Quantitative	Non retenue
assigned_room_type	Type de chambre finalement attribue.	Qualitative	Non retenue
company	Identifiant de l'entreprise associee a la reservation, si applicable.	Qualitative	Non retenue
days_in_waiting_list	Nombre de jours passes sur liste d'attente avant confirmation.	Quantitative	Non retenue
deposit_type	Type de depot ou garantie associe a la reservation.	Qualitative	Non retenue
distribution_channel	Canal de distribution utilise pour effectuer la reservation.	Qualitative	Non retenue
is_repeated_guest	Indique si le client est deja venu auparavant : 1 = oui, 0 = non.	Qualitative	Non retenue
meal	Type de repas reserve.	Qualitative	Non retenue
previous_bookings_not_canceled	Nombre de reservations precedentes non annulees par le client.	Quantitative	Non retenue
reservation_status	Statut final de la reservation : annulee, non annulee ou no-show.	Qualitative	Non retenue
reservation_status_date	Date du dernier statut de la reservation.	Date	Non retenue
reserved_room_type	Type de chambre initialement reserve.	Qualitative	Non retenue

TABLE 3 – Variables construites pour l'analyse

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
is_canceled	is_canceled	Recodage de 0/1 en Non/Oui	Variable cible a predire
lead_time_cat	lead_time	0 = dernière_minute ; <= 7 = court ; <= 30 = moyen ; <= 90 = long ; > 90 = tres_long	Mesurer l'anticipation de la reservation
total_nights	stays_in_week_nights + stays_in_weekend_nights	Somme des nuits en semaine et de week-end	Mesurer la duree totale du sejour
total_nights_cat	total_nights	<= 2 = court_sejour ; <= 5 = moyen_sejour ; > 5 = long_sejour	Regrouper les durees de sejour
adr_cat	adr	Decoupage de l'ADR en quartiles q1_low, q2_midlow, q3_midhigh, q4_high	Comparer les niveaux de prix
has_children	children + babies	Oui si au moins un enfant ou bebe, Non sinon	Identifier les reservations familiales
parking_reserved	required_car_parking_spaces	Oui si au moins une place de parking demandee, Non sinon	Mesurer un signe d'engagement du client
engagement_raw	total_of_special_requests + booking_changes	Somme des demandes speciales et des changements de reservation	Construire un score simple d'engagement
engagement	engagement_raw + parking_binary	Ajout d'un point si une place de parking est reservee	Score enrichi d'engagement
engagement_cat	engagement	0 = faible ; <= 2 = moyen ; >= 3 = fort	Comparer les niveaux d'engagement
previous_cancellations_cat	previous_cancellations	0 = Non ; >= 1 = Une_ou_plus	Capturer l'historique d'annulation

(continued)

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
saison_tourisme	arrival_date_month	Juillet-aout = pick_saison ; juin-septembre = haute_saison ; avril-mai-octobre = moyenne_saison ; autres mois = basse_saison	Tenir compte de la saison touristique
repeated_guest_cat	is_repeated_guest	1 = Oui ; 0 = Non	Identifier les clients déjà venus
continent	country	Conversion du code pays ISO en continent avec countrycode et regroupement des codes non reconnus	Intermediaire de construction de l'origine géographique
identity_location	country + continent	Portugal = Local_Portugal ; Europe hors Portugal = Europe_hors_PRT ; autres origines = Other_International	Resumer l'origine géographique du client pour la modelisation

TABLE 2 – Structure générale de la base de données

Indicateur	Valeur
Unite statistique	Une reservation hoteliere
Nombre d'observations initiales	119 390
Nombre de variables initiales	32
Nombre d'observations exclues au nettoyage	827
Nombre d'observations conservees apres nettoyage	118 563
Part de la base conservee	99.3%
Nombre de variables apres engineering	48
Nombre de reservations City Hotel	79 330
Nombre de reservations Resort Hotel	40 060
Variable cible	is_canceled
Reservations non annulees - base initiale	75 166
Reservations annulees - base initiale	44 224
Taux d'annulation - base initiale	37 %
Reservations non annulees - base nettoye	74 388
Reservations annulees - base nettoye	44 175
Taux d'annulation - base nettoye	37.3%
Valeurs manquantes au sens R	4
Variables avec valeurs manquantes	children (4)

TABLE 4 – Variables retenues pour la modélisation logistique

Variable	Rôle dans l'analyse
is_canceled	Variable cible a predire
hotel	Distinguer City Hotel et Resort Hotel
market_segment	Caracteriser le canal commercial de reservation
customer_type	Distinguer les profils de clients selon le type de reservation
lead_time_cat	Mesurer l'anticipation de la reservation
total_nights_cat	Regrouper les durees de sejour
adr_cat	Comparer les niveaux de prix
has_children	Identifier les reservations familiales
engagement_cat	Comparer les niveaux d'engagement
previous_cancellations_cat	Capturer l'historique d'annulation
saison_tourisme	Tenir compte de la saison touristique
identity_location	Resumer l'origine geographique du client pour la modelisation

TABLE 5 – Synthèse des contrôles et traitements de cohérence

Critère	Effectif	Pourcentage	Décision
ADR extreme superieur a 1000	1	0.00%	Exclu
ADR negatif	1	0.00%	Exclu
Aucun client renseigne	180	0.15%	Exclu
Sejour de 0 nuit	645	0.54%	Exclu
Conserve	118563	99.31%	Conserve