



Conservatoire National des Arts et Métiers

# **Projet STA201 : Analyse multivariée approfondie**

Etude de cas : Annulations de reservations hotelières

Auteurs : ASSAL HAMZA  
TRAORE SAH  
Date : 17-05-2026

# Table des matières

|          |                                                                                            |           |
|----------|--------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Présentation des bases théoriques des deux méthodes</b>                                 | <b>2</b>  |
| 1.1      | Régression logistique . . . . .                                                            | 2         |
| 1.2      | Analyse discriminante sur variables qualitatives . . . . .                                 | 3         |
| <b>2</b> | <b>Introduction, problématique et base de données</b>                                      | <b>5</b>  |
| 2.1      | Présentation des variables importantes à l'étude . . . . .                                 | 5         |
| <b>3</b> | <b>Description des données, prétraitements et statistiques descriptives</b>                | <b>6</b>  |
| 3.1      | Nettoyage et cohérence des données . . . . .                                               | 6         |
| 3.2      | Préparation des données . . . . .                                                          | 7         |
| 3.3      | Analyse statistique univariée . . . . .                                                    | 7         |
| 3.4      | Analyse statistique bivariée . . . . .                                                     | 7         |
| <b>4</b> | <b>Objectif de l'étude et démarche choisie</b>                                             | <b>9</b>  |
| <b>5</b> | <b>Résultats de la première méthode : régression logistique</b>                            | <b>10</b> |
| 5.1      | Stratégie de modélisation . . . . .                                                        | 10        |
| 5.2      | Comparaison des modèles sur validation . . . . .                                           | 10        |
| 5.3      | AIC et complexité des modèles . . . . .                                                    | 11        |
| 5.4      | Choix du seuil de classification . . . . .                                                 | 11        |
| 5.5      | Variables importantes . . . . .                                                            | 12        |
| <b>6</b> | <b>Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives</b> | <b>15</b> |
| 6.1      | Stratégie méthodologique . . . . .                                                         | 15        |
| 6.2      | Tests statistiques sur les axes de l'ACM . . . . .                                         | 15        |
| 6.3      | Choix du nombre d'axes et du classifieur . . . . .                                         | 16        |
| 6.4      | Choix du seuil de classification . . . . .                                                 | 18        |
| <b>7</b> | <b>Comparaison des résultats et conclusion</b>                                             | <b>19</b> |
| <b>8</b> | <b>Sources des données et références</b>                                                   | <b>20</b> |
| <b>9</b> | <b>Annexes</b>                                                                             | <b>21</b> |
| 9.1      | Tableaux complémentaires . . . . .                                                         | 21        |

# 1 Présentation des bases théoriques des deux méthodes

## 1.1 Régression logistique

La régression logistique est une méthode de classification supervisée utilisée lorsque la variable à expliquer est qualitative, le plus souvent binaire. Elle permet d'estimer la probabilité qu'un individu appartienne à une modalité d'intérêt à partir d'un ensemble de variables explicatives quantitatives ou qualitatives. Lorsque les variables explicatives sont qualitatives, elles sont généralement transformées en variables indicatrices afin d'être intégrées au modèle.

Contrairement à une régression linéaire classique, la régression logistique ne modélise pas directement la variable binaire. Elle modélise le logarithme du rapport des chances, appelé logit. Si l'on note  $p_i$  la probabilité que l'individu  $i$  appartienne à la classe étudiée, le modèle s'écrit :

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$$

où  $x_{i1}, \dots, x_{ip}$  représentent les variables explicatives, et  $\beta_0, \dots, \beta_p$  les paramètres du modèle. La transformation logit permet de relier une probabilité comprise entre 0 et 1 à une combinaison linéaire de variables explicatives.

Une fois le modèle estimé, la probabilité prédite s'obtient par la fonction logistique :

$$p_i = \frac{1}{1 + \exp[-(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})]}$$

La décision de classer un individu dans la classe étudiée dépend ensuite d'un seuil de classification. Le seuil de 0,5 est souvent utilisé par défaut, mais il peut être modifié selon l'objectif de l'étude. Lorsque l'on cherche prioritairement à détecter une classe particulière, il est fréquent d'ajuster ce seuil afin d'améliorer la sensibilité, c'est-à-dire la capacité du modèle à repérer correctement les individus appartenant réellement à cette classe.

L'interprétation des coefficients se fait généralement à l'aide des odds ratios. Pour une variable explicative donnée, l'odds ratio correspond à l'exponentielle du coefficient estimé :

$$OR_j = \exp(\beta_j)$$

Un odds ratio supérieur à 1 indique que la variable augmente les chances d'appartenir à la classe étudiée, toutes choses égales par ailleurs. À l'inverse, un odds ratio inférieur à 1 indique une diminution de ces chances. Cette propriété rend la régression logistique intéressante à la fois pour la prédiction et pour l'interprétation des facteurs associés à une modalité donnée.

L'évaluation du modèle repose sur plusieurs indicateurs issus de la matrice de confusion. L'accuracy mesure la proportion globale de bonnes classifications, mais elle peut être insuffisante lorsque les classes sont déséquilibrées ou lorsque l'on s'intéresse davantage à une classe particulière. La sensibilité, ou recall, mesure la proportion d'individus de la classe d'intérêt correctement détectés. La spécificité mesure la proportion d'individus de l'autre classe correctement reconnus. La précision indique, parmi les individus prédits dans la classe d'intérêt, la proportion qui appartient réellement

à cette classe. Le F1-score combine précision et sensibilité, tandis que l'AUC mesure la capacité globale du modèle à séparer les classes indépendamment d'un seuil particulier.

La régression logistique présente plusieurs avantages : elle est relativement simple à mettre en œuvre, interprétable, adaptée à une variable cible binaire et compatible avec des variables explicatives de nature variée. Ses limites tiennent notamment à l'hypothèse d'une relation linéaire entre les variables explicatives et le logit de la probabilité, à la sensibilité aux valeurs extrêmes, à la multicolinéarité et aux situations de séparation quasi parfaite.

## 1.2 Analyse discriminante sur variables qualitatives

L'analyse discriminante sur variables qualitatives est une approche de classification supervisée adaptée aux situations où les variables explicatives sont principalement qualitatives. Dans une perspective prédictive, elle vise à apprendre une règle permettant d'affecter un nouvel individu à l'un des groupes connus à partir de son profil de modalités. Dans la littérature, cette démarche est souvent désignée par le terme DISQUAL, notamment dans les travaux de Gilbert Saporta.

L'idée générale est de transformer l'information qualitative en une représentation numérique exploitable par une analyse discriminante. Pour cela, les variables qualitatives sont généralement codées sous forme d'un tableau disjonctif complet. Chaque modalité devient une indicatrice prenant la valeur 1 si l'individu possède la modalité, et 0 sinon. Cette transformation permet de représenter chaque individu par le profil des modalités qu'il possède.

À partir de cette représentation, une difficulté apparaît : le tableau disjonctif peut contenir beaucoup de colonnes, parfois corrélées entre elles, surtout lorsque les variables qualitatives ont de nombreuses modalités. Pour rendre la modélisation plus stable, on peut d'abord appliquer une analyse des correspondances multiples (ACM). L'ACM résume l'information qualitative dans un nombre réduit d'axes factoriels continus. Ces axes deviennent alors de nouvelles variables synthétiques qui conservent une partie importante de l'information initiale tout en réduisant la dimension du problème.

La partie discriminante peut ensuite être réalisée à partir de ces axes d'ACM. Deux méthodes classiques peuvent être utilisées : l'analyse discriminante linéaire (LDA) et l'analyse discriminante quadratique (QDA). La LDA suppose que les groupes ont des matrices de variance-covariance identiques ; elle construit donc des frontières de décision linéaires. La QDA relâche cette hypothèse et autorise une matrice de variance-covariance différente pour chaque groupe ; elle peut ainsi construire des frontières de décision plus souples, mais elle demande davantage de données pour être estimée de manière stable.

Dans cette logique, l'analyse discriminante sur variables qualitatives peut être vue comme une chaîne prédictive en deux temps. L'ACM transforme et résume les variables qualitatives, puis la LDA ou la QDA apprend une règle de classification à partir des axes factoriels retenus. La qualité du modèle dépend alors du nombre d'axes conservés, de la séparation réelle entre les groupes et de la stabilité des matrices de covariance estimées.

L'évaluation de la méthode se fait comme pour toute méthode de prédiction supervisée. On applique le modèle à un échantillon de test ou de validation, puis on compare les groupes prédits aux groupes observés. La matrice de confusion permet de calculer l'accuracy, la sensibilité, la spécificité, la précision et le F1-score. Ces indicateurs mesurent la capacité de la méthode à classer correctement les individus et à repérer les groupes d'intérêt.

Cette approche est particulièrement utile lorsque l'analyse porte sur des profils construits à partir de modalités qualitatives. L'étape d'ACM permet aussi de garder une lecture descriptive des modalités qui structurent les axes factoriels, même si l'objectif final est prédictif. Ses limites tiennent notamment à la qualité du codage, au choix du nombre d'axes retenus, à la présence de modalités rares et au risque d'instabilité lorsque certains groupes sont peu représentés. Un regroupement raisonné des modalités peut donc être nécessaire avant l'analyse.

## 2 Introduction, problématique et base de données

Notre étude s'appuie sur la base de données *Hotel Booking Demand Datasets*, construite afin d'analyser le comportement d'annulation des réservations dans le secteur hôtelier. Cette base a notamment été diffusée sur Kaggle et documentée dans un article scientifique publié dans la revue *Data in Brief*. Les informations détaillées sur l'origine des données sont précisées dans la section Section 8.

La base regroupe les informations de réservation de deux établissements hôteliers situés au Portugal : un hôtel de type *Resort Hotel* et un hôtel de type *City Hotel*. Les deux sous-bases présentent une structure identique composée de 31 variables. Elles contiennent respectivement 40 060 réservations pour le *Resort Hotel* et 79 330 réservations pour le *City Hotel*.

Chaque observation correspond à une réservation hôtelière, qu'elle ait donné lieu à un séjour effectif ou à une annulation. La variable d'intérêt de notre étude est donc la variable indicatrice d'annulation, notée `is_canceled`, qui prend la valeur 1 lorsque la réservation a été annulée et 0 sinon.

L'objectif de cette étude est d'identifier les profils de clients présentant un risque élevé d'annulation. Une meilleure compréhension de ces profils permettrait au management hôtelier de mettre en place des actions ciblées, telles que des relances, une adaptation des conditions de réservation ou une stratégie de surbooking maîtrisée.

La base de données ne contient pas de valeurs manquantes. Toutefois, certaines variables catégorielles, peuvent prendre la valeur « NULL ». Cette valeur ne correspond pas à une donnée absente, mais indique simplement que l'information n'est pas applicable. Par exemple, une valeur « NULL » pour la variable `Agent` signifie que la réservation n'a pas été effectuée via une agence de voyage et que l'observation n'est pas concernée.

### 2.1 Présentation des variables importantes à l'étude

Les principales variables utilisées dans l'étude sont décrites en Annexe, dans le Tableau Table 15. Elles couvrent la nature de l'hôtel, la variable cible `is_canceled`, les caractéristiques temporelles de la réservation, la composition du séjour, le canal de réservation, le prix moyen journalier et les demandes particulières du client.

### 3 Description des données, prétraitements et statistiques descriptives

La structure générale de la base est résumée en Annexe dans le Tableau Table 16. Les variables construites pour l'analyse sont détaillées dans le Tableau Table 17. Les variables retenues pour la modélisation logistique sont présentées dans le Tableau Table 18. Ces tableaux sont placés en annexe afin de conserver un corps de rapport plus lisible, conformément à la consigne de ne pas intégrer de listing brut dans le texte principal.

#### 3.1 Nettoyage et cohérence des données

Avant l'analyse statistique et la modélisation, plusieurs contrôles ont été réalisés afin de sécuriser l'utilisation de la base. L'objectif était de conserver l'information disponible tout en traitant les situations susceptibles de produire des incohérences dans les variables construites ou dans les modèles.

La base contient très peu de valeurs manquantes au sens strict de R. Les seules valeurs manquantes identifiées concernent la variable `children`, avec 4 observations. Pour construire la variable `has_children`, ces valeurs ont été assimilées à 0 enfant. Ce choix permet d'éviter la création de valeurs manquantes dans une variable synthétique utilisée ensuite dans les analyses.

Certaines variables de la base utilisent également la modalité "NULL". Dans ce projet, cette modalité n'est pas systématiquement considérée comme une valeur manquante : elle peut traduire une information non applicable. Par exemple, une valeur "NULL" pour une agence ou une entreprise peut simplement indiquer que la réservation n'a pas été effectuée par ce canal.

Un contrôle de cohérence a aussi été effectué sur la variable `country`, utilisée pour construire les variables géographiques. Les codes pays non reconnus automatiquement par le package `countrycode` ont été traités explicitement. Les codes CN, ATF et UMI ont été associés à leur continent, tandis que la modalité "NULL" a été classée dans la catégorie `Unknown`.

Les observations présentant des incohérences fortes ont ensuite été exclues de la base d'analyse. Il s'agit des réservations sans aucun client renseigné, des séjours de 0 nuit, des valeurs négatives de prix moyen journalier (`adr`) et d'une valeur extrêmement élevée de `adr`. Les doublons exacts ont été repérés mais n'ont pas été supprimés automatiquement, car la base ne contient pas d'identifiant unique de réservation permettant de distinguer avec certitude un doublon technique d'une réservation distincte mais identique sur les variables disponibles.

Enfin, les variables qualitatives utiles à l'analyse ont été converties en facteurs afin de faciliter les statistiques descriptives, l'analyse discriminante sur variables qualitatives et la modélisation logistique.

La synthèse chiffrée de ces contrôles et décisions est présentée en Annexe dans le Tableau Table 19.

À l'issue de ces traitements, la base d'analyse contient 118563 observations. Les variables construites dans la suite du rapport sont donc calculées à partir de cette base d'analyse.

### 3.2 Préparation des données


La préparation des données consiste ensuite à transformer certaines variables initiales en indicateurs plus directement exploitables pour l'analyse. Plusieurs variables synthétiques ont été construites afin de rendre les résultats plus lisibles, de limiter le nombre de modalités et de disposer de profils interprétables.

Ces variables portent notamment sur le délai de réservation, la durée du séjour, le niveau de prix, la présence d'enfants, l'engagement du client, l'historique d'annulation, la saison touristique et l'origine géographique du client. La variable cible `is_canceled` a également été recodée sous forme factorielle avec les modalités `Non` et `Oui`, ce qui permet une lecture homogène des sorties descriptives et prédictives.

### 3.3 Analyse statistique univariée

Notre variable d'intérêt étant "`is_canceled`" sa distribution se présente ainsi :

#### Matrice des associations (V de Cramér)



L'histogramme Figure 1 présente la répartition des réservations annulées et non annulées.

37% des réservations sont annulées, ce qui reste un niveau élevé d'où l'importance de ce type d'étude et qui nous donne une base relativement équilibrée entre les deux modalités.

### 3.4 Analyse statistique bivariée

Dans la revue de littérature sur des comportements similaires (annulation dans le secteur aéronautique ou autre), quelques variables expliquant ce comportement ont retenu notre attention, notamment parce qu'elles sont présentes dans notre base de données. Il s'agit du lead time, des demandes spéciales, des clients ayant déjà annulé, ainsi que des longs séjours.

Voici un panorama de leurs statistiques bivariées avec notre variable d'intérêt.

La comparaison des fonctions de densités Figure 2






FIGURE 1 – Répartition des annulations de réservations




FIGURE 2 – Fonction de densité du délai entre la date reservation et l'arrivée

## 4 Objectif de l'étude et démarche choisie

L'objectif opérationnel du projet est de mieux identifier les réservations susceptibles d'être annulées. La démarche retenue consiste d'abord à construire des variables qualitatives interprétables, puis à mobiliser deux méthodes : la régression logistique, pour estimer une probabilité d'annulation et interpréter l'effet des facteurs explicatifs, et l'analyse discriminante sur variables qualitatives, pour étudier la discrimination entre les profils de réservations annulées et non annulées.

TABLE 1 – Synthèse de la stratégie retenue pour la régression logistique

| Modele retenu | Type      | Seuil | Base de selection | Base finale        | Role du test                                     |
|---------------|-----------|-------|-------------------|--------------------|--------------------------------------------------|
| lasso         | penalized | 0.42  | validation        | train + validation | evaluation finale dans scripts/07- Comparaison.R |

TABLE 2 – Performances des modèles logistiques sur validation

| Modele          | Type          | Seuil | Accuracy | AUC    | Recall | Specificite | Precision | F1-score | Balanced accuracy |
|-----------------|---------------|-------|----------|--------|--------|-------------|-----------|----------|-------------------|
| glm_full        | glm_selection | 0.43  | 0.8132   | 0.8783 | 0.7418 | 0.8556      | 0.7531    | 0.7474   | 0.7987            |
| glm_backward    | glm_selection | 0.43  | 0.8132   | 0.8783 | 0.7418 | 0.8556      | 0.7531    | 0.7474   | 0.7987            |
| glm_forward     | glm_selection | 0.43  | 0.8132   | 0.8783 | 0.7418 | 0.8556      | 0.7531    | 0.7474   | 0.7987            |
| glm_stepwise    | glm_selection | 0.43  | 0.8132   | 0.8783 | 0.7418 | 0.8556      | 0.7531    | 0.7474   | 0.7987            |
| elastic_net_075 | penalized     | 0.43  | 0.8125   | 0.8767 | 0.7375 | 0.8570      | 0.7538    | 0.7456   | 0.7972            |
| elastic_net_050 | penalized     | 0.42  | 0.8117   | 0.8765 | 0.7431 | 0.8525      | 0.7495    | 0.7463   | 0.7978            |
| elastic_net_025 | penalized     | 0.42  | 0.8116   | 0.8765 | 0.7438 | 0.8519      | 0.7489    | 0.7464   | 0.7979            |
| lasso           | penalized     | 0.42  | 0.8106   | 0.8765 | 0.7427 | 0.8510      | 0.7475    | 0.7451   | 0.7968            |
| ridge           | penalized     | 0.40  | 0.8035   | 0.8712 | 0.7479 | 0.8365      | 0.7310    | 0.7393   | 0.7922            |

## 5 Résultats de la première méthode : régression logistique

Cette partie présente la construction des modèles de régression logistique. L'objectif est double : comparer plusieurs stratégies de sélection de variables et évaluer l'apport des régularisations ridge, lasso et elastic net. Comme pour l'analyse discriminante, le test final n'est pas utilisé dans cette section. Les modèles sont estimés sur train, comparés sur validation, puis le meilleur modèle est réestimé sur train + validation avant l'évaluation finale dans la partie comparaison.

### 5.1 Stratégie de modélisation

La régression logistique modélise directement la probabilité d'annulation d'une réservation. Les variables explicatives retenues dans la base de modélisation sont celles préparées dans `scripts/04-data preparation.R`, ce qui garantit que les modèles logistiques utilisent exactement les mêmes observations que l'analyse discriminante.

Deux familles de modèles ont été comparées. La première famille regroupe les régressions logistiques classiques avec différentes méthodes de sélection : modèle complet, sélection backward, sélection forward et sélection stepwise. Ces modèles sont comparés notamment par leur AIC et par leurs performances sur validation.

La deuxième famille regroupe les régressions logistiques pénalisées : ridge, lasso et elastic net. Ces méthodes sont utiles lorsque les variables indicatrices issues des variables qualitatives sont nombreuses ou corrélées. Ridge réduit les coefficients sans les annuler, lasso peut sélectionner automatiquement certaines modalités en mettant des coefficients à zéro, et elastic net combine ces deux comportements.

### 5.2 Comparaison des modèles sur validation

Le choix du modèle repose d'abord sur la performance prédictive observée sur validation. L'AUC mesure la capacité générale du modèle à séparer les réservations annulées des réservations non annulées, indépendamment du seuil. Le F1-score complète cette lecture car il tient compte à la fois du rappel et de la précision pour la modalité d'intérêt, ici l'annulation.




FIGURE 3 – AUC et F1-score des modèles logistiques sur validation

TABLE 3 – AIC et AIC approximatif des modèles logistiques

| Modele          | Type          | Alpha | Lambda 1se | Log-vraisemblance train | Coefficients non nuls | AIC / AIC approx. |
|-----------------|---------------|-------|------------|-------------------------|-----------------------|-------------------|
| glm_full        | glm_selection | NA    | NA         | NA                      | 27                    | 49293.56          |
| glm_backward    | glm_selection | NA    | NA         | NA                      | 27                    | 49293.56          |
| glm_forward     | glm_selection | NA    | NA         | NA                      | 27                    | 49293.56          |
| glm_stepwise    | glm_selection | NA    | NA         | NA                      | 27                    | 49293.56          |
| elastic_net_025 | penalized     | 0.25  | 0.0043     | -24826.87               | 26                    | 49705.75          |
| elastic_net_075 | penalized     | 0.75  | 0.0037     | -24832.76               | 25                    | 49715.51          |
| elastic_net_050 | penalized     | 0.50  | 0.0042     | -24843.17               | 25                    | 49736.33          |
| lasso           | penalized     | 1.00  | 0.0036     | -24861.45               | 24                    | 49770.90          |
| ridge           | penalized     | 0.00  | 0.0263     | -25756.69               | 27                    | 51567.37          |

Les résultats montrent que les modèles logistiques classiques et pénalisés sont proches. Dans notre exécution, le modèle retenu automatiquement est lasso, avec un seuil de 0.42. Ce choix est effectué sur validation et non sur test.

### 5.3 AIC et complexité des modèles

L'AIC permet de comparer les modèles logistiques classiques en arbitrant entre qualité d'ajustement et complexité. Pour les modèles pénalisés, nous calculons un AIC approximatif fondé sur la log-vraisemblance et le nombre de coefficients non nuls. Il ne doit pas être interprété comme un AIC strictement équivalent à celui d'un `glm`, mais il donne un repère utile pour comparer ridge, lasso et elastic net entre eux.

### 5.4 Choix du seuil de classification

Une régression logistique produit une probabilité d'annulation. Pour transformer cette probabilité en classe prédite, il faut choisir un seuil. Le seuil par défaut de 0,50 n'est pas nécessairement le

TABLE 4 – Seuil retenu pour le modele logistique

| Seuil | Accuracy | Recall | Specificite | Precision | F1-score | Balanced accuracy |
|-------|----------|--------|-------------|-----------|----------|-------------------|
| 0.42  | 0.8106   | 0.7427 | 0.851       | 0.7475    | 0.7451   | 0.7968            |

plus adapte, car l'objectif metier consiste surtout a bien detecter les annulations sans degrader excessivement la precision.

Le seuil est donc optimise sur validation apres le choix du modele. Le critere principal est le F1-score, qui equilibre precision et rappel.




FIGURE 4 – Evolution des metriques selon le seuil du modele logistique retenu

## 5.5 Variables importantes

L'interpretation depend du type de modele retenu. Pour une regression logistique classique, les odds ratios permettent de lire le sens et l'intensite de l'association entre une modalite et la probabilite d'annulation. Un odds ratio superieur a 1 indique une augmentation des chances d'annulation, tandis qu'un odds ratio inferieur a 1 indique une diminution, toutes choses egales par ailleurs.

Pour les modeles penalises, l'importance est calculee a partir de la valeur absolue des coefficients standardises par le coefficient maximal du modele. Le lasso et l'elastic net peuvent aussi indiquer quelles modalites sont effectivement conservees, car certains coefficients peuvent etre mis a zero.

Pour completer l'analyse des regularisations, le tableau suivant presente l'importance agreee des variables dans les modeles penalises. Cette lecture est utile car une meme variable qualitative peut generer plusieurs indicatrices.

En synthese, la regression logistique fournit une reference predictive solide et interpretable. Elle permet de quantifier les facteurs associes aux annulations, tout en comparant des versions classiques

TABLE 5 – Variables ou modalités les plus importantes du modèle logistique retenu

| Modèle | Variable                   | Modalité                              | Odds ratio | p-value | Importance |
|--------|----------------------------|---------------------------------------|------------|---------|------------|
| lasso  | lead_time_cat              | lead_time_cattres_long                | 10.5208    | NA      | 1.0000     |
| lasso  | previous_cancellations_cat | previous_cancellations_catUne ou plus | 10.2882    | NA      | 0.9905     |
| lasso  | engagement_cat             | engagement_catfort                    | 0.1214     | NA      | 0.8962     |
| lasso  | identity_location          | identity_locationLocal_Portugal       | 7.1215     | NA      | 0.8342     |
| lasso  | lead_time_cat              | lead_time_catlong                     | 6.4542     | NA      | 0.7924     |
| lasso  | engagement_cat             | engagement_catmoyen                   | 0.2198     | NA      | 0.6437     |
| lasso  | lead_time_cat              | lead_time_catmoyen                    | 4.0012     | NA      | 0.5892     |
| lasso  | market_segment             | market_segmentOnline_TA               | 3.5594     | NA      | 0.5395     |
| lasso  | customer_type              | customer_typeTransient                | 2.8382     | NA      | 0.4433     |
| lasso  | market_segment             | market_segmentOther                   | 2.3598     | NA      | 0.3648     |
| lasso  | identity_location          | identity_locationOther_International  | 1.7465     | NA      | 0.2369     |
| lasso  | hotel                      | hotelResort Hotel                     | 0.6995     | NA      | 0.1519     |
| lasso  | adr_cat                    | adr_catq4_high                        | 1.3881     | NA      | 0.1393     |
| lasso  | market_segment             | market_segmentCorporate               | 0.7672     | NA      | 0.1126     |
| lasso  | customer_type              | customer_typeTransient-Party          | 0.7802     | NA      | 0.1055     |




FIGURE 5 – Principales variables ou modalités du modèle logistique retenu

TABLE 6 – Importance agregée des variables dans les modèles pénalisés

| Modèle          | Variable                   | Modalités retenues | Importance somme | Importance max | Importance relative |
|-----------------|----------------------------|--------------------|------------------|----------------|---------------------|
| elastic_net_025 | lead_time_cat              | 4                  | 5.2943           | 2.1516         | 0.2639              |
| elastic_net_025 | engagement_cat             | 2                  | 3.6702           | 2.1479         | 0.1830              |
| elastic_net_025 | identity_location          | 2                  | 2.5889           | 1.9859         | 0.1291              |
| elastic_net_025 | market_segment             | 4                  | 2.5516           | 1.2699         | 0.1272              |
| elastic_net_025 | previous_cancellations_cat | 1                  | 2.4492           | 2.4492         | 0.1221              |
| elastic_net_050 | lead_time_cat              | 4                  | 5.3495           | 2.1940         | 0.2733              |
| elastic_net_050 | engagement_cat             | 2                  | 3.6447           | 2.1283         | 0.1862              |
| elastic_net_050 | identity_location          | 2                  | 2.5565           | 1.9726         | 0.1306              |
| elastic_net_050 | market_segment             | 3                  | 2.4814           | 1.2648         | 0.1268              |
| elastic_net_050 | previous_cancellations_cat | 1                  | 2.3986           | 2.3986         | 0.1225              |
| elastic_net_075 | lead_time_cat              | 4                  | 5.5668           | 2.3088         | 0.2853              |
| elastic_net_075 | engagement_cat             | 2                  | 3.6537           | 2.1312         | 0.1873              |
| elastic_net_075 | identity_location          | 2                  | 2.5547           | 1.9782         | 0.1309              |
| elastic_net_075 | market_segment             | 3                  | 2.4516           | 1.2753         | 0.1257              |
| elastic_net_075 | previous_cancellations_cat | 1                  | 2.3801           | 2.3801         | 0.1220              |
| lasso           | lead_time_cat              | 4                  | 5.6268           | 2.3534         | 0.2950              |
| lasso           | engagement_cat             | 2                  | 3.6239           | 2.1090         | 0.1900              |
| lasso           | identity_location          | 2                  | 2.5207           | 1.9631         | 0.1321              |
| lasso           | market_segment             | 3                  | 2.3931           | 1.2696         | 0.1255              |
| lasso           | previous_cancellations_cat | 1                  | 2.3310           | 2.3310         | 0.1222              |
| ridge           | lead_time_cat              | 4                  | 2.9667           | 1.1132         | 0.1956              |
| ridge           | engagement_cat             | 2                  | 2.8481           | 1.6374         | 0.1878              |
| ridge           | market_segment             | 4                  | 2.1157           | 0.8348         | 0.1395              |
| ridge           | identity_location          | 2                  | 1.9695           | 1.5472         | 0.1299              |
| ridge           | previous_cancellations_cat | 1                  | 1.9386           | 1.9386         | 0.1278              |

et pénalisées. L'évaluation finale de ce meilleur modèle logistique sur la base test est présentée dans la section de comparaison finale, afin de conserver une séparation nette entre sélection de modèle et mesure de performance finale.

TABLE 7 – Synthèse de la stratégie retenue pour l’analyse discriminante

| Modèle retenu | Axes retenus | k KNN | Seuil | Axes disponibles | Max axes testés | Max k testé | Base de sélection | Base active finale | Rôle du test            |
|---------------|--------------|-------|-------|------------------|-----------------|-------------|-------------------|--------------------|-------------------------|
| ACM + KNN     | 20           | 15    | 0.34  | 26               | 20              | 26          | validation        | train + validation | individu supplémentaire |

## 6 Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives

Cette partie présente l’application de la méthode DISQUAL à notre problème de prédiction des annulations. L’idée générale consiste à transformer les variables qualitatives en axes factoriels continus à l’aide d’une ACM, puis à utiliser ces axes comme variables explicatives dans des modèles de classification. Nous comparons ici trois classifieurs construits sur les axes ACM : la LDA, la QDA et le KNN.

### 6.1 Stratégie méthodologique

L’analyse discriminante a été construite dans une logique strictement prédictive. La base a d’abord été séparée en trois échantillons : train, validation et test. La base train sert à apprendre la représentation factorielle et les modèles ; la base validation sert à choisir le nombre d’axes, le type de modèle et le seuil de classification ; la base test reste réservée à l’évaluation finale.

Une attention particulière a été portée au risque de fuite d’information. Pour la phase de sélection, l’ACM est estimée uniquement sur la base train. Les individus de validation et de test sont ensuite projetés comme individus supplémentaires. Ainsi, la structure factorielle utilisée pour sélectionner le modèle ne dépend pas des observations de validation ni de test.

La sélection du modèle se fait en deux temps. Premièrement, on compare plusieurs nombres d’axes ACM et plusieurs modèles à partir de l’AUC sur validation. L’AUC est utilisée à cette étape car elle évalue la capacité de séparation du modèle indépendamment d’un seuil de classification particulier. Deuxièmement, une fois le meilleur couple modèle / nombre d’axes retenu, le seuil de classification est optimisé sur validation, principalement à partir du F1-score afin de mieux équilibrer précision et rappel sur la classe des réservations annulées.

Après cette sélection, le modèle final est réestimé en utilisant train + validation comme échantillon actif pour l’ACM finale. La base test est alors projetée en individu supplémentaire, puis utilisée une seule fois pour mesurer la performance finale. Cette stratégie permet d’utiliser davantage de données pour le modèle final tout en conservant une évaluation honnête sur test.

### 6.2 Tests statistiques sur les axes de l’ACM

Avant de lancer la grid search, nous vérifions les hypothèses statistiques associées aux axes factoriels issus de l’ACM. Ces tests sont réalisés sur les axes candidats construits à partir de la base d’entraînement, avant le choix final du nombre d’axes. Cette position est importante : les diagnostics portent sur la représentation factorielle disponible, puis la sélection prédictive décide ensuite combien d’axes conserver.

La LDA suppose une normalité multivariée des variables explicatives dans les groupes et une homogénéité des matrices de covariance entre les classes. La QDA relâche l’hypothèse d’homogénéité



TABLE 8 – Tests de Shapiro-Wilk sur les axes ACM candidats

| Axe    | Statistique | p-value | Conclusion        |
|--------|-------------|---------|-------------------|
| Dim 1  | 0.9791      | 0.0000  | Normalite rejetee |
| Dim 2  | 0.9435      | 0.0000  | Normalite rejetee |
| Dim 3  | 0.9627      | 0.0000  | Normalite rejetee |
| Dim 4  | 0.9970      | 0.0007  | Normalite rejetee |
| Dim 5  | 0.9965      | 0.0001  | Normalite rejetee |
| Dim 6  | 0.9624      | 0.0000  | Normalite rejetee |
| Dim 7  | 0.9980      | 0.0163  | Normalite rejetee |
| Dim 8  | 0.9926      | 0.0000  | Normalite rejetee |
| Dim 9  | 0.9065      | 0.0000  | Normalite rejetee |
| Dim 10 | 0.9962      | 0.0001  | Normalite rejetee |
| Dim 11 | 0.7692      | 0.0000  | Normalite rejetee |
| Dim 12 | 0.9616      | 0.0000  | Normalite rejetee |
| Dim 13 | 0.9788      | 0.0000  | Normalite rejetee |
| Dim 14 | 0.9955      | 0.0000  | Normalite rejetee |
| Dim 15 | 0.9876      | 0.0000  | Normalite rejetee |
| Dim 16 | 0.9970      | 0.0007  | Normalite rejetee |
| Dim 17 | 0.9930      | 0.0000  | Normalite rejetee |
| Dim 18 | 0.9874      | 0.0000  | Normalite rejetee |
| Dim 19 | 0.9427      | 0.0000  | Normalite rejetee |
| Dim 20 | 0.9928      | 0.0000  | Normalite rejetee |

TABLE 9 – Tests de normalite multivariee sur les axes ACM candidats

| Test            | Statistic  | p-value | Method     | MVN         | conclusion                    |
|-----------------|------------|---------|------------|-------------|-------------------------------|
| Mardia Skewness | 130509.689 | <0.001  | asymptotic | Non normale | Normalite multivariee rejetee |
| Mardia Kurtosis | 225.799    | <0.001  | asymptotic | Non normale | Normalite multivariee rejetee |
| Henze-Zirkler   | 3.233      | <0.001  | asymptotic | Non normale | Normalite multivariee rejetee |

des covariances, mais reste plus stable lorsque les axes utilises ne s'éloignent pas trop fortement d'une structure gaussienne. Ces tests ne decident donc pas seuls du modele final : ils servent a evaluer la pertinence statistique des hypotheses, en complement des performances observees sur validation et test.

Lorsque les tests de normalite sont rejetes, l'utilisation de la LDA et de la QDA doit etre interpretee avec prudence : ces methodes restent utilisables comme classifieurs, mais leur justification probabiliste stricte est affaiblie. Lorsque le test de Box M rejette l'homogeneite des matrices de covariance, la QDA devient theoriquement plus flexible que la LDA, mais elle peut aussi etre plus instable si le nombre d'axes est trop eleve. C'est pourquoi le choix final du modele repose sur une validation empirique du nombre d'axes, du type de classifieur et du seuil de classification.

### 6.3 Choix du nombre d'axes et du classifieur

Le nombre d'axes ACM ne doit pas être choisi uniquement à partir de l'inertie factorielle. Dans notre cadre, l'objectif est prédictif : nous cherchons le nombre d'axes qui améliore réellement la capacité à distinguer les réservations annulées des réservations non annulées. Pour cette raison,

TABLE 10 – Test de Box M pour l'homogeneite des matrices de covariance

| Test  | Statistique | Degres de liberte | p-value | Conclusion                          |
|-------|-------------|-------------------|---------|-------------------------------------|
| Box M | 92993.66    | 210               | 0       | Homogeneite des covariances rejetee |

TABLE 11 – Meilleure performance de validation par famille de modèle

| Modèle    | Axes | k  | AUC    | Accuracy | Recall | Spécificité | Précision | F1-score | Balanced accuracy |
|-----------|------|----|--------|----------|--------|-------------|-----------|----------|-------------------|
| ACM + KNN | 20   | 15 | 0.8865 | 0.8169   | 0.6711 | 0.9034      | 0.8050    | 0.7320   | 0.7873            |
| ACM + KNN | 20   | 26 | 0.8843 | 0.8149   | 0.6513 | 0.9120      | 0.8146    | 0.7239   | 0.7816            |
| ACM + KNN | 20   | 5  | 0.8716 | 0.8148   | 0.6997 | 0.8832      | 0.7805    | 0.7379   | 0.7914            |
| ACM + LDA | 20   | NA | 0.8621 | 0.7997   | 0.6325 | 0.8991      | 0.7882    | 0.7018   | 0.7658            |
| ACM + QDA | 20   | NA | 0.8461 | 0.6876   | 0.8729 | 0.5775      | 0.5510    | 0.6755   | 0.7252            |

TABLE 12 – Synthèse de la recherche du paramètre k pour le KNN

| k  | Meilleure AUC | Meilleur F1-score | Nombre d'axes associé à la meilleure AUC |
|----|---------------|-------------------|------------------------------------------|
| 15 | 0.8865        | 0.7361            | 20                                       |
| 26 | 0.8843        | 0.7297            | 20                                       |
| 5  | 0.8716        | 0.7396            | 20                                       |

une grille de recherche est appliquée sur la base validation.

La grille compare plusieurs nombres d'axes pour la LDA, la QDA et le KNN. Pour le KNN, plusieurs valeurs de **k** sont aussi testées. Ce paramètre correspond au nombre de voisins utilisés pour classer une réservation : une petite valeur de **k** donne un modèle plus local et potentiellement plus instable, tandis qu'une grande valeur lisse davantage la décision mais peut perdre des profils spécifiques.




FIGURE 6 – AUC de validation selon le nombre d'axes ACM et le modèle

Au regard des résultats de validation, le modèle retenu est celui qui présente la meilleure AUC, puis le meilleur F1-score en cas de performances proches. Dans notre cas, la sélection retient le modèle ACM + KNN, avec 20 axes ACM. Pour le KNN, la valeur retenue est **k = r discriminant\_method\_recap\$selected\_knn\_k**.




FIGURE 7 – F1-score de validation selon le nombre d’axes ACM et le modèle

TABLE 13 – Seuil de classification retenu sur validation

| Seuil | Accuracy | Recall | Spécificité | Précision | F1-score | Balanced accuracy |
|-------|----------|--------|-------------|-----------|----------|-------------------|
| 0.34  | 0.8073   | 0.7679 | 0.8306      | 0.7292    | 0.748    | 0.7993            |

## 6.4 Choix du seuil de classification

Les modèles produisent une probabilité ou un score associé à la modalité “Oui” de `is_canceled`. Le seuil par défaut de 0,50 n’est pas forcément optimal, surtout lorsque l’objectif est de détecter les annulations. Nous avons donc optimisé le seuil sur la base validation après avoir choisi le modèle et le nombre d’axes.

Le critère principal retenu est le F1-score. Ce choix est cohérent avec l’objectif métier : il faut repérer un maximum d’annulations tout en évitant de générer trop de fausses alertes. Le seuil retenu est 0.34.

TABLE 14 – Performance finale des modeles sur la base test

| Modele                        | Seuil | Accuracy | AUC    | Recall | Specificite | Precision | F1-score | Balanced accuracy |
|-------------------------------|-------|----------|--------|--------|-------------|-----------|----------|-------------------|
| ACM + KNN (20 axes, k=15)     | 0.34  | 0.8184   | 0.8974 | 0.7878 | 0.8366      | 0.7412    | 0.7638   | 0.8122            |
| Regression logistique - lasso | 0.42  | 0.8118   | 0.8795 | 0.7378 | 0.8558      | 0.7524    | 0.7450   | 0.7968            |

## 7 Comparaison des résultats et conclusion

Cette derniere partie confronte les deux approches sur la base test, qui n'a pas ete utilisee pour choisir les variables, le nombre d'axes, les hyperparametres ou les seuils. Elle donne donc la mesure la plus honnete de la capacite de generalisation des modeles.




FIGURE 8 – Comparaison finale des principaux indicateurs sur test

La regression logistique conserve l'avantage d'etre plus directement interpretable : elle fournit des odds ratios et permet de quantifier l'effet des modalites sur la probabilite d'annulation. Elle constitue donc un modele de reference solide pour expliquer les facteurs de risque.

L'approche DISQUAL, fondee sur l'ACM puis la classification, capte davantage la structure globale des profils qualitatifs. Dans notre evaluation finale, le meilleur modele global est ACM + KNN (20 axes, k=15), avec une AUC de 0.897 et un F1-score de 0.764. Ce resultat indique que la representation factorielle suivie du classifieur retenu apporte un gain predictif sur la detection des annulations.

Sur le plan operationnel, le modele peut servir a prioriser les reservations a risque : les observations predites comme annulees peuvent faire l'objet d'une relance, d'une politique de garantie adaptee ou d'une surveillance plus fine. Cette utilisation doit toutefois rester prudente : l'objectif n'est pas de sanctionner un client, mais d'anticiper le risque de no-show ou d'annulation afin d'aider la gestion hoteliere.

## 8 Sources des données et références

La base utilisée provient du jeu de données *Hotel Booking Demand Datasets*, diffusé sur Kaggle et documenté dans l'article scientifique publié dans *Data in Brief* : [Hotel Booking Demand Datasets](#). Les références méthodologiques relatives à la régression logistique et à l'analyse discriminante sur variables qualitatives seront complétées dans cette section.

## 9 Annexes

### 9.1 Tableaux complémentaires

TABLE 15 – Description des principales variables de la base de données

| Variable                       | Description                                                                              | Type         | Choix       |
|--------------------------------|------------------------------------------------------------------------------------------|--------------|-------------|
| adr                            | Prix moyen journalier de la reservation.                                                 | Quantitative | Retenue     |
| adults                         | Nombre d'adultes associes a la reservation.                                              | Quantitative | Retenue     |
| arrival_date_month             | Mois d'arrivee prevue du client.                                                         | Qualitative  | Retenue     |
| babies                         | Nombre de bebes associes a la reservation.                                               | Quantitative | Retenue     |
| booking_changes                | Nombre de modifications effectuees sur la reservation.                                   | Quantitative | Retenue     |
| children                       | Nombre d'enfants associes a la reservation.                                              | Quantitative | Retenue     |
| country                        | Pays d'origine du client, code selon la nomenclature pays disponible dans la base.       | Qualitative  | Retenue     |
| customer_type                  | Type de client : Transient, Contract, Group ou Transient-Party.                          | Qualitative  | Retenue     |
| deposit_type                   | Type de depot ou garantie associe a la reservation.                                      | Qualitative  | Retenue     |
| hotel                          | Type d'hotel concerne par la reservation : Resort Hotel ou City Hotel.                   | Qualitative  | Retenue     |
| is_canceled                    | Variable cible indiquant si la reservation a ete annulee : 1 = annulee, 0 = non annulee. | Qualitative  | Retenue     |
| lead_time                      | Nombre de jours entre la date de reservation et la date d'arrivee prevue.                | Quantitative | Retenue     |
| market_segment                 | Segment de marche ou canal commercial a l'origine de la reservation.                     | Qualitative  | Retenue     |
| previous_cancellations         | Nombre d'annulations precedentes effectuees par le client.                               | Quantitative | Retenue     |
| required_car_parking_spaces    | Nombre de places de parking demandees par le client.                                     | Quantitative | Retenue     |
| stays_in_week_nights           | Nombre de nuits en semaine reservees.                                                    | Quantitative | Retenue     |
| stays_in_weekend_nights        | Nombre de nuits de week-end reservees.                                                   | Quantitative | Retenue     |
| total_of_special_requests      | Nombre de demandes speciales formulees par le client.                                    | Quantitative | Retenue     |
| agent                          | Identifiant de l'agence de voyage ayant effectue la reservation, si applicable.          | Qualitative  | Non retenue |
| arrival_date_day_of_month      | Jour du mois correspondant a l'arrivee prevue.                                           | Quantitative | Non retenue |
| arrival_date_week_number       | Numero de semaine de l'annee correspondant a l'arrivee prevue.                           | Quantitative | Non retenue |
| arrival_date_year              | Annee d'arrivee prevue du client.                                                        | Quantitative | Non retenue |
| assigned_room_type             | Type de chambre finalement attribuee.                                                    | Qualitative  | Non retenue |
| company                        | Identifiant de l'entreprise associee a la reservation, si applicable.                    | Qualitative  | Non retenue |
| days_in_waiting_list           | Nombre de jours passes sur liste d'attente avant confirmation.                           | Quantitative | Non retenue |
| distribution_channel           | Canal de distribution utilise pour effectuer la reservation.                             | Qualitative  | Non retenue |
| is_repeated_guest              | Indique si le client est deja venu auparavant : 1 = oui, 0 = non.                        | Qualitative  | Non retenue |
| meal                           | Type de repas reserve.                                                                   | Qualitative  | Non retenue |
| previous_bookings_not_canceled | Nombre de reservations precedentes non annulees par le client.                           | Quantitative | Non retenue |
| reservation_status             | Statut final de la reservation : annulee, non annulee ou no-show.                        | Qualitative  | Non retenue |
| reservation_status_date        | Date du dernier statut de la reservation.                                                | Date         | Non retenue |
| reserved_room_type             | Type de chambre initialement reserve.                                                    | Qualitative  | Non retenue |

TABLE 17 – Variables construites pour l'analyse

| Variable                   | Variables sources                                                | Règle de construction                                                                                                        | Rôle dans l'analyse                      |
|----------------------------|------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------|------------------------------------------|
| is_canceled                | is_canceled                                                      | Recodage de 0/1 en Non/Oui                                                                                                   | Variable cible a predire                 |
| lead_time_cat              | lead_time                                                        | 0 = derniere_minute ; <= 7 = court ; <= 30 = moyen ; <= 90 = long ; > 90 = tres_long                                         | Mesurer l'anticipation de la reservation |
| total_nights               | stays_in_week_nights + stays_in_weekend_nights                   | Somme des nuits en semaine et de week-end                                                                                    | Mesurer la duree totale du sejour        |
| total_nights_cat           | total_nights                                                     | <= 2 = court_sejour ; <= 5 = moyen_sejour ; > 5 = long_sejour                                                                | Regrouper les durees de sejour           |
| adr_cat                    | adr                                                              | Decoupage de l'ADR en quartiles q1_low, q2_midlow, q3_midhigh, q4_high                                                       | Comparer les niveaux de prix             |
| has_children               | children + babies                                                | Oui si au moins un enfant ou bebe, Non sinon                                                                                 | Identifier les reservations familiales   |
| parking_reserved           | required_car_parking_spaces                                      | Oui si au moins une place de parking demandee, Non sinon                                                                     | Mesurer un signe d'engagement du client  |
| engagement                 | total_of_special_requests + booking_changes + 1 x parking_binary | Somme des demandes speciales et des changements de reservation et de reservation de place de parking                         | Score enrichi d'engagement               |
| engagement_cat             | engagement                                                       | 0 = faible ; <= 2 = moyen ; >= 3 = fort                                                                                      | Comparer les niveaux d'engagement        |
| previous_cancellations_cat | previous_cancellations                                           | 0 = Non ; >= 1 = Une_ou_plus                                                                                                 | Capturer l'historique d'annulation       |
| saison_tourisme            | arrival_date_month                                               | Juillet-aout = pick_saison ; juin-septembre = haute_saison ; avril-mai-octobre = moyenne_saison ; autres mois = basse_saison | Tenir compte de la saison touristique    |
| repeated_guest_cat         | is_repeated_guest                                                | 1 = Oui ; 0 = Non                                                                                                            | Identifier les clients deja venus        |

*(continued)*

| Variable          | Variables sources   | Règle de construction                                                                                      | Rôle dans l'analyse                                           |
|-------------------|---------------------|------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------|
| continent         | country             | Conversion du code pays ISO en continent avec countrycode et regroupement des codes non reconnus           | Intermediaire de construction de l'origine géographique       |
| identity_location | country + continent | Portugal = Local_Portugal ; Europe hors Portugal = Europe_hors_PRT ; autres origines = Other_International | Resumer l'origine géographique du client pour la modelisation |

TABLE 16 – Structure générale de la base de données

| Indicateur                                       | Valeur                    |
|--------------------------------------------------|---------------------------|
| Unite statistique                                | Une reservation hoteliere |
| Nombre d'observations initiales                  | 119 390                   |
| Nombre de variables initiales                    | 32                        |
| Nombre d'observations exclues au nettoyage       | 827                       |
| Nombre d'observations conservees apres nettoyage | 118 563                   |
| Part de la base conservee                        | 99.3%                     |
| Nombre de variables apres engineering            | 47                        |
| Nombre de reservations City Hotel                | 79 330                    |
| Nombre de reservations Resort Hotel              | 40 060                    |
| Variable cible                                   | is_canceled               |
| Reservations non annulees - base initiale        | 75 166                    |
| Reservations annulees - base initiale            | 44 224                    |
| Taux d'annulation - base initiale                | 37 %                      |
| Reservations non annulees - base nettoye         | 74 388                    |
| Reservations annulees - base nettoye             | 44 175                    |
| Taux d'annulation - base nettoye                 | 37.3%                     |
| Valeurs manquantes au sens R                     | 4                         |
| Variables avec valeurs manquantes                | children (4)              |

TABLE 18 – Variables retenues pour la modélisation logistique

| Variable                   | Rôle dans l'analyse                                            |
|----------------------------|----------------------------------------------------------------|
| is_canceled                | Variable cible a predire                                       |
| hotel                      | Distinguer City Hotel et Resort Hotel                          |
| market_segment             | Caracteriser le canal commercial de reservation                |
| customer_type              | Distinguer les profils de clients selon le type de reservation |
| lead_time_cat              | Mesurer l'anticipation de la reservation                       |
| total_nights_cat           | Regrouper les durees de sejour                                 |
| adr_cat                    | Comparer les niveaux de prix                                   |
| has_children               | Identifier les reservations familiales                         |
| engagement_cat             | Comparer les niveaux d'engagement                              |
| previous_cancellations_cat | Capturer l'historique d'annulation                             |
| saison_tourisme            | Tenir compte de la saison touristique                          |
| identity_location          | Resumer l'origine geographique du client pour la modelisation  |



TABLE 19 – Synthèse des contrôles et traitements de cohérence

| Critère                      | Effectif | Pourcentage | Décision |
|------------------------------|----------|-------------|----------|
| ADR extreme superieur a 1000 | 1        | 0.00%       | Exclu    |
| ADR negatif                  | 1        | 0.00%       | Exclu    |
| Aucun client renseigne       | 180      | 0.15%       | Exclu    |
| Sejour de 0 nuit             | 645      | 0.54%       | Exclu    |
| Conserve                     | 118563   | 99.31%      | Conserve |