



Conservatoire National des Arts et Métiers

Projet STA201 : Analyse multivariée approfondie

Etude de cas : Annulations de reservations hotelières

Auteurs : ASSAL HAMZA
TRAORE SAH
Date : 17-05-2026

Table des matières

1	Présentation des bases théoriques des deux méthodes	2
1.1	Régression logistique	2
1.2	Analyse discriminante sur variables qualitatives	3
2	Introduction, problématique et base de données	5
2.1	Présentation des variables importantes à l'étude	5
3	Description des données, prétraitements et statistiques descriptives	6
3.1	Nettoyage et cohérence des données et data engenering	6
3.2	Analyse statistique élémentaire	6
4	Objectif de l'étude et démarche choisie	9
5	Résultats et interprétations de la première méthode : régression logistique	10
5.1	Strategie de modelisation	10
5.2	Comparaison des modeles sur validation	10
5.3	AIC et complexite des modeles	11
5.4	Choix du seuil de classification	11
5.5	Variables importantes	13
6	Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives	15
6.1	Stratégie de modélisation	15
6.2	Construction de l'ACM et interpretation des axes	15
6.2.1	Role de l'ACM dans la methode DISQUAL	15
6.2.2	Inertie des axes factoriels	16
6.2.3	Représentation et interpretation des axes	16
6.3	Tests statistiques sur les axes de l'ACM	18
6.4	Choix du meilleur modèle et du nombre d'axes optimum	18
6.5	Choix du seuil de classification	19
7	Comparaison des résultats et conclusion	21
8	Sources des données et références	22
9	Annexes	23
9.1	Tableaux complémentaires	23
9.2	Objectif de l'étude et démarche choisie	29
9.3	Annexe - Analyse discriminante sur variables qualitatives	29
9.3.1	Inertie des axes factoriels	29
9.3.2	Représentation et interpretation des axes	29
9.3.3	Tests statistiques sur les axes de l'ACM	34
9.3.4	Choix du nombre d'axes et du classifieur	35

1 Présentation des bases théoriques des deux méthodes

1.1 Régression logistique

La régression logistique est une méthode de classification supervisée utilisée lorsque la variable à expliquer est qualitative, le plus souvent binaire. Elle permet d'estimer la probabilité qu'un individu appartienne à une modalité d'intérêt à partir d'un ensemble de variables explicatives quantitatives ou qualitatives. Lorsque les variables explicatives sont qualitatives, elles sont généralement transformées en variables indicatrices afin d'être intégrées au modèle.

Contrairement à une régression linéaire classique, la régression logistique ne modélise pas directement la variable binaire. Elle modélise le logarithme du rapport des chances, appelé logit. Si l'on note p_i la probabilité que l'individu i appartienne à la classe étudiée, le modèle s'écrit :

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$$

où $x_{i1}, \dots, x_{ip}$ représentent les variables explicatives, et $\beta_0, \dots, \beta_p$ les paramètres du modèle. La transformation logit permet de relier une probabilité comprise entre 0 et 1 à une combinaison linéaire de variables explicatives.

Une fois le modèle estimé, la probabilité prédite s'obtient par la fonction logistique :

$$p_i = \frac{1}{1 + \exp[-(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})]}$$

La décision de classer un individu dans la classe étudiée dépend ensuite d'un seuil de classification. Le seuil de 0,5 est souvent utilisé par défaut, mais il peut être modifié selon l'objectif de l'étude. Lorsque l'on cherche prioritairement à détecter une classe particulière, il est fréquent d'ajuster ce seuil afin d'améliorer la sensibilité, c'est-à-dire la capacité du modèle à repérer correctement les individus appartenant réellement à cette classe.

L'interprétation des coefficients se fait généralement à l'aide des odds ratios. Pour une variable explicative donnée, l'odds ratio correspond à l'exponentielle du coefficient estimé :

$$OR_j = \exp(\beta_j)$$

Un odds ratio supérieur à 1 indique que la variable augmente les chances d'appartenir à la classe étudiée, toutes choses égales par ailleurs. À l'inverse, un odds ratio inférieur à 1 indique une diminution de ces chances. Cette propriété rend la régression logistique intéressante à la fois pour la prédiction et pour l'interprétation des facteurs associés à une modalité donnée.

L'évaluation du modèle repose sur plusieurs indicateurs issus de la matrice de confusion. L'accuracy mesure la proportion globale de bonnes classifications, mais elle peut être insuffisante lorsque les classes sont déséquilibrées ou lorsque l'on s'intéresse davantage à une classe particulière. La sensibilité, ou recall, mesure la proportion d'individus de la classe d'intérêt correctement détectés. La spécificité mesure la proportion d'individus de l'autre classe correctement reconnus. La précision indique, parmi les individus prédits dans la classe d'intérêt, la proportion qui appartient réellement

à cette classe. Le F1-score combine précision et sensibilité, tandis que l'AUC mesure la capacité globale du modèle à séparer les classes indépendamment d'un seuil particulier.

La régression logistique présente plusieurs avantages : elle est relativement simple à mettre en œuvre, interprétable, adaptée à une variable cible binaire et compatible avec des variables explicatives de nature variée. Ses limites tiennent notamment à l'hypothèse d'une relation linéaire entre les variables explicatives et le logit de la probabilité, à la sensibilité aux valeurs extrêmes, à la multicolinéarité et aux situations de séparation quasi parfaite.

1.2 Analyse discriminante sur variables qualitatives

L'analyse discriminante sur variables qualitatives est une approche de classification supervisée adaptée aux situations où les variables explicatives sont principalement qualitatives. Dans une perspective prédictive, elle vise à apprendre une règle permettant d'affecter un nouvel individu à l'un des groupes connus à partir de son profil de modalités. Dans la littérature, cette démarche est souvent désignée par le terme DISQUAL, notamment dans les travaux de Gilbert Saporta.

L'idée générale est de transformer l'information qualitative en une représentation numérique exploitable par une analyse discriminante. Pour cela, les variables qualitatives sont généralement codées sous forme d'un tableau disjonctif complet. Chaque modalité devient une indicatrice prenant la valeur 1 si l'individu possède la modalité, et 0 sinon. Cette transformation permet de représenter chaque individu par le profil des modalités qu'il possède.

À partir de cette représentation, une difficulté apparaît : le tableau disjonctif peut contenir beaucoup de colonnes, parfois corrélées entre elles, surtout lorsque les variables qualitatives ont de nombreuses modalités. Pour rendre la modélisation plus stable, on peut d'abord appliquer une analyse des correspondances multiples (ACM). L'ACM résume l'information qualitative dans un nombre réduit d'axes factoriels continus. Ces axes deviennent alors de nouvelles variables synthétiques qui conservent une partie importante de l'information initiale tout en réduisant la dimension du problème.

La partie discriminante peut ensuite être réalisée à partir de ces axes d'ACM. Deux méthodes classiques peuvent être utilisées : l'analyse discriminante linéaire (LDA) et l'analyse discriminante quadratique (QDA). La LDA suppose que les groupes ont des matrices de variance-covariance identiques ; elle construit donc des frontières de décision linéaires. La QDA relâche cette hypothèse et autorise une matrice de variance-covariance différente pour chaque groupe ; elle peut ainsi construire des frontières de décision plus souples, mais elle demande davantage de données pour être estimée de manière stable.

Dans cette logique, l'analyse discriminante sur variables qualitatives peut être vue comme une chaîne prédictive en deux temps. L'ACM transforme et résume les variables qualitatives, puis la LDA ou la QDA apprend une règle de classification à partir des axes factoriels retenus. La qualité du modèle dépend alors du nombre d'axes conservés, de la séparation réelle entre les groupes et de la stabilité des matrices de covariance estimées.

L'évaluation de la méthode se fait comme pour toute méthode de prédiction supervisée. On applique le modèle à un échantillon de test ou de validation, puis on compare les groupes prédits aux groupes observés. La matrice de confusion permet de calculer l'accuracy, la sensibilité, la spécificité, la précision et le F1-score. Ces indicateurs mesurent la capacité de la méthode à classer correctement les individus et à repérer les groupes d'intérêt.

Cette approche est particulièrement utile lorsque l'analyse porte sur des profils construits à partir de modalités qualitatives. L'étape d'ACM permet aussi de garder une lecture descriptive des modalités qui structurent les axes factoriels, même si l'objectif final est prédictif. Ses limites tiennent notamment à la qualité du codage, au choix du nombre d'axes retenus, à la présence de modalités rares et au risque d'instabilité lorsque certains groupes sont peu représentés. Un regroupement raisonné des modalités peut donc être nécessaire avant l'analyse.

2 Introduction, problématique et base de données

##Présentation de la base

Notre étude s'appuie sur la base de données *Hotel Booking Demand Datasets*, construite afin d'analyser le comportement d'annulation des réservations dans le secteur hôtelier. Cette base a notamment été diffusée sur Kaggle et documentée dans un article scientifique publié dans la revue *Data in Brief*. Les informations détaillées sur l'origine des données sont précisées dans la section Section 8.

La base contient 119 390 réservations provenant de deux types d'hôtels *Resort Hotel* et *City Hotel*. Chaque observation correspond à une réservation hôtelière, qu'elle ait donné lieu à un séjour effectif ou à une annulation.

La variable d'intérêt de notre étude est donc la variable indicatrice d'annulation, notée `is_canceled`, qui prend la valeur 1 lorsque la réservation a été annulée et 0 sinon.

La base de données ne contient pas de valeurs manquantes. Toutefois, certaines variables catégorielles, peuvent prendre la valeur « NULL ». Cette valeur ne correspond pas à une donnée absente, mais indique simplement que l'information n'est pas applicable. Par exemple, une valeur « NULL » pour la variable `children` signifie que la réservation ne comporte pas d'enfant.

2.1 Présentation des variables importantes à l'étude

Les principales variables utilisées dans l'étude sont décrites en Annexe, dans le Tableau Table 14. Elles couvrent la nature de l'hôtel, la variable cible `is_canceled`, les caractéristiques temporelles de la réservation, la composition du séjour, le canal de réservation, le prix moyen journalier et les demandes particulières du client.

3 Description des données, prétraitements et statistiques descriptives

La structure générale de la base est résumée en Annexe dans le Tableau Table 15.

3.1 Nettoyage et cohérence des données et data engenering

Avant l’analyse statistique et la modélisation, plusieurs contrôles ont été réalisés afin de sécuriser l’utilisation de la base. L’objectif était de conserver l’information disponible tout en traitant les situations susceptibles de produire des incohérences dans les variables construites ou dans les modèles.

La synthèse chiffrée de ces contrôles et décisions est présentée en Annexe dans le Tableau Table 17.

À l’issue de ces traitements, la base d’analyse contient 118563 observations. Ensuite, de grands travaux de data engenering ont été opéré sur la base de compréhension métier de la problématique et des analyses statistiques.

Certaines variables initiales ont été transformé en indicateurs plus directement exploitables pour l’analyse. Plusieurs variables synthétiques ont été construites afin de rendre les résultats plus lisibles, de limiter le nombre de modalités et de disposer de profils interprétables.

Ces variables portent notamment sur le délai de réservation, la durée du séjour, le niveau de prix, la présence d’enfants, l’engagement du client, l’historique d’annulation, la saison touristique et l’origine géographique du client. La variable cible `is_canceled` a également été recodée sous forme factorielle avec les modalités `Non` et `Oui`, ce qui permet une lecture homogène des sorties descriptives et prédictives.

Ainsi, nous avons l’exemple de `lead_time` devient : `lead_time_cat` = (“derniere_minute”, “court”, “moyen”, “long”, “tres_long”), qui mesure d’une façon plus différenciée la durée entre la reservation et la date d’arrivée.


Aussi les variables `total_of_special_requests`, `booking_changes`, `parking` deviennent `engagement_cat` qui mesure l’investissement envers la reservation.

L’exhaustivité des variables construites et leurs détails sont dans le Tableau Table 16.


3.2 Analyse statistique élémentaire

Notre variable d’intérêt “`is_canceled`” présente 37% des reservations annulées, ce qui reste un niveau élevé d’où l’importance de ce type d’étude et qui nous donne une base relativement équilibrée entre les deux modalités.

Matrice des associations (V de Cramér)



1 des annulations selon les variables exp



Nous faisons un focus sur deux des variables créées à savoir le délai de réservation et l'engagement client. d'après l'analyse bivariable en figure ?@fig-stat on constat que plus le délai de reservation est long plus la probabilité d'annulation augmente. Aussi un fort engagement du client traduit par une faible probabilité d'annulation.

Vous trouverez un panorama des statistiques bivariées avec notre variable d'intérêt en annexe @final_bivariate_plot_all

Aussi une étude de corrélation entre les variables a été faite sur la base du V de cramer. Nous en déduisons une corrélation faible entre la majorité des variables (V-cramer<0.2). Toutefois quelques variables présentent une forte corrélation (exemple entre *market_segment* et *distribution_channel* => cramer_v=0.604). Ce constat nous a mené à arbitrer entre ces deux variables. L'ensemble de

la matrice des associations est détaillé sur la figure ?@fig-stat__corr en annexe.

TABLE 1 – Variables retenues pour les modélisations

Variable	Rôle dans l'analyse
is_canceled	Variable cible à prédire
hotel	Distinguer City Hotel et Resort Hotel
market_segment	Caractériser le canal commercial de réservation
customer_type	Distinguer les profils de clients selon le type de réservation
lead_time_cat	Mesurer l'anticipation de la réservation
total_nights_cat	Regrouper les durées de séjour
adr_cat	Comparer les niveaux de prix
has_children	Identifier les réservations familiales
engagement_cat	Comparer les niveaux d'engagement
previous_cancellations_cat	Capturer l'historique d'annulation
saison_tourisme	Tenir compte de la saison touristique
identity_location	Resumer l'origine géographique du client pour la modélisation

4 Objectif de l'étude et démarche choisie

L'objectif opérationnel du projet est de mieux identifier les réservations susceptibles d'être annulées. La démarche retenue consiste, après avoir construit des variables qualitatives interprétables, à mobiliser deux méthodes : la régression logistique, pour estimer une probabilité d'annulation et interpréter l'effet des facteurs explicatifs, et l'analyse discriminante sur variables qualitatives, pour étudier la discrimination entre les profils de réservations annulées et non annulées.

Pour les deux méthodes nous avons retenues 12 variables qualitatives qui nous semblent les plus pertinentes pour l'étude présentées dans le Tableau Table 1.

En ce qui concerne la démarche de modélisation, la base de données a été divisée en trois sous-échantillons : une base d'entraînement (base train) contenant 50 % des observations, une base de validation contenant 25 % des observations et une base test contenant les 25 % restants. Ce découpage a été réalisé à l'aide d'un échantillonnage stratifié selon la variable cible.

Pour chaque méthode, les modèles ont d'abord été construits à partir de la base d'entraînement. Le choix du meilleur modèle a ensuite été effectué sur la base des performances observées sur la base de validation.

Une fois le modèle optimal sélectionné, celui-ci a été réestimé sur l'ensemble des données d'entraînement et de validation (soit 75 % des données). Enfin, l'évaluation finale des performances a été réalisée exclusivement sur la base test, laquelle n'a été utilisée ni pour la construction ni pour la sélection des modèles.

La figure Figure 7 en annexe présente la démarche suivie pour la modélisation.

TABLE 2 – Synthèse de la stratégie retenue pour la régression logistique

Modele retenu	Type	Seuil	Base de selection	Base finale	Role du test
lasso	penalized	0.42	validation	train + validation	evaluation finale dans scripts/07- Comparaison.R

TABLE 3 – Performances des modèles logistiques sur validation

Modele	Type	Seuil	Accuracy	AUC	Recall	Specificite	Precision	F1-score	Balanced accuracy
glm_full	glm_selection	0.43	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
glm_backward	glm_selection	0.43	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
glm_forward	glm_selection	0.43	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
glm_stepwise	glm_selection	0.43	0.8132	0.8783	0.7418	0.8556	0.7531	0.7474	0.7987
elastic_net_075	penalized	0.43	0.8125	0.8767	0.7375	0.8570	0.7538	0.7456	0.7972
elastic_net_050	penalized	0.42	0.8117	0.8765	0.7431	0.8525	0.7495	0.7463	0.7978
elastic_net_025	penalized	0.42	0.8116	0.8765	0.7438	0.8519	0.7489	0.7464	0.7979
lasso	penalized	0.42	0.8106	0.8765	0.7427	0.8510	0.7475	0.7451	0.7968
ridge	penalized	0.40	0.8035	0.8712	0.7479	0.8365	0.7310	0.7393	0.7922

5 Résultats et interprétations de la première méthode : régression logistique

Cette partie présente la construction des modèles de régression logistique. L'objectif est double : comparer plusieurs stratégies de sélection de variables et évaluer l'apport des régularisations ridge, lasso et elastic net. Les modèles sont estimés sur train, comparés sur validation, puis le meilleur modèle est réestimé sur train + validation avant l'évaluation finale dans la partie comparaison.

5.1 Stratégie de modélisation

Deux familles de modèles ont été comparées. La première famille regroupe les régressions logistiques classiques avec différentes méthodes de sélection : modèle complet, sélection backward, sélection forward et sélection stepwise. Ces modèles sont comparés notamment par leur AIC et par leurs performances sur validation.

La deuxième famille regroupe les régressions logistiques pénalisées : ridge, lasso et elastic net. Ces méthodes sont utiles lorsque les variables indicatrices issues des variables qualitatives sont nombreuses ou corrélées. Ridge réduit les coefficients sans les annuler, lasso peut sélectionner automatiquement certaines modalités en mettant des coefficients à zéro, et elastic net combine ces deux comportements.

5.2 Comparaison des modèles sur validation

Le choix du modèle repose d'abord sur la performance prédictive observée sur validation. L'AUC mesure la capacité générale du modèle à séparer les réservations annulées des réservations non annulées, indépendamment du seuil. Le F1-score complète cette lecture car il tient compte à la fois du rappel et de la précision pour la modalité d'intérêt, ici l'annulation.

Les résultats montrent que les modèles logistiques classiques et pénalisés sont proches. Dans notre exécution, le modèle retenu automatiquement est lasso, avec un seuil de 0.42. Ce choix est effectué sur validation et non sur test.




FIGURE 1 – AUC et F1-score des modeles logistiques sur validation

TABLE 4 – AIC et AIC approximatif des modeles logistiques

Modele	Type	Alpha	Lambda 1se	Log-vraisemblance train	Coefficients non nuls	AIC / AIC approx.
glm_full	glm_selection	NA	NA	NA	27	49293.56
glm_backward	glm_selection	NA	NA	NA	27	49293.56
glm_forward	glm_selection	NA	NA	NA	27	49293.56
glm_stepwise	glm_selection	NA	NA	NA	27	49293.56
elastic_net_025	penalized	0.25	0.0043	-24826.87	26	49705.75
elastic_net_075	penalized	0.75	0.0037	-24832.76	25	49715.51
elastic_net_050	penalized	0.50	0.0042	-24843.17	25	49736.33
lasso	penalized	1.00	0.0036	-24861.45	24	49770.90
ridge	penalized	0.00	0.0263	-25756.69	27	51567.37

5.3 AIC et complexite des modeles

L'AIC permet de comparer les modeles logistiques classiques en arbitrando entre qualite d'ajustement et complexite. Pour les modeles penalises, nous calculons un AIC approximatif fonde sur la log-vraisemblance et le nombre de coefficients non nuls. Il ne doit pas etre interprete comme un AIC strictement equivalent a celui d'un `glm`, mais il donne un repere utile pour comparer ridge, lasso et elastic net entre eux.

5.4 Choix du seuil de classification

Une regression logistique produit une probabilite d'annulation. Pour transformer cette probabilite en classe predite, il faut choisir un seuil. Le seuil par defaut de 0,50 n'est pas necessairement le plus adapte, car l'objectif metier consiste surtout a bien detecter les annulations sans degrader excessivement la precision.

Le seuil est donc optimise sur validation apres le choix du modele. Le critere principal est le F1-score, qui equilibre precision et rappel.




FIGURE 2 – Evolution des metriques selon le seuil du modele logistique retenu

TABLE 5 – Seuil retenu pour le modele logistique

Seuil	Accuracy	Recall	Specificite	Precision	F1-score	Balanced accuracy
0.42	0.8106	0.7427	0.851	0.7475	0.7451	0.7968

TABLE 6 – Variables ou modalités les plus importantes du modèle logistique retenu

Modele	Variable	Modalite	Odds ratio	p-value	Importance
lasso	lead_time_cat	lead_time_cattres_long	10.5208	NA	1.0000
lasso	previous_cancellations_cat	previous_cancellations_catUne_ou_plus	10.2882	NA	0.9905
lasso	engagement_cat	engagement_catfort	0.1214	NA	0.8962
lasso	identity_location	identity_locationLocal_Portugal	7.1215	NA	0.8342
lasso	lead_time_cat	lead_time_catlong	6.4542	NA	0.7924
lasso	engagement_cat	engagement_catmoyen	0.2198	NA	0.6437
lasso	lead_time_cat	lead_time_catmoyen	4.0012	NA	0.5892
lasso	market_segment	market_segmentOnline_TA	3.5594	NA	0.5395
lasso	customer_type	customer_typeTransient	2.8382	NA	0.4433
lasso	market_segment	market_segmentOther	2.3598	NA	0.3648
lasso	identity_location	identity_locationOther_International	1.7465	NA	0.2369
lasso	hotel	hotelResort Hotel	0.6995	NA	0.1519
lasso	adr_cat	adr_catq4_high	1.3881	NA	0.1393
lasso	market_segment	market_segmentCorporate	0.7672	NA	0.1126
lasso	customer_type	customer_typeTransient-Party	0.7802	NA	0.1055

5.5 Variables importantes

L'interprétation dépend du type de modèle retenu. Pour une régression logistique classique, les odds ratios permettent de lire le sens et l'intensité de l'association entre une modalité et la probabilité d'annulation. Un odds ratio supérieur à 1 indique une augmentation des chances d'annulation, tandis qu'un odds ratio inférieur à 1 indique une diminution, toutes choses égales par ailleurs.

Pour les modèles pénalisés, l'importance est calculée à partir de la valeur absolue des coefficients standardisés par le coefficient maximal du modèle. Le lasso et l'elastic net peuvent aussi indiquer quelles modalités sont effectivement conservées, car certains coefficients peuvent être mis à zéro.




FIGURE 3 – Principales variables ou modalités du modèle logistique retenu

Pour compléter l'analyse des régularisations, le tableau suivant présente l'importance agrégée des

TABLE 7 – Importance agregée des variables dans les modèles pénalisés

Modele	Variable	Modalités retenues	Importance somme	Importance max	Importance relative
elastic_net_025	lead_time_cat	4	5.2943	2.1516	0.2639
elastic_net_025	engagement_cat	2	3.6702	2.1479	0.1830
elastic_net_025	identity_location	2	2.5889	1.9859	0.1291
elastic_net_025	market_segment	4	2.5516	1.2699	0.1272
elastic_net_025	previous_cancellations_cat	1	2.4492	2.4492	0.1221
elastic_net_050	lead_time_cat	4	5.3495	2.1940	0.2733
elastic_net_050	engagement_cat	2	3.6447	2.1283	0.1862
elastic_net_050	identity_location	2	2.5565	1.9726	0.1306
elastic_net_050	market_segment	3	2.4814	1.2648	0.1268
elastic_net_050	previous_cancellations_cat	1	2.3986	2.3986	0.1225
elastic_net_075	lead_time_cat	4	5.5668	2.3088	0.2853
elastic_net_075	engagement_cat	2	3.6537	2.1312	0.1873
elastic_net_075	identity_location	2	2.5547	1.9782	0.1309
elastic_net_075	market_segment	3	2.4516	1.2753	0.1257
elastic_net_075	previous_cancellations_cat	1	2.3801	2.3801	0.1220
lasso	lead_time_cat	4	5.6268	2.3534	0.2950
lasso	engagement_cat	2	3.6239	2.1090	0.1900
lasso	identity_location	2	2.5207	1.9631	0.1321
lasso	market_segment	3	2.3931	1.2696	0.1255
lasso	previous_cancellations_cat	1	2.3310	2.3310	0.1222
ridge	lead_time_cat	4	2.9667	1.1132	0.1956
ridge	engagement_cat	2	2.8481	1.6374	0.1878
ridge	market_segment	4	2.1157	0.8348	0.1395
ridge	identity_location	2	1.9695	1.5472	0.1299
ridge	previous_cancellations_cat	1	1.9386	1.9386	0.1278

variables dans les modèles pénalisés. Cette lecture est utile car une même variable qualitative peut générer plusieurs indicatrices.

En synthèse, la régression logistique fournit une référence prédictive solide et interprétable. Elle permet de quantifier les facteurs associés aux annulations, tout en comparant des versions classiques et pénalisées. L'évaluation finale de ce meilleur modèle logistique sur la base test est présentée dans la section de comparaison finale, afin de conserver une séparation nette entre sélection de modèle et mesure de performance finale.

6 Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives

Cette partie présente l'application de la méthode DISQUAL à notre problème de prédiction des annulations. L'idée générale consiste à transformer les variables qualitatives en axes factoriels continus à l'aide d'une ACM, puis à utiliser ces axes comme variables explicatives dans des modèles de classification. Nous comparerons donc trois classifieurs construits sur les axes ACM : la LDA, la QDA et le KNN.

6.1 Stratégie de modélisation

L'analyse discriminante sera construite dans une logique strictement prédictive. Comme pour le modèle logistique Les mêmes bases : train, validation et test ont été utilisées. La base train sert à apprendre la représentation factorielle et les modèles ; la base validation sert à choisir le meilleur modèle et le nombre d'axes optimum pour la prédiction, le type de modèle et le seuil de classification ; la base test reste réservée à l'évaluation finale.

Une attention particulière a été portée au risque de fuite d'information. Pour la phase de sélection, l'ACM est estimée uniquement sur la base train. Les individus de validation et de test sont ensuite projetés comme individus supplémentaires. Ainsi, la structure factorielle utilisée pour sélectionner le modèle ne dépend pas des observations de validation ni de test.

La sélection du modèle se fait en deux temps. Premièrement, on compare plusieurs nombres d'axes ACM et plusieurs modèles à partir de l'AUC sur validation. L'AUC est utilisée à cette étape car elle évalue la capacité de séparation du modèle indépendamment d'un seuil de classification particulier.

Deuxièmement, une fois le meilleur couple modèle / nombre d'axes retenu, le seuil de classification est optimisé sur validation, principalement à partir du F1-score afin de mieux équilibrer précision et rappel sur la classe des réservations annulées.

Après cette sélection, le modèle final est recalibré en utilisant train + validation pour l'ACM finale. La base test est alors projetée en individu supplémentaire, puis utilisée une seule fois pour mesurer la performance finale. Cette stratégie permet d'utiliser d'avantage de données pour le modèle final tout en conservant une évaluation précise et stricte sur la base test.

6.2 Construction de l'ACM et interpretation des axes

6.2.1 Role de l'ACM dans la methode DISQUAL

L'analyse des correspondances multiples (ACM) est l'étape qui transforme les variables qualitatives en axes factoriels continus. Dans notre cas, les variables explicatives sont des profils de reservation : type d'hotel, segment de marche, type de client, delai de reservation, duree du sejour, niveau de prix, presence d'enfants, engagement, historique d'annulation, saison touristique et origine du client.

L'ACM permet donc de passer d'une lecture variable par variable a une lecture en **profils**. Chaque axe oppose des combinaisons de modalites.

La variable cible `is_canceled` est ajoutée comme variable qualitative supplémentaire. Elle ne participe donc pas à la construction des axes, mais elle est projetée sur ces axes pour vérifier si les profils factoriels sont liés au risque d'annulation.

6.2.2 Inertie des axes factoriels

L'inertie indique la part de structure du tableau disjonctif expliquée par chaque axe. L'inertie expliquée par les 5 premiers axes (33%) est représentée dans le tableau ci dessous.

TABLE 8 – Inertie des premiers axes de l'ACM

Axe	Valeur propre	Inertie (%)	Inertie cumulee (%)
dim 1	0.2229137	9.43	9.43
dim 2	0.1715162	7.26	16.69
dim 3	0.1470762	6.22	22.91
dim 4	0.1296038	5.48	28.39
dim 5	0.1106199	4.68	33.07

On note que nous avons 26 axes au total. En annexe, la représentation de l'inertie de l'ensemble des axes dans la figure Figure 8

6.2.3 Représentation et interpretation des axes

L'interpretation des axes combine quatre elements :

- l'inertie de l'axe ;
- les modalites les plus contributives ;
- les modalites les mieux representees ;
- la position de la cible `is_canceled` projetee en supplementaire.

La représentation graphique suivantes affichent les modalites les plus contributives sur les deux premiers axes factoriels. Les libelles utilisent la forme `variable = modalite`. La cible est ajoutée en bleu comme variable supplementaire. Ainsi, le graphique montre a la fois la structure des profils et la position descriptive de l'annulation.




FIGURE 4 – Plan factoriel 1-2 avec modalites labellisees

Nous pouvons ainsi interpréter précisément les axes obtenus :

6.2.3.1 Axe 1 : engagement apparent contre risque historique et canal de reservation

Le pole negatif de l'axe 1 regroupe notamment `has_children = Oui`, `adr_cat = q4_high` et `engagement_cat = fort`. Il correspond a des reservations qui semblent plus engagees : presence d'enfants, niveau de prix eleve et signaux comportementaux traduisant une implication plus forte dans le sejour.

Le pole positif regroupe `previous_cancellations_cat = Une_ou_plus`, `market_segment = Other` et `market_segment = Corporate`, avec une forte contribution de `market_segment = Online_TA`. Ce pole renvoie a des profils ou le canal, le segment et l'historique d'annulation jouent un role plus important.

Interpretation metier : l'axe 1 oppose des reservations a engagement apparent fort a des reservations plus marquees par un risque historique ou commercial. Le fait que `is_canceled_Oui` soit projete du cote positif indique que les annulations sont descriptivement plus proches des profils ayant deja annule ou appartenant a certains segments/canaux.

6.2.3.2 Axe 2 : temporalite de reservation et mode de commercialisation

L'axe 2 oppose `customer_type = Contract`, `market_segment = Offline_TA` et `lead_time_cat = tres_long` à `lead_time_cat = derniere_minute`, `market_segment = Corporate` et `customer_type = Group`. Les contributions les plus fortes viennent des categories de delai de reservation.

Interpretation metier : cet axe decrit principalement la temporalite de decision. Les reservations tres anticipees ou intermediees par des canaux offline ne renvoient pas aux memes comportements que les reservations de derniere minute ou corporate. Le risque d'annulation depend ici de la combinaison entre delai, canal et type de client.

Une representation des autres axes 3,4 et 5 est en annexe Figure 9 et Figure 10 ainsi que des modalités structurantes sur chaque axe sur Figure 11

6.3 Tests statistiques sur les axes de l'ACM

Avant la grid search, nous évaluons les hypothèses statistiques associées aux axes factoriels issus de l'ACM, construits uniquement sur la base d'entraînement. Cette étape permet de vérifier dans quelle mesure les axes utilisés comme variables explicatives sont compatibles avec les hypothèses de l'analyse discriminante.

La normalité est étudiée à deux niveaux : axe par axe avec le test de Shapiro-Wilk, puis globalement avec les tests multivariés de Mardia et de Henze-Zirkler. L'homogénéité des matrices de covariance entre les deux classes de `is_canceled` est vérifiée avec le test de Box's M. Les résultats détaillés de ces diagnostics sont présentés dans les tableaux Table 18, Table 19 et Table 20.

Ces tests ne déterminent pas directement le modèle final, mais ils éclairent la validité théorique de la LDA et de la QDA. Si la normalité ou l'homogénéité des covariances sont rejetées, les modèles restent utilisables comme classifieurs prédictifs, mais leur interprétation probabiliste doit être nuancée. Le choix final repose donc principalement sur la performance observée en validation, via la sélection du nombre d'axes, du modèle et du seuil de classification.

6.4 Choix du meilleur modèle et du nombre d'axes optimum

Le nombre d'axes ACM ne doit pas être choisi uniquement à partir de l'inertie factorielle. Dans notre cadre, l'objectif est prédictif : nous cherchons le nombre d'axes qui améliore réellement la capacité à distinguer les réservations annulées des réservations non annulées. Pour cette raison, une grille de recherche est appliquée sur la base validation.

La grille compare plusieurs nombres d'axes pour la LDA, la QDA et le KNN. Pour le KNN, plusieurs valeurs de `k` sont aussi testées. Ce paramètre correspond au nombre de voisins utilisés pour classer une réservation.

En voici un tableau récapitulatif :

TABLE 9 – Meilleure performance de validation par famille de modèle

Modèle	Axes	k	AUC	Accuracy	Recall	Spécificité	Précision	F1-score	Balanced accuracy
ACM + KNN	26	15	0.8924	0.8199	0.6777	0.9044	0.8081	0.7372	0.7910
ACM + KNN	26	26	0.8915	0.8158	0.6583	0.9094	0.8118	0.7270	0.7838
ACM + LDA	26	NA	0.8753	0.8128	0.6923	0.8844	0.7805	0.7338	0.7884
ACM + KNN	26	5	0.8751	0.8144	0.7018	0.8813	0.7783	0.7381	0.7916
ACM + QDA	26	NA	0.8582	0.7388	0.8653	0.6638	0.6045	0.7117	0.7645

TABLE 10 – Synthèse de la recherche du paramètre k pour le KNN

k	Meilleure AUC	Meilleur F1-score	Nombre d'axes associé à la meilleure AUC
15	0.8924	0.7372	26
26	0.8915	0.7297	26
5	0.8751	0.7396	26

Une première lecture des résultats de validation conduirait à retenir directement le modèle présentant la meilleure AUC dans le Tableau en annexe Table 21. Dans notre cas, il s'agit du modèle KNN avec $k = 15$ et 26 axes ACM. Toutefois, notre objectif n'est pas uniquement de maximiser la performance apparente sur validation : nous cherchons aussi à conserver un modèle parcimonieux, plus stable et moins exposé au risque de sur-ajustement. Nous examinons donc plus finement les gains marginaux d'AUC associés à l'ajout progressif d'axes factoriels. Cette analyse montre que le passage de 15 à 26 axes améliore très peu l'AUC, alors qu'il augmente sensiblement la complexité du modèle. Nous retenons donc le modèle KNN avec $k = 15$ et 15 axes ACM comme compromis entre précision prédictive, stabilité et parcimonie.

TABLE 11 – Gains marginaux d'AUC selon le nombre d'axes pour le KNN retenu

Nombre d'axes	k KNN	AUC	Gain vs étape précédente	Gain vs 15 axes	Écart au meilleur	Lecture
1	15	0.8468	NA	-0.0393	0.0456	Gain encore utile
2	15	0.8590	0.0121	-0.0272	0.0334	Gain encore utile
3	15	0.8550	-0.0040	-0.0312	0.0374	Gain encore utile
4	15	0.8676	0.0126	-0.0185	0.0248	Gain encore utile
5	15	0.8731	0.0055	-0.0131	0.0193	Gain encore utile
7	15	0.8815	0.0084	-0.0047	0.0109	Gain encore utile
10	15	0.8838	0.0023	-0.0024	0.0086	Gain encore utile
15	15	0.8862	0.0024	0.0000	0.0062	Choix retenu
20	15	0.8865	0.0003	0.0003	0.0059	Gain marginal faible
26	15	0.8924	0.0059	0.0062	0.0000	Gain marginal faible

Une représentation graphique de l'évolution de l'AUC Figure 12 et du F1 score Figure 13 par modèle est disponible en annexe

6.5 Choix du seuil de classification

Après le choix du modèle discriminant parcimonieux, défini par le KNN avec $k = 15$ et 15 axes ACM, nous procédons à l'optimisation du seuil de classification. En effet, le modèle produit un score associé à la modalité `is_canceled = Oui`, mais le seuil usuel de 0,50 n'est pas nécessairement optimal, en particulier lorsque l'objectif est d'améliorer la détection des annulations.

Nous réalisons donc une grid search du seuil sur la base validation, en testant une grille de valeurs comprises entre 0,10 et 0,90. Pour chaque seuil candidat, les observations sont classées en **Oui** ou **Non**, puis les indicateurs de performance sont recalculés. Le critère principal retenu est le F1-score, car il permet d'arbitrer entre le rappel, c'est-à-dire la capacité à détecter les annulations, et la précision, c'est-à-dire la limitation des fausses alertes. Le seuil finalement retenu est 0.34.

TABLE 12 – Seuil de classification retenu sur validation pour le modèle discriminant parcimonieux

Modèle	Axes ACM	k KNN	Seuil	Accuracy	Recall	Spécificité	Précision	F1-score	Balanced accuracy
ACM + KNN	15	15	0.34	0.8111	0.7706	0.8351	0.7352	0.7525	0.8029

7 Comparaison des résultats et conclusion

Cette dernière partie confronte les deux approches sur la base test, qui n'a pas été utilisée pour choisir les variables, le nombre d'axes, les hyperparamètres ou les seuils. Elle donne donc la mesure la plus honnête de la capacité de généralisation des modèles.

TABLE 13 – Performance finale des modèles sur la base test

Modèle	Seuil	Accuracy	AUC	Recall	Specificité	Precision	F1-score	Balanced accuracy
ACM + KNN (15 axes, k=15)	0.34	0.8174	0.8967	0.7825	0.8381	0.7417	0.7615	0.8103
Regression logistique - lasso	0.42	0.8118	0.8795	0.7378	0.8558	0.7524	0.7450	0.7968




FIGURE 5 – Comparaison finale des principaux indicateurs sur test

La régression logistique conserve l'avantage d'être plus directement interpretable : elle fournit des odds ratios et permet de quantifier l'effet des modalités sur la probabilité d'annulation. Elle constitue donc un modèle de référence solide pour expliquer les facteurs de risque.

L'approche DISQUAL, fondée sur l'ACM puis la classification, capte davantage la structure globale des profils qualitatifs. Dans notre évaluation finale, le meilleur modèle global est ACM + KNN (15 axes, k=15), avec une AUC de 0.897 et un F1-score de 0.762. Ce résultat indique que la représentation factorielle suivie du classifieur retenu apporte un gain prédictif sur la détection des annulations.

Sur le plan opérationnel, le modèle peut servir à prioriser les réservations à risque : les observations prédites comme annulées peuvent faire l'objet d'une relance, d'une politique de garantie adaptée ou d'une surveillance plus fine. Cette utilisation doit toutefois rester prudente : l'objectif n'est pas de sanctionner un client, mais d'anticiper le risque de no-show ou d'annulation afin d'aider la gestion hôtelière.

8 Sources des données et références

La base utilisée provient du jeu de données *Hotel Booking Demand Datasets*, diffusé sur Kaggle et documenté dans l'article scientifique publié dans *Data in Brief* : [Hotel Booking Demand Datasets](#). Les références méthodologiques relatives à la régression logistique et à l'analyse discriminante sur variables qualitatives seront complétées dans cette section.

9 Annexes

9.1 Tableaux complémentaires

TABLE 14 – Description des principales variables de la base de données

Variable	Description	Type	Choix
adr	Prix moyen journalier de la reservation.	Quantitative	Retenue
adults	Nombre d'adultes associes a la reservation.	Quantitative	Retenue
arrival_date_month	Mois d'arrivee prevue du client.	Qualitative	Retenue
babies	Nombre de bebes associes a la reservation.	Quantitative	Retenue
booking_changes	Nombre de modifications effectuees sur la reservation.	Quantitative	Retenue
children	Nombre d'enfants associes a la reservation.	Quantitative	Retenue
country	Pays d'origine du client, code selon la nomenclature pays disponible dans la base.	Qualitative	Retenue
customer_type	Type de client : Transient, Contract, Group ou Transient-Party.	Qualitative	Retenue
deposit_type	Type de depot ou garantie associe a la reservation.	Qualitative	Retenue
hotel	Type d'hotel concerne par la reservation : Resort Hotel ou City Hotel.	Qualitative	Retenue
is_canceled	Variable cible indiquant si la reservation a ete annulee : 1 = annulee, 0 = non annulee.	Qualitative	Retenue
is_repeated_guest	Indique si le client est deja venu auparavant : 1 = oui, 0 = non.	Qualitative	Retenue
lead_time	Nombre de jours entre la date de reservation et la date d'arrivee prevue.	Quantitative	Retenue
market_segment	Segment de marche ou canal commercial a l'origine de la reservation.	Qualitative	Retenue
previous_cancellations	Nombre d'annulations precedentes effectuees par le client.	Quantitative	Retenue
required_car_parking_spaces	Nombre de places de parking demandees par le client.	Quantitative	Retenue
stays_in_week_nights	Nombre de nuits en semaine reservees.	Quantitative	Retenue
stays_in_weekend_nights	Nombre de nuits de week-end reservees.	Quantitative	Retenue
total_of_special_requests	Nombre de demandes speciales formulees par le client.	Quantitative	Retenue
agent	Identifiant de l'agence de voyage ayant effectue la reservation, si applicable.	Qualitative	Non retenue
arrival_date_day_of_month	Jour du mois correspondant a l'arrivee prevue.	Quantitative	Non retenue
arrival_date_week_number	Numero de semaine de l'annee correspondant a l'arrivee prevue.	Quantitative	Non retenue
arrival_date_year	Annee d'arrivee prevue du client.	Quantitative	Non retenue
assigned_room_type	Type de chambre finalement attribuee.	Qualitative	Non retenue
company	Identifiant de l'entreprise associee a la reservation, si applicable.	Qualitative	Non retenue
days_in_waiting_list	Nombre de jours passes sur liste d'attente avant confirmation.	Quantitative	Non retenue
distribution_channel	Canal de distribution utilise pour effectuer la reservation.	Qualitative	Non retenue
meal	Type de repas reserve.	Qualitative	Non retenue
previous_bookings_not_canceled	Nombre de reservations precedentes non annulees par le client.	Quantitative	Non retenue
reservation_status	Statut final de la reservation : annulee, non annulee ou no-show.	Qualitative	Non retenue
reservation_status_date	Date du dernier statut de la reservation.	Date	Non retenue
reserved_room_type	Type de chambre initialement reserve.	Qualitative	Non retenue

TABLE 16 – Variables construites pour l'analyse

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
is_canceled	is_canceled	Recodage de 0/1 en Non/Oui	Variable cible a predire
lead_time_cat	lead_time	0 = derniere_minute ; <= 7 = court ; <= 30 = moyen ; <= 90 = long ; > 90 = tres_long	Mesurer l'anticipation de la reservation
total_nights	stays_in_week_nights + stays_in_weekend_nights	Somme des nuits en semaine et de week-end	Mesurer la duree totale du sejour
total_nights_cat	total_nights	<= 2 = court_sejour ; <= 5 = moyen_sejour ; > 5 = long_sejour	Regrouper les durees de sejour
adr_cat	adr	Decoupage de l'ADR en quartiles q1_low, q2_midlow, q3_midhigh, q4_high	Comparer les niveaux de prix
has_children	children + babies	Oui si au moins un enfant ou bebe, Non sinon	Identifier les reservations familiales
parking_reserved	required_car_parking_spaces	Oui si au moins une place de parking demandee, Non sinon	Mesurer un signe d'engagement du client
engagement	total_of_special_requests + booking_changes + 1 x parking_binary	Somme des demandes speciales et des changements de reservation et de reservation de place de parking	Score enrichi d'engagement
engagement_cat	engagement	0 = faible ; <= 2 = moyen ; >= 3 = fort	Comparer les niveaux d'engagement
previous_cancellations_cat	previous_cancellations	0 = Non ; >= 1 = Une_ou_plus	Capturer l'historique d'annulation
saison_tourisme	arrival_date_month	Juillet-aout = pick_saison ; juin-septembre = haute_saison ; avril-mai-octobre = moyenne_saison ; autres mois = basse_saison	Tenir compte de la saison touristique
repeated_guest_cat	is_repeated_guest	1 = Oui ; 0 = Non	Identifier les clients deja venus

(continued)

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
continent	country	Conversion du code pays ISO en continent avec countrycode et regroupement des codes non reconnus	Intermédiaire de construction de l'origine géographique
identity_location	country + continent	Portugal = Local_Portugal ; Europe hors Portugal = Europe_hors_PRT ; autres origines = Other_International	Resumer l'origine géographique du client pour la modélisation




FIGURE 6 – Analyses bivariées en fonction de la variable d'intérêt

\$corr			
	hotel	market_segment	distribution_channel
hotel	1.00000000	0.1443347	0.18780436
market_segment	0.14433466	1.00000000	0.60371814
distribution_channel	0.18780436	0.6037181	1.00000000
customer_type	0.05222287	0.2685087	0.07963108
lead_time_cat	0.12078445	0.2255644	0.18626774
total_nights_cat	0.32582816	0.1638330	0.11138295
adr_cat	0.35228061	0.2530670	0.11892206
has_children	0.05284494	0.1966796	0.08828458
repeated_guest_cat	0.05231868	0.3260096	0.30646313
engagement_cat	0.12730657	0.2784588	0.06699961
previous_cancellations_cat	0.08431119	0.2560578	0.08299575
saison_tourisme	0.06536176	0.1065301	0.06377222
identity_location	0.06711482	0.2997005	0.11266968
	customer_type	lead_time_cat	total_nights_cat
hotel	0.05222287	0.12078445	0.32582816
market_segment	0.26850866	0.22556438	0.16383302
distribution_channel	0.07963108	0.18626774	0.11138295
customer_type	1.00000000	0.09038721	0.11275509

TABLE 15 – Structure générale de la base de données

Indicateur	Valeur
Unite statistique	Une reservation hoteliere
Nombre d'observations initiales	119 390
Nombre de variables initiales	32
Nombre d'observations exclues au nettoyage	827
Nombre d'observations conservees apres nettoyage	118 563
Part de la base conservee	99.3%
Nombre de variables apres engineering	47
Nombre de reservations City Hotel	79 330
Nombre de reservations Resort Hotel	40 060
Variable cible	is_canceled
Reservations non annulees - base initiale	75 166
Reservations annulees - base initiale	44 224
Taux d'annulation - base initiale	37 %
Reservations non annulees - base nettoye	74 388
Reservations annulees - base nettoye	44 175
Taux d'annulation - base nettoye	37.3%
Valeurs manquantes au sens R	4
Variables avec valeurs manquantes	children (4)

lead_time_cat	0.09038721	1.00000000	0.23777394
total_nights_cat	0.11275509	0.23777394	1.00000000
adr_cat	0.12542376	0.09609069	0.10370687
has_children	0.10645540	0.03519385	0.07323415
repeated_guest_cat	0.10731052	0.23869571	0.12922191
engagement_cat	0.04906940	0.08744757	0.06913151
previous_cancellations_cat	0.15757923	0.14145388	0.09930129
saison_tourisme	0.06118281	0.16770766	0.09848127
identity_location	0.05447943	0.11233984	0.16497523
adr_cat has_children repeated_guest_cat			
hotel	0.35228061	0.05284494	0.05231868
market_segment	0.25306696	0.19667961	0.32600964
distribution_channel	0.11892206	0.08828458	0.30646313
customer_type	0.12542376	0.10645540	0.10731052
lead_time_cat	0.09609069	0.03519385	0.23869571
total_nights_cat	0.10370687	0.07323415	0.12922191
adr_cat	1.00000000	0.26809187	0.15677442
has_children	0.26809187	1.00000000	0.03517608
repeated_guest_cat	0.15677442	0.03517608	1.00000000
engagement_cat	0.11650752	0.15081750	0.03753259
previous_cancellations_cat	0.16649439	0.06132199	0.15936156
saison_tourisme	0.25731144	0.12984400	0.06553214
identity_location	0.14391051	0.06756952	0.15921385
engagement_cat previous_cancellations_cat			
hotel	0.12730657		0.08431119
market_segment	0.27845882		0.25605775
distribution_channel	0.06699961		0.08299575
customer_type	0.04906940		0.15757923
lead_time_cat	0.08744757		0.14145388
total_nights_cat	0.06913151		0.09930129
adr_cat	0.11650752		0.16649439
has_children	0.15081750		0.06132199
repeated_guest_cat	0.03753259		0.15936156
engagement_cat	1.00000000		0.17176971
previous_cancellations_cat	0.17176971		1.00000000
saison_tourisme	0.06212260		0.04974956
identity_location	0.17779729		0.26765728
saison_tourisme identity_location			
hotel	0.06536176	0.06711482	
market_segment	0.10653009	0.29970046	
distribution_channel	0.06377222	0.11266968	
customer_type	0.06118281	0.05447943	
lead_time_cat	0.16770766	0.11233984	
total_nights_cat	0.09848127	0.16497523	
adr_cat	0.25731144	0.14391051	
has_children	0.12984400	0.06756952	
repeated_guest_cat	0.06553214	0.15921385	

engagement_cat	0.06212260	0.17779729
previous_cancellations_cat	0.04974956	0.26765728
saison_tourisme	1.00000000	0.03743645
identity_location	0.03743645	1.00000000

\$corrPos

	xName	yName	x	y	corr
1	hotel	hotel	1	13	1.00000000
2	market_segment	hotel	2	13	0.14433466
3	market_segment	market_segment	2	12	1.00000000
4	distribution_channel	hotel	3	13	0.18780436
5	distribution_channel	market_segment	3	12	0.60371814
6	distribution_channel	distribution_channel	3	11	1.00000000
7	customer_type	hotel	4	13	0.05222287
8	customer_type	market_segment	4	12	0.26850866
9	customer_type	distribution_channel	4	11	0.07963108
10	customer_type	customer_type	4	10	1.00000000
11	lead_time_cat	hotel	5	13	0.12078445
12	lead_time_cat	market_segment	5	12	0.22556438
13	lead_time_cat	distribution_channel	5	11	0.18626774
14	lead_time_cat	customer_type	5	10	0.09038721
15	lead_time_cat	lead_time_cat	5	9	1.00000000
16	total_nights_cat	hotel	6	13	0.32582816
17	total_nights_cat	market_segment	6	12	0.16383302
18	total_nights_cat	distribution_channel	6	11	0.11138295
19	total_nights_cat	customer_type	6	10	0.11275509
20	total_nights_cat	lead_time_cat	6	9	0.23777394
21	total_nights_cat	total_nights_cat	6	8	1.00000000
22	adr_cat	hotel	7	13	0.35228061
23	adr_cat	market_segment	7	12	0.25306696
24	adr_cat	distribution_channel	7	11	0.11892206
25	adr_cat	customer_type	7	10	0.12542376
26	adr_cat	lead_time_cat	7	9	0.09609069
27	adr_cat	total_nights_cat	7	8	0.10370687
28	adr_cat	adr_cat	7	7	1.00000000
29	has_children	hotel	8	13	0.05284494
30	has_children	market_segment	8	12	0.19667961
31	has_children	distribution_channel	8	11	0.08828458
32	has_children	customer_type	8	10	0.10645540
33	has_children	lead_time_cat	8	9	0.03519385
34	has_children	total_nights_cat	8	8	0.07323415
35	has_children	adr_cat	8	7	0.26809187
36	has_children	has_children	8	6	1.00000000
37	repeated_guest_cat	hotel	9	13	0.05231868
38	repeated_guest_cat	market_segment	9	12	0.32600964
39	repeated_guest_cat	distribution_channel	9	11	0.30646313
40	repeated_guest_cat	customer_type	9	10	0.10731052

41	repeated_guest_cat	lead_time_cat	9	9	0.23869571
42	repeated_guest_cat	total_nights_cat	9	8	0.12922191
43	repeated_guest_cat	adr_cat	9	7	0.15677442
44	repeated_guest_cat	has_children	9	6	0.03517608
45	repeated_guest_cat	repeated_guest_cat	9	5	1.00000000
46	engagement_cat	hotel	10	13	0.12730657
47	engagement_cat	market_segment	10	12	0.27845882
48	engagement_cat	distribution_channel	10	11	0.06699961
49	engagement_cat	customer_type	10	10	0.04906940
50	engagement_cat	lead_time_cat	10	9	0.08744757
51	engagement_cat	total_nights_cat	10	8	0.06913151
52	engagement_cat	adr_cat	10	7	0.11650752
53	engagement_cat	has_children	10	6	0.15081750
54	engagement_cat	repeated_guest_cat	10	5	0.03753259
55	engagement_cat	engagement_cat	10	4	1.00000000
56	previous_cancellations_cat	hotel	11	13	0.08431119
57	previous_cancellations_cat	market_segment	11	12	0.25605775
58	previous_cancellations_cat	distribution_channel	11	11	0.08299575
59	previous_cancellations_cat	customer_type	11	10	0.15757923
60	previous_cancellations_cat	lead_time_cat	11	9	0.14145388
61	previous_cancellations_cat	total_nights_cat	11	8	0.09930129
62	previous_cancellations_cat	adr_cat	11	7	0.16649439
63	previous_cancellations_cat	has_children	11	6	0.06132199
64	previous_cancellations_cat	repeated_guest_cat	11	5	0.15936156
65	previous_cancellations_cat	engagement_cat	11	4	0.17176971
66	previous_cancellations_cat	previous_cancellations_cat	11	3	1.00000000
67	saison_tourisme	hotel	12	13	0.06536176
68	saison_tourisme	market_segment	12	12	0.10653009
69	saison_tourisme	distribution_channel	12	11	0.06377222
70	saison_tourisme	customer_type	12	10	0.06118281
71	saison_tourisme	lead_time_cat	12	9	0.16770766
72	saison_tourisme	total_nights_cat	12	8	0.09848127
73	saison_tourisme	adr_cat	12	7	0.25731144
74	saison_tourisme	has_children	12	6	0.12984400
75	saison_tourisme	repeated_guest_cat	12	5	0.06553214
76	saison_tourisme	engagement_cat	12	4	0.06212260
77	saison_tourisme	previous_cancellations_cat	12	3	0.04974956
78	saison_tourisme	saison_tourisme	12	2	1.00000000
79	identity_location	hotel	13	13	0.06711482
80	identity_location	market_segment	13	12	0.29970046
81	identity_location	distribution_channel	13	11	0.11266968
82	identity_location	customer_type	13	10	0.05447943
83	identity_location	lead_time_cat	13	9	0.11233984
84	identity_location	total_nights_cat	13	8	0.16497523
85	identity_location	adr_cat	13	7	0.14391051
86	identity_location	has_children	13	6	0.06756952
87	identity_location	repeated_guest_cat	13	5	0.15921385

```

88      identity_location      engagement_cat 13  4 0.17779729
89      identity_location previous_cancellations_cat 13  3 0.26765728
90      identity_location      saison_tourisme 13  2 0.03743645
91      identity_location      identity_location 13  1 1.00000000

```

```

$arg
$arg$type
[1] "upper"

```

9.2 Objectif de l'étude et démarche choisie




FIGURE 7 – Démarche de modélisation

TABLE 17 – Synthèse des contrôles et traitements de cohérence

Critère	Effectif	Pourcentage	Décision
ADR extreme superieur a 1000	1	0.00%	Exclu
ADR negatif	1	0.00%	Exclu
Aucun client renseigne	180	0.15%	Exclu
Sejour de 0 nuit	645	0.54%	Exclu
Conserve	118563	99.31%	Conserve

9.3 Annexe - Analyse discriminante sur variables qualitatives

9.3.1 Inertie des axes factoriels

9.3.2 Représentation et interpretation des axes

9.3.2.1 Axe 3 : nature du sejour et saisonnalite




FIGURE 8 – Décroissance de l'inertie de l'ensemble des axes ACM

L'axe 3 oppose des profils `market_segment = Corporate`, `identity_location = Other_International` et `saison_tourisme = basse_saison` à des profils `customer_type = Contract`, `total_nights_cat = long_sejour` et `hotel = Resort Hotel`.

Interpretation métier : cet axe distingue une logique plus professionnelle/internationale ou basse saison d'une logique plus touristique, resort et long séjour. Il structure donc les motivations probables du séjour. Cette distinction est importante car une réservation business, un séjour resort et un long séjour ne portent pas les mêmes contraintes d'annulation.

9.3.2.2 Axe 4 : volatilité opérationnelle autour du séjour

L'axe 4 oppose `customer_type = Group`, `total_nights_cat = long_sejour` et `customer_type = Contract` à `previous_cancellations_cat = Une_ou_plus`, `has_children = Oui` et `lead_time_cat = derniere_minute`. Les contributions de `adr_cat = q4_high`, `saison_tourisme = basse_saison`, `saison_tourisme = pick_saison`, `total_nights_cat = court_sejour` et `hotel = Resort Hotel` montrent que cet axe combine prix, saison et structure du séjour.

Interpretation métier : cet axe capte une forme de volatilité opérationnelle. Les réservations courtes, chères, saisonnières ou associées à un historique d'annulation peuvent être plus difficiles à stabiliser. La position de `is_canceled_Oui` sur cet axe confirme que cette dimension contient une information pertinente pour la prédiction.

9.3.2.3 Axe 5 : canal, prix et saison

L'axe 5 oppose `market_segment = Other`, `engagement_cat = fort` et `has_children = Oui` à custo-

Plan factoriel 3-4

Modalites actives labellisees par variable d'origine et cible projetee




FIGURE 9 – Plan factoriel 3-4 avec modalites labellisees




FIGURE 10 – Plan factoriel 1-5 avec modalités labellisées

mer_type = Group, customer_type = Contract et lead_time_cat = derniere_minute. Les contributions de market_segment = Other, market_segment = Offline_TA, adr_cat = q3_midhigh, saison_tourisme = haute_saison et lead_time_cat = derniere_minute indiquent que cet axe combine canal, niveau de prix et saison.

Interpretation metier : cet axe affine la lecture du risque en distinguant des profils commerciaux et saisonniers. Il ne represente pas un seul facteur simple, mais une combinaison de contexte de reservation, de prix et de periode touristique.

Modalites structurantes des axes ACM




FIGURE 11 – Modalites les plus contributives aux premiers axes

Les contributions indiquent quelles modalites construisent vraiment chaque axe. Une modalite peut etre eloignee du centre sans etre la plus structurante; inversement, une modalite fortement contributive doit etre integree a l'interpretation de l'axe.

9.3.3 Tests statistiques sur les axes de l'ACM

TABLE 18 – Tests de Shapiro-Wilk sur les axes ACM candidats

Axe	Statistique	p-value	Conclusion
Dim 1	0.9791	0.0000	Normalite rejetee
Dim 2	0.9435	0.0000	Normalite rejetee
Dim 3	0.9627	0.0000	Normalite rejetee
Dim 4	0.9970	0.0007	Normalite rejetee
Dim 5	0.9965	0.0001	Normalite rejetee
Dim 6	0.9624	0.0000	Normalite rejetee
Dim 7	0.9980	0.0163	Normalite rejetee
Dim 8	0.9926	0.0000	Normalite rejetee
Dim 9	0.9065	0.0000	Normalite rejetee
Dim 10	0.9962	0.0001	Normalite rejetee
Dim 11	0.7692	0.0000	Normalite rejetee
Dim 12	0.9616	0.0000	Normalite rejetee
Dim 13	0.9788	0.0000	Normalite rejetee
Dim 14	0.9955	0.0000	Normalite rejetee
Dim 15	0.9876	0.0000	Normalite rejetee
Dim 16	0.9970	0.0007	Normalite rejetee
Dim 17	0.9930	0.0000	Normalite rejetee
Dim 18	0.9874	0.0000	Normalite rejetee
Dim 19	0.9427	0.0000	Normalite rejetee
Dim 20	0.9928	0.0000	Normalite rejetee
Dim 21	0.9989	0.2509	Normalite non rejetee
Dim 22	0.9964	0.0001	Normalite rejetee
Dim 23	0.9975	0.0026	Normalite rejetee
Dim 24	0.9960	0.0000	Normalite rejetee
Dim 25	0.9987	0.1302	Normalite non rejetee
Dim 26	0.9964	0.0001	Normalite rejetee

TABLE 19 – Tests de normalite multivariee sur les axes ACM candidats

Test	Statistic	p.value	Method	MVN	conclusion
Mardia Skewness	151806.120	<0.001	asymptotic	Non normale	Normalite multivariee rejetee
Mardia Kurtosis	187.651	<0.001	asymptotic	Non normale	Normalite multivariee rejetee
Henze-Zirkler	2.485	<0.001	asymptotic	Non normale	Normalite multivariee rejetee

TABLE 20 – Test de Box M pour l'homogeneite des matrices de covariance

Test	Statistique	Degres de liberte	p-value	Conclusion
Box M	149357	351	0	Homogeneite des covariances rejetee

9.3.4 Choix du nombre d'axes et du classifieur

TABLE 21 – AUC de validation selon le nombre d'axes ACM et le modèle

Nombre d'axes	LDA	QDA	KNN k = 5	KNN k = 15	KNN k = 26
1	0.6089	0.6089	0.8496	0.8468	0.8267
2	0.6777	0.7011	0.8558	0.859	0.844
3	0.6787	0.6988	0.8558	0.855	0.8404
4	0.7184	0.7562	0.8577	0.8676	0.8596
5	0.7353	0.7606	0.8646	0.8731	0.8649
7	0.7714	0.7998	0.8656	0.8815	0.8783
10	0.7993	0.8196	0.8699	0.8838	0.8818
15	0.8394	0.8368	0.8707	0.8862	0.8842
20	0.8621	0.8461	0.8716	0.8865	0.8843
26	0.8753	0.8582	0.8751	0.8924	0.8915




FIGURE 12 – AUC de validation selon le nombre d'axes ACM et le modèle




FIGURE 13 – F1-score de validation selon le nombre d'axes ACM et le modèle