



Conservatoire National des Arts et Métiers

Projet STA201 : Analyse multivariée approfondie

Etude de cas : Annulations de réservations hôtelières

Auteurs : ASSAL HAMZA
TRAORE SAH
Date : 17-05-2026

Table des matières

1	Présentation des bases théoriques des deux approches	3
1.1	Première approche : Régression logistique	3
1.1.1	Sélection de variables	3
1.1.2	Régression logistique pénalisée	4
1.1.3	Stratégie d'évaluation des modèles	5
1.2	Deuxième approche : Analyse discriminante sur variables qualitatives	5
1.2.1	Analyse discriminante linéaire	6
1.2.2	Analyse discriminante quadratique	7
1.2.3	Méthode des k plus proches voisins	7
1.2.4	Hypothèses et validation	7
2	Introduction, problématique et base de données	9
2.1	Présentation des variables importantes à l'étude	9
3	Description des données, prétraitements et statistiques descriptives	10
3.1	Nettoyage et cohérence des données et data engenering	10
3.2	Analyse statistique élémentaire	10
4	Objectif de l'étude et démarche choisie	12
5	Résultats et interprétations de la première méthode : régression logistique	13
5.1	Stratégie de modélisation	13
5.2	Construction de l'ACM et interpretation des axes	13
5.2.1	Role de l'ACM dans la methode DISQUAL	13
5.2.2	Inertie des axes factoriels	14
5.2.3	Représentation et interpretation des axes	14
5.3	Tests statistiques sur les axes de l'ACM	16
5.4	Choix du meilleur modèle et du nombre d'axes optimum	16
5.5	Choix du seuil de classification	17
6	Comparaison des résultats et conclusion	18
7	Sources des données et références	19

8	Annexes	20
8.1	Tableaux complémentaires	20
8.2	Objectif de l'étude et démarche choisie	21
8.3	Annexe - Analyse discriminante sur variables qualitatives	21
8.3.1	Inertie des axes factoriels	21
8.3.2	Représentation et interpretation des axes	26
8.3.3	Tests statistiques sur les axes de l'ACM	29
8.3.4	Choix du nombre d'axes et du classifieur	30

1 Présentation des bases théoriques des deux approches

1.1 Première approche : Régression logistique

La régression logistique est une méthode de classification supervisée utilisée lorsque la variable à expliquer est qualitative, le plus souvent binaire. Elle permet d'estimer la probabilité qu'un individu appartienne à une modalité d'intérêt à partir d'un ensemble de variables explicatives quantitatives ou qualitatives. Lorsque les variables explicatives sont qualitatives, elles sont généralement transformées en variables indicatrices afin d'être intégrées au modèle.

L'objectif du modèle est d'estimer la probabilité conditionnelle de réalisation de l'événement : $P(Y = 1 | X) = p(X)$ où X représente l'ensemble des variables explicatives.

Contrairement à une régression linéaire classique, la probabilité estimée doit nécessairement rester comprise entre 0 et 1. Pour cette raison, la régression logistique utilise la fonction logit, qui transforme la probabilité en logarithme des chances, ou log-odds :

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

avec :

$p(X)$: la probabilité de réalisation de l'événement ;

β_0 : la constante du modèle ;

β_j : le coefficient associé à la variable explicative X_j ;

p : le nombre de variables explicatives intégrées au modèle.

Les coefficients sont généralement estimés par maximisation de la vraisemblance. L'interprétation des paramètres se fait souvent à partir des odds ratios, obtenus en exponentiant les coefficients : $OR_j = e^{\beta_j}$

Un odds ratio supérieur à 1 indique que la variable est associée à une augmentation des chances de réalisation de l'événement. À l'inverse, un odds ratio inférieur à 1 indique une diminution des chances de réalisation de l'événement. Lorsque l'odds ratio est proche de 1, l'effet de la variable est faible ou limité.

1.1.1 Sélection de variables

Dans un modèle comportant un nombre important de variables explicatives, une étape de sélection de variables peut être nécessaire. Elle vise à construire un modèle plus parcimonieux, c'est-à-dire un modèle qui conserve un nombre réduit de variables tout en maintenant un bon niveau de performance prédictive.

Les méthodes classiques de sélection reposent notamment sur des procédures dites stepwise. Trois approches sont généralement utilisées :

la sélection ascendante, ou forward, qui part d'un modèle vide puis ajoute progressivement les variables les plus pertinentes ;

la sélection descendante, ou backward, qui part du modèle complet puis retire progressivement les variables les moins pertinentes ;

la sélection mixte, qui combine les deux logiques précédentes.

Ces procédures peuvent s'appuyer sur des critères statistiques tels que l'AIC, le BIC ou la significativité des coefficients. Néanmoins, elles peuvent devenir instables en présence de variables fortement corrélées ou lorsque le nombre de variables est important. Dans notre contexte, les modèles pénalisés sont étudiés constituent une alternative pertinente.

1.1.2 Régression logistique pénalisée

Les méthodes de régression pénalisée consistent à modifier la fonction d'optimisation du modèle en ajoutant une contrainte sur les coefficients. L'objectif est de réduire la complexité du modèle, de limiter le surapprentissage et d'améliorer la capacité de généralisation sur des données nouvelles.

Dans le cadre d'une régression logistique classique, les coefficients sont estimés en maximisant la vraisemblance. Dans une régression pénalisée, on ajoute un terme de pénalisation à cette même fonction. De manière générale, le problème peut s'écrire sous la forme suivante :

$$\min_{\beta} [-\log L(\beta) + \text{Pénalité}(\beta)]$$

où $L(\beta)$ représente la vraisemblance du modèle et $\text{Pénalité}(\beta)$ le terme de régularisation appliqué aux coefficients.

1.1.2.1 Ridge

La régression ridge applique une pénalisation de norme L_2 sur les coefficients :

$$\min_{\beta} \left[-\log L(\beta) + \lambda \sum_{j=1}^p \beta_j^2 \right]$$

Le paramètre λ contrôle l'intensité de la pénalisation. Plus λ est élevé, plus les coefficients sont contraints vers zéro. La méthode ridge réduit la magnitude des coefficients sans les annuler complètement. Elle est particulièrement utile en présence de multicollinéarité, car elle stabilise les estimations lorsque plusieurs variables explicatives portent une information similaire.

1.1.2.2 Lasso

La méthode lasso repose sur une pénalisation de norme L_1 : $\min_{\beta} [-\log L(\beta) + \lambda \sum_{j=1}^p |\beta_j|]$

Contrairement au ridge, le lasso peut ramener certains coefficients exactement à zéro. Il réalise donc simultanément une régularisation du modèle et une sélection automatique de variables. Cette propriété est particulièrement intéressante lorsque le nombre de variables explicatives est élevé ou lorsque certaines variables apportent peu d'information au modèle.

1.1.2.3 Elastic net

L'elastic net combine les deux types de pénalisation, ridge et lasso :

$$\min_{\beta} \left[-\log L(\beta) + \lambda \left((1 - \alpha) \sum_{j=1}^p \beta_j^2 + \alpha \sum_{j=1}^p |\beta_j| \right) \right]$$

Le paramètre α contrôle l'équilibre entre les deux pénalisations :

$\alpha = 0$ correspond à une pénalisation ridge ; $\alpha = 1$ correspond à une pénalisation lasso ; $0 < \alpha < 1$ correspond à un compromis elastic net.

Cette approche est adaptée lorsque plusieurs variables sont corrélées entre elles. Elle combine la stabilité du ridge et la capacité de sélection du lasso.

1.1.3 Stratégie d'évaluation des modèles

L'évaluation du modèle repose sur plusieurs indicateurs issus de la matrice de confusion. L'accuracy mesure la proportion globale de bonnes classifications, mais elle peut être insuffisante lorsque les classes sont déséquilibrées ou lorsque l'on s'intéresse davantage à une classe particulière. La sensibilité, ou recall, mesure la proportion d'individus de la classe d'intérêt correctement détectés. La spécificité mesure la proportion d'individus de l'autre classe correctement reconnus. La précision indique, parmi les individus prédits dans la classe d'intérêt, la proportion qui appartient réellement à cette classe. Le F1-score combine précision et sensibilité, tandis que l'AUC mesure la capacité globale du modèle à séparer les classes indépendamment d'un seuil particulier.

Pour l'évaluation de la calibration du modèle, le score de Brier est privilégié au test de Hosmer-Lemeshow, compte tenu de la sensibilité extrême de ce dernier en présence d'un échantillon de grande taille. Le score de Brier donne ainsi mesure plus stable et plus lisible dans ce contexte. Il est défini par : $\text{Brier} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2$ où $\hat{p}_i$ désigne la probabilité prédite d'annulation pour l'observation i , et y_i vaut 1 si la réservation est annulée et 0 sinon. Plus ce score est faible, meilleure est la qualité probabiliste du modèle.

La régression logistique présente plusieurs avantages : elle est relativement simple à mettre en œuvre, interprétable, adaptée à une variable cible binaire et compatible avec des variables explicatives de nature variée. Ses limites tiennent notamment à l'hypothèse d'une relation linéaire entre les variables explicatives et le logit de la probabilité, à la sensibilité aux valeurs extrêmes, à la multicolinéarité et aux situations de séparation quasi parfaite.

1.2 Deuxième approche : Analyse discriminante sur variables qualitatives

La méthode DISQUAL, développée dans la tradition de l'analyse des données de Saporta, est une méthode de discrimination adaptée aux variables qualitatives. Elle repose sur deux étapes principales : d'abord une Analyse des Correspondances Multiples (ACM), puis une méthode de classification supervisée appliquée aux coordonnées factorielles obtenues.

Soit un échantillon de n individus décrits par p variables qualitatives. Les données sont d'abord transformées en tableau disjonctif complet Z , dans lequel chaque modalité est codée par une indicatrice binaire. L'ACM permet ensuite de projeter les individus dans un espace factoriel continu. Chaque individu i est alors représenté par un vecteur de coordonnées :

$$F_i = (f_{i1}, f_{i2}, \dots, f_{iK}),$$

où f_{ik} désigne la coordonnée de l'individu i sur l'axe factoriel k . Ces coordonnées deviennent les variables explicatives utilisées par les modèles de classification. En pratique, seuls les axes les plus informatifs sont conservés afin de limiter le bruit et le risque de sur-ajustement.

Dans une démarche prédictive rigoureuse, l'ACM doit être estimée uniquement sur la base d'entraînement. Les bases de validation et de test sont ensuite projetées comme individus supplémentaires. Cette précaution évite une fuite d'information, car les axes utilisés pour entraîner le modèle ne doivent pas être construits à partir d'observations servant ensuite à évaluer sa performance.

1.2.1 Analyse discriminante linéaire

La LDA, ou analyse discriminante linéaire, trouve son origine dans les travaux de Fisher. Il s'agit d'un classifieur probabiliste fondé sur le théorème de Bayes. On suppose que, conditionnellement à la classe $Y = k$, le vecteur explicatif X suit une loi normale multivariée :

$$X \mid Y = k \sim \mathcal{N}(\mu_k, \Sigma).$$

L'hypothèse centrale de la LDA est que les classes partagent une même matrice de covariance Σ , mais possèdent des moyennes différentes μ_k . Pour un individu décrit par un vecteur x , la règle de décision consiste à choisir la classe maximisant la probabilité a posteriori $P(Y = k \mid X = x)$. En appliquant la formule de Bayes, cette probabilité est proportionnelle au produit de la densité conditionnelle et de la probabilité a priori :

$$P(Y = k \mid X = x) \propto \pi_k f_k(x),$$

où π_k désigne la probabilité a priori de la classe k . Sous l'hypothèse d'une covariance commune, le logarithme de cette quantité conduit à la fonction discriminante linéaire :

$$\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log(\pi_k).$$

L'individu est affecté à la classe dont le score $\delta_k(x)$ est le plus élevé. Dans le cas de deux classes, la frontière de décision est une droite, ou plus généralement un hyperplan. Appliquée à DISQUAL, la LDA ne travaille donc pas directement sur les variables qualitatives initiales, mais sur les axes factoriels issus de l'ACM.

1.2.2 Analyse discriminante quadratique

La QDA, ou analyse discriminante quadratique, repose sur la même logique bayésienne que la LDA, mais relâche l'hypothèse d'égalité des matrices de covariance. On suppose alors :

$$X | Y = k \sim \mathcal{N}(\mu_k, \Sigma_k).$$

Chaque classe possède donc sa propre matrice de covariance Σ_k . La fonction discriminante devient :

$$\delta_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) + \log(\pi_k).$$

La frontière de décision entre deux classes n'est plus linéaire mais quadratique. La QDA est donc plus flexible que la LDA : elle peut représenter des séparations plus complexes lorsque les classes ont des dispersions différentes dans l'espace factoriel. Cette flexibilité a cependant un coût, car il faut estimer une matrice de covariance par classe. La QDA peut ainsi devenir instable lorsque le nombre d'axes conservés est élevé ou lorsque certaines classes sont peu représentées.

1.2.3 Méthode des k plus proches voisins

Le KNN, ou méthode des k plus proches voisins, adopte une logique différente de la LDA et de la QDA. Il ne suppose pas de distribution normale, ni de forme paramétrique de la frontière de décision. C'est une méthode non paramétrique fondée sur la proximité entre individus.

Pour prédire la classe d'un nouvel individu x , on calcule sa distance aux individus de la base d'entraînement dans l'espace des axes ACM. On retient ensuite les k individus les plus proches. La probabilité prédite d'annulation peut être estimée par la proportion de voisins appartenant à la classe d'annulation :

$$\widehat{P}(Y = 1 | X = x) = \frac{1}{k} \sum_{i \in N_k(x)} \mathbf{1}(Y_i = 1),$$

où $N_k(x)$ désigne l'ensemble des k plus proches voisins de x . L'individu est ensuite classé comme annulé si cette probabilité dépasse un seuil donné, par exemple 0,50, ou un seuil optimisé sur validation.

Le choix de k est crucial. Une faible valeur de k produit un modèle très local, sensible au bruit et aux observations atypiques. Une grande valeur de k lisse davantage la décision, ce qui peut améliorer la stabilité mais réduire la capacité à détecter des profils spécifiques. Dans le cadre DISQUAL, le KNN est particulièrement pertinent car les distances sont calculées dans un espace factoriel continu résumant les profils qualitatifs.

1.2.4 Hypothèses et validation

La LDA et la QDA reposent sur une hypothèse de normalité multivariée des coordonnées ACM conditionnellement aux classes. La LDA suppose en plus l'égalité des matrices de covariance. Ces hypothèses peuvent être étudiées à l'aide de tests de normalité et du test de Box. Toutefois,

elles sont rarement parfaitement vérifiées en pratique, surtout lorsque les variables initiales sont qualitatives.

Ainsi, la LDA et la QDA peuvent être utilisées à la fois comme modèles probabilistes et comme classifieurs empiriques. Le choix final entre LDA, QDA et KNN doit donc reposer principalement sur la performance observée sur validation et sur test. Les paramètres importants, notamment le nombre d'axes ACM, le nombre de voisins k et le seuil de classification, doivent être sélectionnés sans utiliser la base de test afin de garantir une évaluation non biaisée.

2 Introduction, problématique et base de données

##Présentation de la base

Notre étude s'appuie sur la base de données *Hotel Booking Demand Datasets*, construite afin d'analyser le comportement d'annulation des réservations dans le secteur hôtelier. Cette base a notamment été diffusée sur Kaggle et documentée dans un article scientifique publié dans la revue *Data in Brief*. Les informations détaillées sur l'origine des données sont précisées dans la section Section 7.

La base contient 119 390 réservations provenant de deux types d'hôtels *Resort Hotel* et *City Hotel*. Chaque observation correspond à une réservation hôtelière, qu'elle ait donné lieu à un séjour effectif ou à une annulation.

La variable d'intérêt de notre étude est donc la variable indicatrice d'annulation, notée `is_canceled`, qui prend la valeur 1 lorsque la réservation a été annulée et 0 sinon.

La base de données ne contient pas de valeurs manquantes. Toutefois, certaines variables catégorielles, peuvent prendre la valeur « NULL ». Cette valeur ne correspond pas à une donnée absente, mais indique simplement que l'information n'est pas applicable. Par exemple, une valeur « NULL » pour la variable `children` signifie que la réservation ne comporte pas d'enfant.

2.1 Présentation des variables importantes à l'étude

Les principales variables utilisées dans l'étude sont décrites en Annexe, dans le Tableau Table 8. Elles couvrent la nature de l'hôtel, la variable cible `is_canceled`, les caractéristiques temporelles de la réservation, la composition du séjour, le canal de réservation, le prix moyen journalier et les demandes particulières du client.

3 Description des données, prétraitements et statistiques descriptives

La structure générale de la base est résumée en Annexe dans le Tableau Table 9.

3.1 Nettoyage et cohérence des données et data engenering

Avant l'analyse statistique et la modélisation, plusieurs contrôles ont été réalisés afin de sécuriser l'utilisation de la base. L'objectif étant de conserver l'information disponible tout en traitant les situations susceptibles de produire des incohérences dans les variables construites ou dans les modèles.

La synthèse chiffrée de ces contrôles et décisions est présentée en Annexe dans le Tableau Table 11.

À l'issue de ces traitements, la base d'analyse contient 118563 observations. Ensuite, de grands travaux de data engenering ont été opéré sur la base de compréhension métier de la problématique et des analyses statistiques.

Certaines variables initiales ont été transformé en indicateurs plus directement exploitables pour l'analyse. Plusieurs variables synthétiques ont été construites afin de rendre les résultats plus lisibles, de limiter le nombre de modalités et de disposer de profils interprétables.

Ces variables portent notamment sur le délai de réservation, la durée du séjour, le niveau de prix, la présence d'enfants, l'engagement du client, l'historique d'annulation, la saison touristique et l'origine géographique du client. La variable cible `is_canceled` a également été recodée sous forme factorielle avec les modalités `Non` et `Oui`, ce qui permet une lecture homogène des sorties descriptives et prédictives.

Ainsi, nous avons l'exemple de `lead_time` devient : `lead_time_cat` = (“derniere_minute”, “court”, “moyen”, “long”, “tres_long”), qui mesure d'une façon plus différenciée la durée entre la reservation et la date d'arrivée.

Aussi les variables `total_of_special_requests`, `booking_changes`, `parking` deviennent `engagement_cat` qui mesure l'investissement envers la reservation.

L'exhaustivité des variables construites et leurs détails sont dans le Tableau Table 10.

3.2 Analyse statistique élémentaire

Notre variable d'intérêt “`is_canceled`” présente 37% des reservations annulées, ce qui reste un niveau élevé d'ou l'importance de ce type d'étude et qui nous donne une base relativement équilibrée entre les deux modalités.

Nous faisons un focus sur deux des variables créées à savoir le délai de réservation et l'engagement client. d'après l'analyse bivariée en figure Figure 1 on constat que plus le délai de reservation est long plus la probabilité d'annulation augmente. Aussi un fort engagement du client traduit par une faible probabilité d'annulation.

Vous trouverez un panorama des statistiques bivariées avec notre variable d'intérêt en annexe @final_bivariate_plot_all




FIGURE 1 – stat desc

Aussi une étude de corrélation entre les variables a été faite sur la base du V de cramer. Nous en déduisons une corrélation faible entre la majorité des variables ($V\text{-cramer} < 0.2$). Toutefois quelques variables présentent une forte corrélation (exemple entre *market_segment* et *distribution_channel* => $\text{cramer_v} = 0.604$). Ce constat nous a mené à arbitrer entre ces deux variables. L'ensemble de la matrice des associations est détaillé sur la figure Figure 5 en annexe.

TABLE 1 – Variables retenues pour les modélisations

Variable	Modalité	Rôle dans l'analyse
is_canceled	Non ; Oui	Variable cible à prédire
hotel	City Hotel ; Resort Hotel	Distinguer City Hotel et Resort Hotel
market_segment	Direct ; Online_TA ; Offline_TA ; Corporate ; Other	Caractériser le canal commercial de réservation
customer_type	Contract ; Group ; Transient ; Transient-Party	Distinguer les profils de clients selon le type de réservation
lead_time_cat	derniere_minute ; court ; moyen ; long ; tres_long	Mesurer l'anticipation de la réservation
total_nights_cat	court_sejour ; moyen_sejour ; long_sejour	Regrouper les durées de séjour
adr_cat	q1_low ; q2_midlow ; q3_midhigh ; q4_high	Comparer les niveaux de prix
has_children	Non ; Oui	Identifier les réservations familiales
engagement_cat	faible ; moyen ; fort	Comparer les niveaux d'engagement
previous_cancellations_cat	Non ; Une_ou_plus	Capturer l'historique d'annulation
saison_tourisme	basse_saison ; moyenne_saison ; haute_saison ; pick_saison	Tenir compte de la saison touristique
identity_location	Europe_hors_PRT ; Local_Portugal ; Other_International	Resumer l'origine géographique du client pour la modélisation

4 Objectif de l'étude et démarche choisie

L'objectif opérationnel du projet est de mieux identifier les réservations susceptibles d'être annulées. La démarche retenue consiste, après avoir construit des variables qualitatives interprétables, à mobiliser deux méthodes : la régression logistique, pour estimer une probabilité d'annulation et interpréter l'effet des facteurs explicatifs, et l'analyse discriminante sur variables qualitatives, pour étudier la discrimination entre les profils de réservations annulées et non annulées.

Pour les deux méthodes nous avons retenues 12 variables qualitatives qui nous semblent les plus pertinentes pour l'étude présentées dans le Tableau Table 1.

En ce qui concerne la démarche de modélisation, la base de données a été divisée en trois sous-échantillons : une base d'entraînement (base train) contenant 50 % des observations, une base de validation contenant 25 % des observations et une base test contenant les 25 % restants. Ce découpage a été réalisé à l'aide d'un échantillonnage stratifié selon la variable cible.

Pour chaque méthode, les modèles ont d'abord été construits à partir de la base d'entraînement. Le choix du meilleur modèle a ensuite été effectué sur la base des performances observées sur la base de validation.

Une fois le modèle optimal sélectionné, celui-ci a été réestimé sur l'ensemble des données d'entraînement et de validation (soit 75 % des données). Enfin, l'évaluation finale des performances a été réalisée exclusivement sur la base test, laquelle n'a été utilisée ni pour la construction ni pour la sélection des modèles.

La figure Figure 6 en annexe présente la démarche suivie pour la modélisation.

5 Résultats et interprétations de la première méthode : régression logistique

acompleter

Résultats de la deuxième méthode : analyse discriminante sur variables qualitatives

Cette partie présente l'application de la méthode DISQUAL à notre problème de prédiction des annulations. L'idée générale consiste à transformer les variables qualitatives en axes factoriels continus à l'aide d'une ACM, puis à utiliser ces axes comme variables explicatives dans des modèles de classification. Nous comparerons donc trois modèles construits sur les axes ACM : la LDA, la QDA et le KNN.

5.1 Stratégie de modélisation

L'analyse discriminante sera construite dans une logique strictement prédictive. Comme pour le modèle logistique Les mêmes bases : train, validation et test ont été utilisées. La base train sert à apprendre la représentation factorielle et les modèles ; la base validation sert à choisir le meilleur modèle et le nombre d'axes optimum pour la prédiction, le type de modèle et le seuil de classification ; la base test reste réservée à l'évaluation finale.

La sélection du modèle se fait en deux temps. Premièrement, on compare plusieurs nombres d'axes ACM et plusieurs modèles à partir de l'AUC sur validation. L'AUC est utilisée à cette étape car elle évalue la capacité de séparation du modèle indépendamment d'un seuil de classification particulier.

Deuxièmement, une fois le meilleur couple modèle / nombre d'axes retenu, le seuil de classification est optimisé sur validation, principalement à partir du F1-score afin de mieux équilibrer précision et rappel sur la classe des réservations annulées.

Après cette sélection, le modèle final est recalibré en utilisant train + validation pour l'ACM finale. La base test est alors projetée en individu supplémentaire, puis utilisée une seule fois pour mesurer la performance finale. Cette stratégie permet d'utiliser d'avantage de données pour le modèle final tout en conservant une évaluation précise et stricte sur la base test.

5.2 Construction de l'ACM et interpretation des axes

5.2.1 Role de l'ACM dans la methode DISQUAL

L'analyse des correspondances multiples (ACM) est l'étape qui transforme les variables qualitatives en axes factoriels continus. Dans notre cas, les variables explicatives sont des profils de reservation : type d'hotel, segment de marche, type de client, delai de reservation, duree du sejour, niveau de prix, presence d'enfants, engagement, historique d'annulation, saison touristique et origine du client.

L'ACM permet donc de passer d'une lecture variable par variable à une lecture en **profils**. Chaque axe oppose des combinaisons de modalites.

TABLE 2 – Inertie des premiers axes de l'ACM

Axe	Valeur propre	Inertie (%)	Inertie cumulee (%)
dim 1	0.2229137	9.43	9.43
dim 2	0.1715162	7.26	16.69
dim 3	0.1470762	6.22	22.91
dim 4	0.1296038	5.48	28.39
dim 5	0.1106199	4.68	33.07

La variable cible `is_canceled` est ajoutée comme variable qualitative supplémentaire. Elle ne participe donc pas à la construction des axes, mais elle est projetée sur ces axes pour vérifier si les profils factoriels sont liés au risque d'annulation.

5.2.2 Inertie des axes factoriels

L'inertie indique la part de structure du tableau disjonctif expliquée par chaque axe. L'inertie expliquée par les 5 premiers axes (33%) est représentée dans le tableau ci dessous.

On note que nous avons 26 axes au total. En annexe, la représentation de l'inertie de l'ensemble des axes dans la figure [Figure 7](#)

5.2.3 Représentation et interpretation des axes

La représentation graphique suivante affiche les modalités les plus contributives sur les deux premiers axes factoriels. Les libelles utilisent la forme `variable = modalite`. La cible est ajoutée en bleu comme variable supplémentaire. Ainsi, le graphique montre à la fois la structure des profils et la position descriptive de l'annulation.




FIGURE 2 – Plan factoriel 1-2 avec modalites labellisees

Nous pouvons ainsi interpréter précisément les axes obtenus :

5.2.3.1 Axe 1 : engagement apparent contre risque historique et canal de réservation

L'axe 1 oppose, du côté négatif, des réservations à engagement apparent fort, caractérisées notamment par la présence d'enfants, un prix élevé et un niveau d'engagement important, à des profils situés du côté positif, davantage marqués par un historique d'annulation, certains segments de marché et des canaux de réservation spécifiques. La projection de `is_canceled = Oui` du côté positif suggère que les annulations sont descriptivement plus associées aux profils présentant un risque historique ou commercial qu'aux réservations traduisant un engagement plus fort dans le séjour.

5.2.3.2 Axe 2 : temporalité de réservation et mode de commercialisation

L'axe 2 traduit principalement une opposition liée au délai de réservation et au mode de commercialisation. Il distingue les réservations très anticipées ou intermédiées par des canaux offline, associées notamment aux clients contractuels, des réservations de dernière minute, corporate ou de groupe. D'un point de vue métier, cet axe montre que le risque d'annulation dépend fortement de la combinaison entre temporalité de décision, canal de réservation et type de client. .

Une représentation des autres axes 3,4 et 5 est en annexe Figure 8 et Figure 9 ainsi que des modalités structurantes sur chaque axe sur Figure 10

TABLE 3 – Meilleure performance de validation par famille de modèle

Modèle	Axes	k	AUC	Accuracy	Recall	Spécificité	Précision	F1-score	Balanced accuracy
ACM + KNN	26	15	0.8924	0.8199	0.6777	0.9044	0.8081	0.7372	0.791
ACM + KNN	26	26	0.8915	0.8158	0.6583	0.9094	0.8118	0.727	0.7838
ACM + LDA	26	-	0.8753	0.8128	0.6923	0.8844	0.7805	0.7338	0.7884
ACM + KNN	26	5	0.8751	0.8144	0.7018	0.8813	0.7783	0.7381	0.7916
ACM + QDA	26	-	0.8582	0.7388	0.8653	0.6638	0.6045	0.7117	0.7645

TABLE 4 – Synthèse de la recherche du paramètre k pour le KNN

k	Meilleure AUC	Meilleur F1-score	Nombre d'axes associé à la meilleure AUC
15	0.8924	0.7372	26
26	0.8915	0.7297	26
5	0.8751	0.7396	26

5.3 Tests statistiques sur les axes de l'ACM

Avant la grid search, nous évaluons les hypothèses statistiques associées aux axes factoriels issus de l'ACM, construits uniquement sur la base d'entraînement. Cette étape permet de vérifier dans quelle mesure les axes utilisés comme variables explicatives sont compatibles avec les hypothèses de l'analyse discriminante.

La normalité est étudiée à deux niveaux : axe par axe avec le test de Shapiro-Wilk, puis globalement avec les tests multivariés de Mardia et de Henze-Zirkler. L'homogénéité des matrices de covariance entre les deux classes de `is_canceled` est vérifiée avec le test de Box's M. Les résultats détaillés de ces diagnostics sont présentés dans les tableaux Table 12, Table 13 et Table 14.

Ces tests ne déterminent pas directement le modèle final, mais ils éclairent la validité théorique de la LDA et de la QDA. Si la normalité ou l'homogénéité des covariances sont rejetées, les modèles restent utilisables comme classifieurs prédictifs, mais leur interprétation probabiliste doit être nuancée. Le choix final repose donc principalement sur la performance observée en validation, via la sélection du nombre d'axes, du modèle et du seuil de classification.

5.4 Choix du meilleur modèle et du nombre d'axes optimum

Le nombre d'axes ACM ne doit pas être choisi uniquement à partir de l'inertie factorielle. Dans notre cadre, l'objectif est prédictif : nous cherchons le nombre d'axes qui améliore réellement la capacité à distinguer les réservations annulées des réservations non annulées. Pour cette raison, une grille de recherche est appliquée sur la base validation.

La grille compare plusieurs nombres d'axes pour la LDA, la QDA et le KNN. Pour le KNN, plusieurs valeurs de `k` sont aussi testées. Ce paramètre correspond au nombre de voisins utilisés pour classer une réservation.

En voici un tableau récapitulatif :

Une première lecture des résultats de validation conduirait à retenir directement le modèle présentant la meilleure AUC dans le Tableau en annexe Table 15. Dans notre cas, il s'agit du modèle KNN avec `k = 15` et 26 axes ACM. Toutefois, notre objectif n'est pas uniquement de maximiser la performance apparente sur validation : nous cherchons aussi à conserver un modèle parcimonieux,

TABLE 5 – Gains marginaux d’AUC selon le nombre d’axes pour le KNN retenu

Nombre d’axes	k KNN	AUC	Gain vs étape précédente	Gain vs 15 axes	Écart au meilleur	Lecture
1	15	0.8468	-	-0.0393	0.0456	Gain encore utile
2	15	0.8590	0.0121	-0.0272	0.0334	Gain encore utile
3	15	0.8550	-0.004	-0.0312	0.0374	Gain encore utile
4	15	0.8676	0.0126	-0.0185	0.0248	Gain encore utile
5	15	0.8731	0.0055	-0.0131	0.0193	Gain encore utile
7	15	0.8815	0.0084	-0.0047	0.0109	Gain encore utile
10	15	0.8838	0.0023	-0.0024	0.0086	Gain encore utile
15	15	0.8862	0.0024	0.0000	0.0062	Choix retenu
20	15	0.8865	3e-04	0.0003	0.0059	Gain marginal faible
26	15	0.8924	0.0059	0.0062	0.0000	Gain marginal faible

plus stable et moins exposé au risque de sur-ajustement. Nous examinons donc plus finement les gains marginaux d’AUC associés à l’ajout progressif d’axes factoriels. Cette analyse montre que le passage de 15 à 26 axes améliore très peu l’AUC, alors qu’il augmente sensiblement la complexité du modèle. Nous retenons donc le modèle KNN avec $k = 15$ et 15 axes ACM comme compromis entre précision prédictive, stabilité et parcimonie.

Une représentation graphique de l’évolution de l’AUC Figure 11 et du F1 score Figure 12 par modèle est disponible en annexe

5.5 Choix du seuil de classification

Après le choix du modèle discriminant parcimonieux, défini par le KNN avec $k = 15$ et 15 axes ACM, nous procédons à l’optimisation du seuil de classification. En effet, le modèle produit un score associé à la modalité `is_canceled = Oui`, mais le seuil usuel de 0,50 n’est pas nécessairement optimal, en particulier lorsque l’objectif est d’améliorer la détection des annulations.

Nous réalisons donc une grid search du seuil sur la base validation, en testant une grille de valeurs comprises entre 0,10 et 0,90. Pour chaque seuil candidat, les observations sont classées en `Oui` ou `Non`, puis les indicateurs de performance sont recalculés. Le critère principal retenu est le F1-score, car il permet d’arbitrer entre le rappel, c’est-à-dire la capacité à détecter les annulations, et la précision, c’est-à-dire la limitation des fausses alertes. Le seuil finalement retenu est 0.34.

TABLE 6 – Seuil de classification retenu sur validation pour le modèle discriminant parcimonieux

Modèle	Axes ACM	k KNN	Seuil	Accuracy	Recall	Spécificité	Précision	F1-score	Balanced accuracy
ACM + KNN	15	15	0.34	0.8111	0.7706	0.8351	0.7352	0.7525	0.8029

6 Comparaison des résultats et conclusion

Cette dernière partie confronte les deux approches sur la base test, qui n'a pas été utilisée pour choisir les variables, le nombre d'axes, les hyperparamètres ou les seuils. Elle donne donc la mesure la plus honnête de la capacité de généralisation des modèles.

TABLE 7 – Performance finale des modèles sur la base test

Modèle	Seuil	Accuracy	AUC	Recall	Specificité	Precision	F1-score	Balanced accuracy
ACM + KNN (15 axes, k=15)	0.34	0.8174	0.8967	0.7825	0.8381	0.7417	0.7615	0.8103
Regression logistique - lasso	0.42	0.8118	0.8795	0.7378	0.8558	0.7524	0.7450	0.7968




FIGURE 3 – Comparaison finale des principaux indicateurs sur test

La régression logistique conserve l'avantage d'être plus directement interprétable : elle fournit des odds ratios et permet de quantifier l'effet des modalités sur la probabilité d'annulation. Elle constitue donc un modèle de référence solide pour expliquer les facteurs de risque.

L'approche DISQUAL, fondée sur l'ACM puis la classification, capte davantage la structure globale des profils qualitatifs. Dans notre évaluation finale, le meilleur modèle global est ACM + KNN (15 axes, k=15), avec une AUC de 0.897 et un F1-score de 0.762. Ce résultat indique que la représentation factorielle suivie du classifieur retenu apporte un gain prédictif sur la détection des annulations.

Sur le plan opérationnel, le modèle peut servir à prioriser les réservations à risque : les observations prédites comme annulées peuvent faire l'objet d'une relance, d'une politique de garantie adaptée ou d'une surveillance plus fine. Cette utilisation doit toutefois rester prudente : l'objectif n'est pas de sanctionner un client, mais d'anticiper le risque de no-show ou d'annulation afin d'aider la gestion hôtelière.

7 Sources des données et références

La base utilisée provient du jeu de données *Hotel Booking Demand Datasets*, diffusé sur Kaggle et documenté dans l'article scientifique publié dans *Data in Brief* : [Hotel Booking Demand Datasets](#). Les références méthodologiques relatives à la régression logistique et à l'analyse discriminante sur variables qualitatives seront complétées dans cette section.

- Ghojogh, B. et Crowley, M. (2019). *Linear and Quadratic Discriminant Analysis : Tutorial*. arXiv :1906.02590. <https://arxiv.org/abs/1906.02590>
- Stanford University. *Discriminant Analysis*, STATS305C. https://web.stanford.edu/class/stats305c/lectures/Discriminant_analysis.html
- James, G., Witten, D., Hastie, T. et Tibshirani, R. *An Introduction to Statistical Learning*. Voir le chapitre sur la classification. <https://www.statlearning.com/>
- Documentation R `DiscriMiner::disqual`. *Discriminant Analysis on Qualitative Variables*. <https://www.rdocumentation.org/packages/DiscriMiner/versions/0.1-29/topics/disqual>
- Cnam. *Cours - Méthodes factorielles*. <https://cedric.cnam.fr/vertigo/Cours/RCP208/coursMethodesFactorielles.html>
- Saporta, G. (2006). *Probabilités, analyse des données et statistique*. Technip.

8 Annexes

8.1 Tableaux complémentaires

TABLE 8 – Description des principales variables de la base de données

Variable	Description	Type	Choix
adr	Prix moyen journalier de la reservation.	Quantitative	Retenue
adults	Nombre d'adultes associes a la reservation.	Quantitative	Retenue
arrival_date_month	Mois d'arrivee prevue du client.	Qualitative	Retenue
babies	Nombre de bebes associes a la reservation.	Quantitative	Retenue
booking_changes	Nombre de modifications effectuees sur la reservation.	Quantitative	Retenue
children	Nombre d'enfants associes a la reservation.	Quantitative	Retenue
country	Pays d'origine du client, code selon la nomenclature pays disponible dans la base.	Qualitative	Retenue
customer_type	Type de client : Transient, Contract, Group ou Transient-Party.	Qualitative	Retenue
deposit_type	Type de depot ou garantie associe a la reservation.	Qualitative	Retenue
hotel	Type d'hotel concerne par la reservation : Resort Hotel ou City Hotel.	Qualitative	Retenue
is_canceled	Variable cible indiquant si la reservation a ete annulee : 1 = annulee, 0 = non annulee.	Qualitative	Retenue
is_repeated_guest	Indique si le client est deja venu auparavant : 1 = oui, 0 = non.	Qualitative	Retenue
lead_time	Nombre de jours entre la date de reservation et la date d'arrivee prevue.	Quantitative	Retenue
market_segment	Segment de marche ou canal commercial a l'origine de la reservation.	Qualitative	Retenue
previous_cancellations	Nombre d'annulations precedentes effectuees par le client.	Quantitative	Retenue
required_car_parking_spaces	Nombre de places de parking demandees par le client.	Quantitative	Retenue
stays_in_week_nights	Nombre de nuits en semaine reservees.	Quantitative	Retenue
stays_in_weekend_nights	Nombre de nuits de week-end reservees.	Quantitative	Retenue
total_of_special_requests	Nombre de demandes speciales formulees par le client.	Quantitative	Retenue
agent	Identifiant de l'agence de voyage ayant effectue la reservation, si applicable.	Qualitative	Non retenue
arrival_date_day_of_month	Jour du mois correspondant a l'arrivee prevue.	Quantitative	Non retenue
arrival_date_week_number	Numero de semaine de l'annee correspondant a l'arrivee prevue.	Quantitative	Non retenue
arrival_date_year	Annee d'arrivee prevue du client.	Quantitative	Non retenue
assigned_room_type	Type de chambre finalement attribuee.	Qualitative	Non retenue
company	Identifiant de l'entreprise associee a la reservation, si applicable.	Qualitative	Non retenue
days_in_waiting_list	Nombre de jours passes sur liste d'attente avant confirmation.	Quantitative	Non retenue
distribution_channel	Canal de distribution utilise pour effectuer la reservation.	Qualitative	Non retenue
meal	Type de repas reserve.	Qualitative	Non retenue
previous_bookings_not_canceled	Nombre de reservations precedentes non annulees par le client.	Quantitative	Non retenue
reservation_status	Statut final de la reservation : annulee, non annulee ou no-show.	Qualitative	Non retenue
reservation_status_date	Date du dernier statut de la reservation.	Date	Non retenue
reserved_room_type	Type de chambre initialement reserve.	Qualitative	Non retenue

TABLE 10 – Variables construites pour l'analyse

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
is_canceled	is_canceled	Recodage de 0/1 en Non/Oui	Variable cible a predire
lead_time_cat	lead_time	0 = derniere_minute ; <= 7 = court ; <= 30 = moyen ; <= 90 = long ; > 90 = tres_long	Mesurer l'anticipation de la reservation
total_nights	stays_in_week_nights + stays_in_weekend_nights	Somme des nuits en semaine et de week-end	Mesurer la duree totale du sejour
total_nights_cat	total_nights	<= 2 = court_sejour ; <= 5 = moyen_sejour ; > 5 = long_sejour	Regrouper les durees de sejour
adr_cat	adr	Decoupage de l'ADR en quartiles q1_low, q2_midlow, q3_midhigh, q4_high	Comparer les niveaux de prix
has_children	children + babies	Oui si au moins un enfant ou bebe, Non sinon	Identifier les reservations familiales
parking_reserved	required_car_parking_spaces	Oui si au moins une place de parking demandee, Non sinon	Mesurer un signe d'engagement du client
engagement	total_of_special_requests + booking_changes + 1 x parking_binary	Somme des demandes speciales et des changements de reservation et de reservation de place de parking	Score enrichi d'engagement
engagement_cat	engagement	0 = faible ; <= 2 = moyen ; >= 3 = fort	Comparer les niveaux d'engagement
previous_cancellations_cat	previous_cancellations	0 = Non ; >= 1 = Une_ou_plus	Capturer l'historique d'annulation
saison_tourisme	arrival_date_month	Juillet-aout = pick_saison ; juin-septembre = haute_saison ; avril-mai-octobre = moyenne_saison ; autres mois = basse_saison	Tenir compte de la saison touristique

(continued)

Variable	Variables sources	Règle de construction	Rôle dans l'analyse
repeated_guest_cat	is_repeated_guest	1 = Oui ; 0 = Non	Identifier les clients déjà venus
continent	country	Conversion du code pays ISO en continent avec countrycode et regroupement des codes non reconnus	Intermédiaire de construction de l'origine géographique
identity_location	country + continent	Portugal = Local_Portugal ; Europe hors Portugal = Europe_hors_PRT ; autres origines = Other_International	Resumer l'origine géographique du client pour la modélisation

8.2 Objectif de l'étude et démarche choisie

8.3 Annexe - Analyse discriminante sur variables qualitatives

8.3.1 Inertie des axes factoriels




FIGURE 7 – Décroissance de l'inertie de l'ensemble des axes ACM

TABLE 9 – Structure générale de la base de données

Indicateur	Valeur
Unite statistique	Une reservation hoteliere
Nombre d'observations initiales	119 390
Nombre de variables initiales	32
Nombre d'observations exclues au nettoyage	827
Nombre d'observations conservees apres nettoyage	118 563
Part de la base conservee	99.3%
Nombre de variables apres engineering	47
Nombre de reservations City Hotel	79 330
Nombre de reservations Resort Hotel	40 060
Variable cible	is_canceled
Reservations non annulees - base initiale	75 166
Reservations annulees - base initiale	44 224
Taux d'annulation - base initiale	37 %
Reservations non annulees - base nettoye	74 388
Reservations annulees - base nettoye	44 175
Taux d'annulation - base nettoye	37.3%
Valeurs manquantes au sens R	4
Variables avec valeurs manquantes	children (4)

TABLE 11 – Synthèse des contrôles et traitements de cohérence

Critère	Effectif	Pourcentage	Décision
ADR extreme superieur a 1000	1	0.00%	Exclu
ADR negatif	1	0.00%	Exclu
Aucun client renseigne	180	0.15%	Exclu
Sejour de 0 nuit	645	0.54%	Exclu
Conserve	118563	99.31%	Conserve




FIGURE 4 – Analyses bivariées en fonction de la variable d'intérêt




FIGURE 5 – Matrice d'associations des variables explicatives




FIGURE 6 – Démarche de modélisation

8.3.2 Représentation et interpretation des axes




FIGURE 8 – Plan factoriel 3-4 avec modalites labellisees

8.3.2.1 Axe 3 : nature du séjour et saisonnalité

L'axe 3 oppose des profils `market_segment = Corporate`, `identity_location = Other_International` et `saison_tourisme = basse_saison` a des profils `customer_type = Contract`, `total_nights_cat = long_sejour` et `hotel = Resort Hotel`.

Interpretation metier : cet axe distingue une logique plus professionnelle/internationale ou basse saison d'une logique plus touristique, resort et long sejour. Il structure donc les motivations probables du sejour. Cette distinction est importante car une reservation business, un sejour resort et un long sejour ne portent pas les memes contraintes d'annulation.

8.3.2.2 Axe 4 : volatilité opérationnelle autour du séjour

L'axe 4 oppose `customer_type = Group`, `total_nights_cat = long_sejour` et `customer_type = Contract` a `previous_cancellations_cat = Une_ou_plus`, `has_children = Oui` et `lead_time_cat = dernière_minute`. Les contributions de `adr_cat = q4_high`, `saison_tourisme = basse_saison`, `saison_tourisme = pick_saison`, `total_nights_cat = court_sejour` et `hotel = Resort Hotel` montrent que cet axe combine prix, saison et structure du sejour.

Interpretation metier : cet axe capte une forme de volatilité opérationnelle. Les reservations courtes, cheres, saisonnieres ou associees a un historique d'annulation peuvent etre plus difficiles a stabiliser.

La position de `is_canceled_Oui` sur cet axe confirme que cette dimension contient une information pertinente pour la prediction.

Plan factoriel 1-5

Modalites actives labellisees par variable d'origine et cible projetee




FIGURE 9 – Plan factoriel 1-5 avec modalites labellisees

8.3.2.3 Axe 5 : canal, prix et saison

L'axe 5 oppose `market_segment = Other`, `engagement_cat = fort` et `has_children = Oui` a `customer_type = Group`, `customer_type = Contract` et `lead_time_cat = derniere_minute`. Les contributions de `market_segment = Other`, `market_segment = Offline_TA`, `adr_cat = q3_midhigh`, `saison_tourisme = haute_saison` et `lead_time_cat = derniere_minute` indiquent que cet axe combine canal, niveau de prix et saison.

Interpretation metier : cet axe affine la lecture du risque en distinguant des profils commerciaux et saisonniers. Il ne represente pas un seul facteur simple, mais une combinaison de contexte de reservation, de prix et de periode touristique.

Modalites structurantes des axes ACM




FIGURE 10 – Modalites les plus contributives aux premiers axes

Les contributions indiquent quelles modalites construisent vraiment chaque axe. Une modalite peut etre eloignee du centre sans etre la plus structurante ; inversement, une modalite fortement contributive doit etre integree a l'interpretation de l'axe.

8.3.3 Tests statistiques sur les axes de l'ACM

TABLE 12 – Tests de Shapiro-Wilk sur les axes ACM candidats

Axe	Statistique	p-value	Conclusion
Dim 1	0.9791	0.0000	Normalite rejetee
Dim 2	0.9435	0.0000	Normalite rejetee
Dim 3	0.9627	0.0000	Normalite rejetee
Dim 4	0.9970	0.0007	Normalite rejetee
Dim 5	0.9965	0.0001	Normalite rejetee
Dim 6	0.9624	0.0000	Normalite rejetee
Dim 7	0.9980	0.0163	Normalite rejetee
Dim 8	0.9926	0.0000	Normalite rejetee
Dim 9	0.9065	0.0000	Normalite rejetee
Dim 10	0.9962	0.0001	Normalite rejetee
Dim 11	0.7692	0.0000	Normalite rejetee
Dim 12	0.9616	0.0000	Normalite rejetee
Dim 13	0.9788	0.0000	Normalite rejetee
Dim 14	0.9955	0.0000	Normalite rejetee
Dim 15	0.9876	0.0000	Normalite rejetee
Dim 16	0.9970	0.0007	Normalite rejetee
Dim 17	0.9930	0.0000	Normalite rejetee
Dim 18	0.9874	0.0000	Normalite rejetee
Dim 19	0.9427	0.0000	Normalite rejetee
Dim 20	0.9928	0.0000	Normalite rejetee
Dim 21	0.9989	0.2509	Normalite non rejetee
Dim 22	0.9964	0.0001	Normalite rejetee
Dim 23	0.9975	0.0026	Normalite rejetee
Dim 24	0.9960	0.0000	Normalite rejetee
Dim 25	0.9987	0.1302	Normalite non rejetee
Dim 26	0.9964	0.0001	Normalite rejetee

TABLE 13 – Tests de normalite multivariee sur les axes ACM candidats

Test	Statistic	p.value	Method	MVN	conclusion
Mardia Skewness	151806.120	<0.001	asymptotic	Non normale	Normalite multivariee rejetee
Mardia Kurtosis	187.651	<0.001	asymptotic	Non normale	Normalite multivariee rejetee
Henze-Zirkler	2.485	<0.001	asymptotic	Non normale	Normalite multivariee rejetee

TABLE 14 – Test de Box M pour l'homogeneite des matrices de covariance

Test	Statistique	Degres de liberte	p-value	Conclusion
Box M	149357	351	0	Homogeneite des covariances rejetee

8.3.4 Choix du nombre d'axes et du classifieur

TABLE 15 – AUC de validation selon le nombre d'axes ACM et le modèle

Nombre d'axes	LDA	QDA	KNN k = 5	KNN k = 15	KNN k = 26
1	0.6089	0.6089	0.8496	0.8468	0.8267
2	0.6777	0.7011	0.8558	0.859	0.844
3	0.6787	0.6988	0.8558	0.855	0.8404
4	0.7184	0.7562	0.8577	0.8676	0.8596
5	0.7353	0.7606	0.8646	0.8731	0.8649
7	0.7714	0.7998	0.8656	0.8815	0.8783
10	0.7993	0.8196	0.8699	0.8838	0.8818
15	0.8394	0.8368	0.8707	0.8862	0.8842
20	0.8621	0.8461	0.8716	0.8865	0.8843
26	0.8753	0.8582	0.8751	0.8924	0.8915




FIGURE 11 – AUC de validation selon le nombre d'axes ACM et le modèle




FIGURE 12 – F1-score de validation selon le nombre d'axes ACM et le modèle